

Introdução à Ciência de Dados


Alimed Celecia, Álvaro Veiga, Fernanda
Baião, Patrick Happ

PRÉ-PROCESSAMENTO DE DADOS OBTENÇÃO E TRATAMENTO



Data Science life cycle

(Relembbrando)




[Shcherbakov, M., Shcherbakova, N., Brebels, A., Janovsky, T., Kamaev, V., 2014, "Lean Data Science Research Life Cycle: A Concept for Data Analysis Software Development", Knowledge-Based Software Engineering, v. 466, pp. 708-716, Springer, 2014

Fayyad, Usama, Gregory Piatetsky-Shapiro, and Padhraic Smyth. "From data mining to knowledge discovery in databases." AI magazine 17.3 (1996): 37-37.

Data Science life cycle

(Simplificando)




[Shcherbakov, M., Shcherbakova, N., Brebels, A., Janovsky, T., Kamaev, V., 2014, "Lean Data Science Research Life Cycle: A Concept for Data Analysis Software Development", Knowledge-Based Software Engineering, v. 466, pp. 708-716, Springer, 2014]

Fayyad, Usama, Gregory Piatetsky-Shapiro, and Padhraic Smyth. "From data mining to knowledge discovery in databases." AI magazine 17.3 (1996): 37-37.

Data Science life cycle

(Simplificando)





[Shcherbakov, M., Shcherbakova, N., Brebels, A., Janovsky, T., Kamaev, V., 2014, "Lean Data Science Research Life Cycle: A Concept for Data Analysis Software Development", Knowledge-Based Software Engineering, v. 466, pp. 708-716, Springer, 2014]

Fayyad, Usama, Gregory Piatetsky-Shapiro, and Padhraic Smyth. "From data mining to knowledge discovery in databases." AI magazine 17.3 (1996): 37-37.

Data Science life cycle

(Simplificando)




[Shcherbakov, M., Shcherbakova, N., Brebels, A., Janovsky, T., Kamaev, V., 2014, "Lean Data Science Research Life Cycle: A Concept for Data Analysis Software Development", Knowledge-Based Software Engineering, v. 466, pp. 708-716, Springer, 2014]

Fayyad, Usama, Gregory Piatetsky-Shapiro, and Padhraic Smyth. "From data mining to knowledge discovery in databases." AI magazine 17.3 (1996): 37-37.

Data Science life cycle

(Simplificado)



ENTENDENDO OS DADOS
TIPOS DE DADOS E TIPOS DE BASES DE DADOS
QUALIDADE DOS DADOS
TÉCNICAS DE PRÉ-PROCESSAMENTO

Entendendo os dados

Não espera-se que todos sejam *experts* em todas as áreas, mas entendimento dos dados é essencial para iniciar um projeto e definir os dados a serem coletados

- Que dados estão disponíveis?
- Que dados são relevantes para a questão de pesquisa? Eles estão disponíveis/acessíveis?
 - Se não, ainda é possível endereçar a QP, ou ela deve ser reformulada?
 - Os dados podem ser enriquecidos com outras fontes ?
- Existem dados históricos suficientes?
 - Qual o horizonte temporal adequado a ser considerado?
- Quem são os especialistas neste domínio?
 - Eles participarão do projeto? Senão, qual o nível de comprometimento/disponibilidade deles para interação com a equipe?

Idealmente, deveria ser construído um modelo conceitual do domínio


- Conceitos e relacionamentos (restrições) envolvidos na questão de pesquisa que será endereçada no projeto de Ciência de Dados

Exemplo

QP: Dadas informações sobre um paciente novo no posto de saúde, quero descobrir se ele é um caso de COVID-19

- O que é a COVID-19?
 - O que caracteriza um indivíduo com COVID-19?
- O que é um caso COVID-19?
 - segundo a OMS?
 - segundo o ECDC?
 - (alguma outra definição relevante?)
- Como integrar os dados relacionados a estas definições?


Exemplo



Powered by Visual Paradigm Community Edition

Maddalena, L., & Baião, F. (2021). OntoCovid: Aplicando SABio para a modelagem conceitual bem fundamentada no domínio da COVID-19. In *14th Seminar on Ontology Research in Brazil, ONTOBRAS 2021 and 5th Doctoral and Masters Consortium on Ontologies, WTDO 2021* (pp. 259-266).

Exemplo



Maddalena, L., & Baïão, F. (2021). OntoCovid: Aplicando SABiO para a modelagem conceitual bem fundamentada no domínio da COVID-19. In *14th Seminar on Ontology Research in Brazil, ONTOBRAS 2021 and 5th Doctoral and Masters Consortium on Ontologies, WTD0 2021* (pp. 259-266).

O que é uma base de dados (dataset)?

Conjunto de objetos de dados e seus atributos

- Atributo
 - uma propriedade ou uma característica de um objeto
 - Ex: cor dos olhos de uma pessoa, temperatura máxima de um dia, data de óbito de alguém...
 - = variáveis, campos, características, features...

Uma coleção de atributos descreve objetos


- Objetos também são conhecidos como registros, pontos, casos, amostras, entidades ou instâncias

Atributos

Objetos

<i>Tid</i>	Refund	Marital Status	Taxable Income	Cheat
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

Tipos de Variáveis



Variável Nominal

Assume valores numéricos que representam classes mutuamente exclusivas

- Estado civil: casado, solteiro, viúvo.
- Bairro: Jardins, Itaim...
- CEP: 22453-900, 22450-193

CUIDADO: é importante que sejam mutuamente excludentes.

- ERRADO: segunda, ..., sexta, feriado
- CERTO: duas variáveis
 - segunda,.....domingo
 - feriado, não feriado

Variável Ordinal

Assume valores não numéricos que podem ser ordenados segundo algum critério.

- Nível de educação.
- Classe social.
- Faixa etária.

É frequente se transformar variáveis numéricas em variáveis ordinais através da criação de faixas

- idade.
- nível de renda.

Variável Dicotômica

Variável nominal com apenas duas classes

- Possui ou não cartão de crédito.
- Mora em apartamento próprio ou não.
- Casado ou não

Codificada numericamente como 0 ou 1 (valores binários)

- A soma de valores observados = número de vezes em que a classe 1 foi observada.

$$\sum_i x_i = \text{freqüência de 1}$$

- A média = freqüência relativa

$$\frac{1}{N} \sum_i x_i = \text{proporção de valores iguais a 1}$$

Variáveis Nominais e Binárias

- Variável nominal com k classes = conjunto de k-1 variáveis binárias
- Variáveis auxiliares (dummy variables)
- ex: profissão com 5 categorias

‘Dummy variavles[

Profissão	ENG	MED	ADV	MIL
Engenheiro	0	0	0	1
Médico	0	0	1	0
Advogado	0	1	0	0
Militar	1	0	0	0
outros	0	0	0	0

Variáveis Numéricas:

Escala Intervalar e Escala Proporcional

As variáveis numéricas podem se apresentar em duas formas principais:

- 1. variáveis de escala intervalar: não permitem a definição de um zero absoluto.
 - ex: medida de posição, temperatura.
- 2. Variáveis de escala proporcional: permitem a definição de um zero absoluto.
 - ex: a idade, o salário e o preço de um produto.


Na prática as duas formas são utilizadas quase indistintamente.

Tipos de variáveis - Resumo

Tipo de Variável		Propriedades	Estatísticas
Qualitativa	Nominal	Categórica não-ordenável	% de casos para cada classe Moda Tabela de Contingência
	Ordinal	Categórica ordenável	Mediana, percentis, correlação de ordem
Quantitativa	Numérica Intervalar	Apenas a diferença faz sentido	Média, Variância, correlação
	Numérica Proporcional	Diferença e divisão fazem sentido	
Ambos	Binária	0 ou 1	

Propriedades dos valores dos atributos

O tipo de um atributo define suas propriedades:



Atributos nominais: distinção

Atributos ordinais: distinção & ordem

Atributos de intervalo: distinção, ordem & adição

Atributos de razão: todas as 4 propriedades

Tipos de bases de dados

Base de Registros

- Coleção de objetos
- Matriz de dados
- Documentos
- Transações

Base de Grafos

- World Wide Web
- Estruturas moleculares

Base Ordenada

- Dados espaciais
- Dados temporais
- Dados sequenciais
- Dados com sequência genética

Base de Registros

Coleção de Objetos

Base que consiste de uma coleção de objetos, cada um consistindo de um conjunto finito de atributos

- Não existe relação entre os objetos
- Todo registro tem a mesma quantidade de atributos
- Representada de forma “flat”

<i>Tid</i>	Refund	Marital Status	Taxable Income	Cheat
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

Base de Registros

Matriz de Dados

Caso particular de uma base Registro, onde os atributos são todos numéricos.

Se os objetos tem o mesmo conjunto de atributos numéricos, então os objetos podem ser pontos em um espaço multi-dimensional, onde cada dimensão representa um atributo distinto

Tal base pode ser representada por uma matriz m por n , onde existem m linhas, uma para cada objeto e n colunas uma para cada atributo (operações entre matrizes podem ser feitas)

Projection of x Load	Projection of y load	Distance	Load	Thickness
10.23	5.27	15.22	2.7	1.2
12.65	6.25	16.22	2.2	1.1

Base de Registros

Base de documentos

Tipo de base de registro onde cada documento torna-se um vetor de termos

- Cada termo é um componente (atributo) do vetor,
- O valor de cada componente pode ser o número de vezes que o termo ocorre no documento.

	team	coach	play	ball	score	game	win	lost	timeout	season
Document 1	3	0	5	0	2	6	0	2	0	2
Document 2	0	7	0	2	1	0	0	3	0	0
Document 3	0	1	0	0	1	2	2	0	3	0

Base de Registros

Transações

Um caso especial de base de registros, onde cada objeto (transação) envolve um conjunto de itens.

- Objetos (transações, neste caso) ainda são independentes entre si, mas agora existe informação sobre “grupos” de coisas (itens) que existiram ou ocorreram juntos
- Ex: supermercado:
 - Transação = conjunto de produtos comprados por um cliente durante uma ida ao supermercado
 - Item = cada produto individual adquirido em uma transação

<i>TID</i>	<i>Items</i>
1	Bread, Coke, Milk
2	Beer, Bread
3	Beer, Coke, Diaper, Milk
4	Beer, Bread, Diaper, Milk
5	Coke, Diaper, Milk

Base Ordenada

Os atributos têm um relacionamento que envolve ordem

Sequências de transações:

- dados consideram o atributo tempo
 - Séries temporais
 - "Log de eventos"

Time	Customer	Items Purchased
t1	C1	A, B
t2	C3	A, C
t2	C1	C, D
t3	C2	A, D
t4	C2	E
t5	C1	A, E

Customer	Time and Items Purchased
C1	(t1: A,B) (t2:C,D) (t5:A,E)
C2	(t3: A, D) (t4: E)
C3	(t2: A, C)

QUALIDADE DOS DADOS

Qualidade dos dados: Por que pré-processar os dados?

Medidas para a qualidade dos dados: Uma visão multidimensional

- Precisão
- Completude
- Consistência
- Atualidade
- Confiabilidade
- Interpretabilidade

Como esses problemas se manifestam normalmente?

Qualidade dos dados:

Problemas típicos que requerem pré-processamento

Que tipo de problemas de qualidade de dados?

- Valores faltantes (missing values)

- Ruído (noise)

- Pontos fora da distribuição (outliers)

- Dados duplicados

Como podemos detectar problemas com os dados?

○ que podemos fazer a respeito desses problemas?

TÉCNICAS DE PRÉ-PROCESSAMENTO

Pré-Processamento

Por onde começar?

Apoio computacional é imprescindível

Conhecer o dado

- Análise descritiva
- Análises exploratórias
 - Muitos gráficos
- Acesso ao esquema (ou dicionário) dos dados ajuda muito

Pré-Processamento

Visão geral

O pré-processamento de dados pode ser visto como um processo (iterativo e interativo) de

- Detectar questões a serem tratadas nos dados
- Definir técnica para tratamento
- Aplicar técnica
- Avaliar impacto do tratamento

Essencialmente, se compara a um processo de ETL de ambientes de Business Intelligence

- Para saber mais...
 - Busque por “Ferramentas ETL” (Extraction/Transformation/Loading)

Técnicas de Pré-Processamento de dados

- Limpeza de dados
 - Tratar dados faltantes, ruídos, outliers, inconsistências
 - Tratar redundância de dados
- Redução de dados
 - Agregação
 - Seleção de dados (filtragem)
 - Amostragem
 - Redução de dimensionalidade
- Transformação de dados
 - Discretização e Binarização
 - Normalização
 - Transformação de atributos
 - Geração de hierarquia conceitual
- Engenharia de características (Feature Engineering)

Limpeza de dados

Os dados no mundo real são “sujos”

- erros de instrumento, erros humanos ou computacionais, erros de transmissão
- Incompletos (faltantes)
 - Ausência de valores do atributo para alguns objetos
 - Ex: cargo = “ ”
- Ruídos (Noise)
 - contendo erros, valores impossíveis ou logicamente incorretos
 - Ex: Salario=“-10”
- Outliers
 - Fora do padrão, mas potencialmente legítimos, teoricamente possíveis
 - valor_compra = R\$2.000.000,00
- Inconsistentes
 - contendo discrepâncias em códigos ou nomes
 - Ex.: idade=“42”, Birthday=“03/07/2020”
- Intencionalmente modificados (ex: dados faltantes disfarçados)
 - 1 de janeiro como aniversário de todos?

Dados incompletos ou faltantes (Missing Data)

Os dados nem sempre estão disponíveis

- Ex: endereço sem CEP, sintomas não preenchidos no prontuário, valores de compra zerados, ...

Podem se manifestar de várias formas

- NaN, espaço em branco, 0, vazio, NULL, ...

Possíveis razões

- defeitos em equipamento
- inconsistente com outros dados registrados e, portanto, excluídos
- dados não inseridos devido a mal-entendido
- certos dados podem não ter sido considerados importantes no momento da entrada
- não registrar histórico ou alterações dos dados

Impacto na qualidade dos modelos aprendidos

- Alguns algoritmos (scikit-learn estimators) assumem que todos os valores são numéricos e contêm valores com significado

O quê fazer com dados faltantes?

Como tratar dados faltantes?

idade	renda	comprou
20	2000	Sim
56	8200	Sim
31	2500	Não
12	900	Sim
24	500	Sim
78	4800	Não
18	1200	Sim
46		Sim
...		

1. Manter os valores faltantes
2. Remover dados faltantes
3. Preencher os valores faltantes manualmente
4. Preencher os valores faltantes automaticamente (Imputação)

Manter valores faltantes

- Na prática, deixa que o algoritmo de mineração lide com os valores faltantes
 - Alguns têm a capacidade de aprender a melhor estratégia de imputação com base em alguma métrica
 - XGBoost (training loss reduction)
 - Outros ignoram os valores faltantes
 - LightGBM (use_missing=false)
 - Geralmente, muitos algoritmos não são capazes de lidar e disparam erros em função de algum dado faltante (NaN, NULL, ...)
 - ie. Scikit learn — LinearRegression

Remover dados faltantes

Remover o registro (objeto, linha da tabela) completo

- escolha típica quando o atributo de classe está ausente (em projetos que requerem aprendizado supervisionado)
- Não é efetivo quando o % de valores faltantes por atributo varia consideravelmente
- Perde todos os outros atributos não faltantes do registro

idade	renda	comprou
20		Sim
56	8200	Sim
31		Não
12	900	Sim
24		Sim
78		Não
18	1200	Sim
46		Sim
...		

Remover dados faltantes

Remover o registro (objeto, linha da tabela) completo

- escolha típica quando o atributo de classe está ausente (em projetos que requerem aprendizado supervisionado)
- Não é efetivo quando o % de valores faltantes por atributo varia consideravelmente
- Perde todos os outros atributos não faltantes do registro

Remover todo o atributo da tabela

- Se o percentual de dados faltantes de um atributo for alto...
- Mas...
 - Perde todos os valores deste atributo para os demais objetos
- Não vale a pena se este atributo é muito relevante para o problema da pesquisa
 - ex: remover atributo “renda” para análise de crédito...

Imputação de dados

Mais populares

- Imputar uma constante global (ex: “unknown”, “INDEFINIDO”)
- Imputar o valor (médio/mediano) do atributo
- Imputar o valor (médio/mediano) do atributo para todas as amostras que pertencem à mesma classe
- Imputar usando valor (mais frequente)
- Imputar valor aleatório
- Imputar usando inferência
 - Estimar o valor provável usando k-NN, modelo bayesiano, árvore de decisão, ...

https://colab.research.google.com/github/UrbsLab/ML_Pipeline_Notebooks/blob/master/ML_102_Workshop.ipynb

Imputação de dados

Imputar valor (médio/mediano)

- calcular a media/mediana dos valores não faltantes de um atributo e substituir os valores faltantes de cada atributo separadamente e independentemente dos demais atributos
- Só funciona com atributos do tipo numérico.

	col1	col2	col3	col4	col5			col1	col2	col3	col4	col5	
0	2	5.0	3.0	6	NaN	mean()		0	2.0	5.0	3.0	6.0	7.0
1	9	NaN	9.0	0	7.0			1	9.0	11.0	9.0	0.0	7.0
2	19	17.0	NaN	9	NaN			2	19.0	17.0	6.0	9.0	7.0

Imputação de dados

Imputar valor (médio/mediano)

- Vantagens
 - Fácil, rápido
 - Funciona bem com datasets numéricos relativamente pequenos
- Desvantagens
 - Não considera a correlação entre atributos. Cada atributo é imputado de forma independente
 - Não se aplica a atributos do tipo categórico
 - Baixa precisão
 - Não considera incertezas
- Ex (Python)
 - <https://gist.github.com/wmlba/2621a6f418e5bda6ee9fcb129b79ae24#file-mean-impute-py>

Imputação de dados

Imputar usando valor (mais frequente) ou (zero/constante)

- substituir os valores faltantes de cada atributo por outro valor fixo (valor mais frequente, zero ou outra constante pré-determinada) deste mesmo atributo
- Vantagens
 - Fácil, rápido
 - Escalável
 - Funciona com atributos do tipo categórico
- Desvantagens
 - Não considera a correlação entre atributos. Cada atributo é imputado de forma independente
 - Pode introduzir viés na interpretação dos dados
- Ex (Python)
 - https://gist.github.com/wmlba/07a36758096b9462431b3e7daca3ad41#file-impute_most_frequent-py

Imputação de dados

Usando valores aleatórios

Substituir os valores faltantes por valores gerados aleatoriamente


Abordagens

- Missing completely at random (MCAR)
- Missing at random (MAR)
- Not missing at random (NMAR)

Imputação de dados

Imputação multivariada por equações encadeadas

- (Multivariate Imputation by Chained Equation - MICE)
 - Buuren, S. van, and Karin Groothuis-Oudshoorn. "mice: Multivariate imputation by chained equations in R." *Journal of statistical software* (2010): 1-68.
 - Valores faltantes são preenchidos múltiplas vezes
 - Múltiplas imputações avaliam melhor a incerteza dos valores faltantes



	id	sex	age	wt	ht	hgb
0	2	5.0	3.0	6.0	NaN	
1	9	NaN	9.0	0.0	7.0	
2	19	17.0	NaN	9.0	NaN	
3	7	10.0	3.0	6.0	4.0	
4	2	8.0	10.0	NaN	3.0	

`mice()`

	id	sex	age	wt	ht	hgb
0	2.0	5.0	3.00	6.00	4.666667	
1	9.0	10.0	9.00	0.00	7.000000	
2	19.0	17.0	6.25	9.00	4.666667	
3	7.0	10.0	3.00	6.00	4.000000	
4	2.0	8.0	10.00	5.25	3.000000	

Imputação de dados

Imputação multivariada por equações encadeadas

- Vantagens
 - Flexível
 - Funciona para atributos categóricos e numéricos
 - Considera a incerteza dos valores faltantes
- Desvantagens
 - Custo computacional
- Ex (Python)
 - https://gist.github.com/wmlba/5843bf488dee8259ad47a6b62e4cfc21#file-impute_mice-py

Imputação de dados

Imputar usando inferência

k-NN (k vizinhos mais próximos)

- Algoritmo usado para classificação
- Usa a ideia de “similaridade de características” com outros objetos do dataset de treinamento
- Encontra os k vizinhos mais próximos aos objetos com valores faltantes e então substitui os valores faltantes com base nos valores não faltantes da vizinhança
 - Média ponderada, ou valor mais frequente
- Vantagens
 - Maior precisão do que imputar média, mediana ou valor mais frequente (dependendo do dataset)
- Desvantagens
 - Custoso computacionalmente
 - Knn trabalha com todo o dataset em memória
 - Sensível a outliers
- Ex (Python)
 - https://gist.github.com/wmlba/801f8b3b2e10d96bbf70bf51a6ed1ddb#file-impute_knn-py

Imputação de dados

Imputação usando aprendizado profundo

- Valores faltantes são preenchidos usando redes neurais artificiais profundas
 - Deep Neural Networks
- Vantagens
 - Funciona para atributos categóricos e numéricos
 - Muito preciso
- Desvantagens
 - Complexo
 - Imputação de cada atributo
 - Custo computacional
- Ex (Python)
 - <https://gist.github.com/wmlba/b56f8023d4549dd1bca45a8b8c5d5201#file-impute-datawig-py>

Imputação de dados

- Qual a melhor técnica?
 - Não há “receita de bolo”
 - Processo experimental
 - Algumas restrições
 - tipo do dado
 - categórico, numérico
 - custo computacional, infraestrutura de TI disponível
 - hardware, poder computacional
 - técnica de aprendizado de máquina que será aplicada na etapa seguinte do ciclo de vida de Ciência de Dados

Mais sobre missing data...

“Missing Values in Data Mining”

- <https://sci2s.ugr.es/MVDM>

Ruídos (Noise)

Noise

- erro aleatório ou variância em uma variável, de acordo com uma medida

Possíveis razões

- instrumentos de coleta de dados defeituosos
- problemas de entrada de dados
- problemas de transmissão de dados
- limitação tecnológica
- Problemas de interpretação do significado

Tipos de ruído

Information Sources

Attributes		Class
Att 1	Att 2	Class
0.25	red	positive
0.25	red	negative
0.99	green	negative
1.02	green	positive
2.05	?	negative
=	green	positive

Kinds of Noise

Class Noise

- Contradictory examples
- Misclassified examples

Attribute Noise

- Erroneous values
- Missing values
- Don't care values

Ruído de classe (label noise)

- Ocorre quando um exemplo está classificado incorretamente.
- Exemplos contraditórios
- Classificações erradas

Ruído de atributo

- Valores de um ou mais atributos corrompidos
- Com erros
- Faltantes ou desconhecidos
- Incompletos ou “do not care”.

[X. Zhu, X. Wu, *Class Noise vs. Attribute Noise: A Quantitative Study*, Artificial Intelligence Review 22 (2004) 177-210
doi: [10.1007/s10462-004-0751-8](https://doi.org/10.1007/s10462-004-0751-8)]

Como tratar ruídos?

Basicamente, todas as técnicas de tratamento de dados faltantes se aplicam aqui...

- Exceto a manutenção dos ruídos (a menos em casos bem específicos)

Outras técnicas de tratamento de ruídos

- Binning
 - Ordenar os dados e particioná-los em “bins” (de igual frequência)
 - E então suavizar os dados de cada “bin” (pela média, moda, valores mínimo e máximo, ...).
- Regressão
 - Suavizar, adequando os dados a funções de regressão
- Clustering
 - Detectar e remover outliers

Combinar inspeção humana + automatizada

- Detectar valores suspeitos e verificar manualmente

*Cuidado: Os dados reais também podem ter ruído, portanto um modelo encontrado a partir de dados “completamente puros” pode ter um desempenho pior do que um modelo aprendido com dados com *algum* ruído...*

Mais sobre ruídos...

(alguns) artigos

- Gupta, S., & Gupta, A. (2019). Dealing with noise problem in machine learning data-sets: A systematic review. *Procedia Computer Science*, 161, 466-474.
- X. Zhu, X. Wu, Class Noise vs. Attribute Noise: A Quantitative Study, *Artificial Intelligence Review* 22 (2004) 177-210 doi: [10.1007/s10462-004-0751-8](https://doi.org/10.1007/s10462-004-0751-8)
- D. Nettleton, A. Orriols-Puig, A. Fornells, A Study of the Effect of Different Types of Noise on the Precision of Supervised Learning Techniques, *Artificial Intelligence Review* 33 (2010) 275-306 doi: [10.1007/s10462-010-9156-z](https://doi.org/10.1007/s10462-010-9156-z)

Página do grupo da U. Granada (Espanha)

- Noisy Data in Data Mining <https://sci2s.ugr.es/noisydata>

Exemplo de aplicacao de técnicas de tratamento de ruídos

- Libralon, G. L., de Leon Ferreira, A. C. P., & Lorena, A. C. (2009). Pre-processing for noise detection in gene expression classification data. *Journal of the Brazilian Computer Society*, 15(1), 3-11.

Outliers

Pontos fora da distribuição


O que é outlier?

“Um outlier é uma observação que se diferencia tanto das demais observações que levanta suspeitas de que aquela observação foi gerada por um mecanismo distinto” Hawkins

Diferente de ruído (noise), podem ser de interesse

- Detecção de fraude
- Detecção de invasão em uma rede


idade	renda	comprou
0.20	0.04	Sim
0.56	0.12	Sim
0.31	0.05	Não
0.12	0.01	Sim
0.24	0.01	Sim
0.78	0.08	Não
0.18	0.02	Sim
0.55	1.00	Sim
...		



Como detectar outliers?


Abordagem boxplot

- Mais simples, uso de modelagem estatística
- Lida com todos os tipos de atributos
 - Categóricos (nominais, ordinais) e contínuos (de intervalo, de razão)
- Boxplots sintetizam a distribuição estatística dos dados
 - valor mínimo (0%)
 - quartil inferior (25%)
 - Mediana (50%)
 - quartil superior (75%)
 - valor máximo (100%)



Abordagem boxplot para detectar outliers

- Outliers podem ser definidos como valores “muito” fora dos limites mínimo e máximo
 - Heurística: $1.5 \times \text{IQR}$ (inter quartil range) abaixo do valor mínimo ou acima do valor máximo



- <https://www.kaggle.com/code/hgultekin/box-plots-finding-all-outliers>

Outros métodos (para ir além...)

- Hodge, V.J., Austin, J. (2004) A survey of outlier detection methodologies. Artificial Intelligence Review. pp. 85126. ISSN 1573-7462
<https://doi.org/10.1023/B:AIRE.0000045502.10941.a9>

Exemplos práticos

(no contexto de análises exploratórias de dados)

- R
 - <https://r4ds.had.co.nz/exploratory-data-analysis.html>
- Python
 - <https://www.datacamp.com/community/tutorials/exploratory-data-analysis-python>
 - <https://www.kaggle.com/ekami66/detailed-exploratory-data-analysis-with-python>
- KNIME
 - <https://www.knime.com/blog/exploratory-data-analysis-with-knime-univariate-and-bivariate-visual-exploration>

Tratamento de dados Inconsistentes

Tipos de dados inadequados

- Violações às dependências lógicas
 - Ex: CEP versus bairro, erros ortográficos, trocas de letras nas palavras 😊
- Violações às regras do negócio
 - Valores fora do domínio (idade < 0!)
 - regras de unicidade (CPFs repetidos com nomes diferentes), regras de sequenciamento (data óbito > data de um exame) e regras de “nulidade” (vendas online sem vendedor associado)
- Como tratar as inconsistências?
 - um bom entendimento do domínio (ou ajuda de especialista!) é essencial

Tratamento de dados redundantes

Redundância de dados pode ocorrer com frequência na integração de dados

- Identificação de objetos: O mesmo atributo ou objeto pode ter nomes diferentes em fontes de dados distintas
- Dados derivados: Um atributo pode ser um dado “derivado” de outro atributo em outra tabela
- Ou pode acontecer de 2 ou mais atributos terem a mesma distribuição de valores (em termos estatísticos)

Técnicas de detecção e tratamento de redundâncias

- Conhecimento das regras do domínio
- Inspeção manual
- Inspeção automática através de técnicas de análise de correlação/dependência e análise de co-variância

ANÁLISE DE DEPENDÊNCIA E CORRELAÇÃO

Análise de dependência (Atributos nominais)

Ex: o Teste X^2 (chi-square)

- Sejam duas variáveis categóricas com duas classes cada uma
- Considere n objetos onde se observou essas duas variáveis
- Tabela de contingência : $X_{i,j}$ número de objetos com A_i e B_j

	Play chess	Not play chess	Sum (row)
Like science fiction	250	200	450
Not like science fiction	50	1000	1050
Sum (col.)	300	1200	1500

* <https://www.statisticshowto.com/probability-and-statistics/expected-value/>

Análise de dependência (Atributos nominais)

Questão: Jogar xadrez e gostar de SciFi são variáveis **DEPENDENTES ENTRE SI** ?

Calculando a proporção de enxadristas para quem gosta e quem não gosta de SciFi

	Play chess	Not play chess	Sum (row)
Like science fiction	56%	44%	100%
Not like science fiction	5%	95%	10%
Sum (col.)	20%	80%	

Distribuição esperada

- → Se fossem independentes as 2 primeiras linhas deveriam ser parecidas com a 3a.... Pois não faria diferença gostar ou não SciFi....

Análise de dependência (Atributos nominais)

Olhando no outro sentido.....

Proporção de enxadristas amantes de SciFi para quem gosta de SciFi e quem não gosta.

	Play chess	Not play chess	Sum (row)
Like science fiction	83%	17%	31%
Not like science fiction	17%	83%	72%
Sum (col.)	100%	100%	

- → Outra vez
- Se fossem independentes as 3 colunas deveriam ser parecidas.... Pois não faria diferença ser ou não exadrista....

* <https://www.statisticshowto.com/probability-and-statistics/expected-value/>

Análise de dependência (Atributos nominais)

O Teste χ^2 (chi-square)


$$\chi^2 = \sum_{i=1}^{n1} \sum_{j=1}^{n2} \frac{(\text{Observado em } i, j - \text{Esperado em } i, j)^2}{\text{Esperado em } i, j}$$

*Esperado em i, j = nro de observações da linha i * proporção de observações linha j*

Quanto maior o valor de χ^2 , mais dependência

Dependência não implica em causalidade

- Ex: # hospitais e # roubos de carros em uma cidade são tipicamente correlacionados. Ambos são causados por uma outra variável (população)
- (Ótima referência sobre o assunto)
 - Judea Pearl and Dana Mackenzie. *The book of why: the new science of cause and effect*. Basic books, 2018.



* <https://www.statisticshowto.com/probability-and-statistics/expected-value/>

Cálculo do Chi-Square:

Exemplo

	Play chess	Not play chess	Sum (row)
Like science fiction	250	200	450
Not like science fiction	50	1000	1050
Sum (col.)	300	1200	1500

$$Esperado_{i,j} = \frac{count(A = a_i) \times count(B = b_j)}{n}$$

Cálculo do Chi-Square:

Exemplo

$$e_{ij} = \frac{\text{count}(A = a_i) \times \text{count}(B = b_j)}{n},$$

	Play chess	Not play chess	Sum (row)
Like science fiction	250	200	450
Not like science fiction	50	1000	1050
Sum (col.)	300	1200	1500

$$Esperado_{i,j} = \frac{\text{count}(A = a_i) \times \text{count}(B = b_j)}{n}$$

$$Esperado_{1,1} = \frac{450 \times 300}{1500} = 90$$

$$Esperado_{2,1} = \frac{1050 \times 300}{1500} = 210$$

$$Esperado_{1,2} = \frac{450 \times 1200}{1500} = 360$$

$$Esperado_{2,2} = \frac{1050 \times 1200}{1500} = 840$$

Cálculo do Chi-Square:

Exemplo

	Play chess	Not play chess	Sum (row)
Like science fiction	250 (90)	200 (360)	450
Not like science fiction	50 (210)	1000 (840)	1050
Sum (col.)	300	1200	1500

(números entre parênteses são os valores esperados, calculados com base na distribuição dos dados entre as 2 categorias)

Cálculo do Chi-Square:

Exemplo

	Play chess	Not play chess	Sum (row)
Like science fiction	250 (90)	200 (360)	450
Not like science fiction	50 (210)	1000 (840)	1050
Sum (col.)	300	1200	1500

(números entre parênteses são os valores esperados, calculados com base na distribuição dos dados entre as 2 categorias)

$$\chi^2 = \frac{(250 - 90)^2}{90} + \frac{(50 - 210)^2}{210} + \frac{(200 - 360)^2}{360} + \frac{(1000 - 840)^2}{840} = 507.93$$

Alto, portanto “like_science_fiction” e “play_chess” são interdependentes

Análise de dependência (linear)

(Atributos numéricos)

Coeficiente de correlação de Pearson

$$COR(X, Y) = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\{\sum_{i=1}^n (x_i - \bar{x})^2\}} \cdot \sqrt{\{\sum_{i=1}^n (y_i - \bar{y})^2\}}}$$


Onde:

- x_i : valor da variável X na i-ésima observação;
- y_i : valor da variável Y na i-ésima observação;
- $\bar{x}$: média dos valores de X;
- $\bar{y}$: média dos valores de Y;
- n : número total de observações.

Análise de correlação (Atributos numéricos)

O que você espera em relação à correlação entre as Taxa Selic e IPCA?

Qual é a relevância de encontrar correlações?




Análise de correlação

(Atributos numéricos)


Qual é a relevância de encontrar correlações?

- Entre duas variáveis de entrada: possível redundância nos dados.
- Entre uma variável de entrada e de saída: possível maior importância da variável para o modelo.




Detecção visual da correlação

Gráficos de dispersão mostrando as similaridades entre -1 a 1 .




Detecção visual da correlação

Entretanto, devemos tomar cuidado com uma relação estatística que não é causada por uma conexão direta entre elas. Chamamos esse fenômeno de **correlação espúria**.



Detecção visual da correlação



AI explanation


As more people tuned in to watch The Big Bang Theory, they couldn't help but be influenced by all the talk of theoretical physics and geeky romance. With all that intellectual and romantic stimulation, it's no wonder there was a sudden surge in people trying to figure out the mechanics of baby-making!



Tyler Vigen
(tylervigen.com)


Detecção visual da correlação

Entretanto, devemos tomar cuidado com uma relação estatística que não é causada por uma conexão direta entre elas. Chamamos esse fenômeno de **correlação espúria**.



Detecção visual da correlação

Entretanto, devemos tomar cuidado com uma relação estatística que não é causada por uma conexão direta entre elas. Chamamos esse fenômeno de **correlação espúria**.



Discretização

- Alguns algoritmos de mineração de dados exigem que os atributos tenham valores categóricos.
- Discretização é a técnica de transformar um atributo numérico em um atributo categórico.
- Exemplos de técnicas de discretização
 - Número pré-definido de intervalos
 - Intervalos com mesma largura
 - Intervalos com mesma frequência
 - Intervalos dependentes da classe
- Ex:
 - <https://towardsdatascience.com/an-introduction-to-discretization-in-data-science-55ef8c9775a2>
 - <https://pandas.pydata.org/pandas-docs/version/0.23/generated/pandas.cut.html>

Discretização

Intervalos com mesma largura

- ▶ Considere os dados, crie os intervalos e mapeie cada valor numérico para o número do intervalo (bin) correspondente.
- ▶ Para a variável v a ser discretizada
 - ▶ Ordene os valores de v de forma crescente
 - ▶ Crie os intervalos
 - ▶ Defina o número de intervalos (k)
 - ▶ Sejam A e B o maior e o menor valor de v
 - ▶ $w = (A - B)/k$ // largura do intervalo
// As extremidades dos intervalos são $A+w$, $A + 2w$, ..., $A + (n-1)w$
 - ▶ Aplique a discretização nos valores originais de v
 - ▶ Crie uma nova variável v'
 - ▶ Para cada registro i da tabela original
 - ▶ $v'(i) =$ número do bin correspondente ao valor de $v(i)$


Discretização

Intervalos com mesma largura

- ▶ Ex: variável temperatura, $k = 7$
 - ▶ $w = (85 - 64) / 7 = 21 / 7 = 3$
 - ▶ 7 intervalos, cada um de largura 3

Temp	Temp_disc
64	1
65	1
68	2
69	2
70	3
71	3
72	3
72	3
75	4
75	4
80	6
81	6
83	7
85	7

valores
originais de v
no dataset:



Discretização

Intervalos com mesma largura

Cuidado...

- Intervalos com a mesma largura podem gerar distribuição desbalanceada entre os bins
 - quando existem muitas ocorrências em um intervalo e poucas nos outros
 - Ex: salário anual em uma grande corporação podem variar de 15K a 500k por ano....mas a maioria das ocorrências é perto do limite inferior
- Pode ser um problema para tarefas de mineração de dados
- Como evitar quando isso acontece?

Discretização

Intervalos com mesma frequência

- ▶ Considere os dados, crie os intervalos e mapeie cada valor numérico para o número do intervalo (bin) correspondente.
 - ▶ Para a variável v a ser discretizada
 - ▶ Ordene os valores de v de forma crescente
 - ▶ Crie os intervalos
 - ▶ Defina número de intervalos (k)
 - ▶ Seja n = número de registros na coluna v
 - ▶ $f = \text{topo}(n/k)$ // frequência (número de registros) no intervalo
 - ▶ Aplique a discretização nos valores originais de v
 - ▶ $i = 1$
 - ▶ Crie nova variável v'
 - ▶ Para cada registro $v(i)$ da tabela original
 - ▶ Enquanto $i \leq f$ faça
 - ▶ $v'(i) = I$
 - ▶ $i := i+1$


Discretização

Intervalos com mesma frequência

- ▶ Ex: variável temperatura, $k = 4$
 - ▶ $n = 14, f = \text{topo}(14/4) = 4$
 - ▶ 4 intervalos, cada um com 4 ocorrências

Temp	Temp_disc
64	1
65	1
68	1
69	1
70	2
71	2
72	2
72	2
75	3
75	3
80	3
81	3
83	4
85	4

valores
originais de v
no dataset:



Discretização

Intervalos com mesma frequência

- ▶ Distribuição uniforme dos dados
 - ▶ a menos do “resto”
- ▶ Cria intervalos de larguras distintas

Temp	Temp_disc
64	1
65	1
68	1
69	1
70	2
71	2
72	2
72	2
75	3
75	3
80	3
81	3
83	4
85	4

Discretização

Intervalos dependentes da classe

Intervalos dependentes de um atributo

- Utiliza o valor de um atributo (geralmente classe) para determinar onde colocar o breakpoint
- Ex: mínimo de 3 valores seguidos de um atributo em um intervalo e quebre assim que outro valor é encontrado

64	65	68	69	70	71	72	72	75	75	80	81	83	85
Yes	No	Yes	Yes	Yes	No	No	Yes	Yes	Yes	No	Yes	Yes	No

Pode-se aplicar conhecimento do domínio para criar intervalos com algum significado


Ex: idade: criança [0,12[, adolescente [12, 18[, adulto [18, ...]

<https://www.unicef.org/brazil/estatuto-da-crianca-e-do-adolescente>


Temp	Classe	Temp_disc
64	Yes	1
65	No	1
68	Yes	1
69	Yes	1
70	Yes	1
71	No	2
72	No	2
72	No	2
75	Yes	2
75	Yes	2
80	No	3
81	Yes	3
83	Yes	3
85	No	3

Discretização


Não supervisionada




Dados



Intervalos iguais



Frequencia igual



K-means

Discretização

Outras técnicas

https://www.academia.edu/4781426/Building_A_New_Taxonomy_For_Data_Discretization_Techniques

- Diferentes abordagens de discretização
 - Intervalos não disjuntos
 - permite sobreposição de intervalos
 - Iterativo
 - usa algumas técnicas e depois minimiza o erro de classificação
 - Lazy
 - discretiza somente durante a classificação
- Diferentes critérios de discretização
 - Baseado em entropia
 - ChiMerge
 - usa o teste Chi-quadrado da mesma forma que a entropia
 - Fuzzy
 - permite alguma imprecisão nos intervalos
 - Não supervisionada
 - Aplica-se técnica de clusterização ao dataset, cria-se uma nova feature para o cluster

Transformação de atributo

Uma função que mapeia todo o conjunto de valores de um atributo para um novo conjunto de forma que o valor antigo pode ser identificado com um dos novos valores

- Funções simples
 - Conversões de tipos (strings->datas), conversão de medidas (USD->R\$), ...
 - Conversão de categórico para numérico
 - **Padronização e normalização**
- Indo além...
 - <https://towardsdatascience.com/data-transformation-and-feature-engineering-e3c7dfbb4899>
 - <https://www.kaggle.com/code/parasjindal96/how-to-normalize-dataframe-pandas>

Transformação de atributo

Funções simples

- Exemplos
 - x^k , $\log(x)$, e^x , $|x|$, $1/x$
 - $1/x$
 - reduz a magnitude para números maiores do que 1 e aumenta para números entre 0 e 1
- Questões
 - A ordem deve ser mantida?
 - A transformação aplica-se para todos os valores?
 - especialmente negativos e zero
 - Qual o efeito da transformação para valores entre 0 e 1?

Transformação de atributo

Conversão de categórico para numérico

Alguns algoritmos de mineração de dados não conseguem utilizar atributos categóricos ou numéricos.

- Árvores de decisão lidam bem com atributos categóricos (símbolos), mas...
- Redes neurais (e muitos algoritmos de agrupamento) lidam somente com atributos numéricos

Como converter?

- Atributos binários
 - um valor é 0 o outro é 1
 - Atributos ordenados
 - converte para números preservando a ordem
 - Poucos valores
 - converte cada valor em um atributo binário
 - Muitos valores
 - converte um grupo de valores em um atributo binário
 - Valores únicos
 - ignore o atributo
-
- Busquem por *LabelEncoder*, *OneHotEncoding*...

<https://towardsdatascience.com/change-column-data-type-in-pandas-954d7acdef1d>

Transformação de atributo

Conversão de categórico para numérico

Qualquer modelo de Machine Learning entende apenas números.
Mesmo assim, é comum que algumas informações tabulares não estejam disponibilizadas para uso direto.

Resta a pergunta: **como tratar estes dados?**

Não existe uma forma correta de realizar este tipo de transformação, mas existem algumas técnicas tradicionais:

- Codificação real;

- Codificação binária;

- Codificação 1-N;

Transformação de atributo

Conversão de categórico para numérico

Codificação real: Transforma o atributo em um valor numérico, representando apenas como um único atributo

Exemplo: Meses do ano.

- 0 – Janeiro,
- 1 – Fevereiro,
- 2 – Março,
- etc.

Transformação de atributo

Conversão de categórico para numérico

Codificação real: Transforma o atributo em um valor numérico, representando apenas como um único atributo

Exemplo: Meses do ano.

- 0 – Janeiro,
- 1 – Fevereiro,
- 2 – Março,
- etc.

Atenção!

Modelos lineares podem interpretar diferenças numéricas como “distâncias iguais” entre categorias, o que nem sempre é verdade.

Transformação de atributo

Conversão de categórico para numérico

Codificação binária: Transforma um atributo em um Código binário. Com isso, um único atributo se transformará em n , onde $2^n \geq \# \text{atributos}$.

Exemplo: Meses do ano. Como são 12 meses, precisamos de 4 bits.

- 0 0 0 0 – Janeiro,
- 0 0 0 1 – Fevereiro,
- 0 0 1 0 – Março,
- etc.

Transformação de atributo

Conversão de categórico para numérico

Codificação 1-N: Também conhecido como “one-hot encoding”. Cada atributo categórico é representado por uma nova coluna. No caso, transformamos um atributo em n atributos, onde n é o número de valores distintos da variável.

Exemplo: Meses do ano. Como são 12 valores distintos, $n = 12$.

- 1 0 0 0 0 0 0 0 0 0 0 0 – Janeiro
- 0 1 0 0 0 0 0 0 0 0 0 0 – Fevereiro
- 0 0 1 0 0 0 0 0 0 0 0 0 – Março
- Etc


Transformação de atributo

Pode ser necessário normalizar os dados para comparar dois valores numéricos

- Ex: comparar pessoas por idade e ganho

idade	renda	comprou
20	2000	Sim
56	8200	Sim
31	2500	Não
12	900	Sim
24	500	Sim
78	4800	Não
18	1200	Sim
...		

idade	renda	vai comprar
50	4000	Sim



Transformação de atributo

Escalonamento

Pode ser necessário escalonar os dados para comparar dois valores numéricos:

- Ex: comparar pessoas por idade e ganho

Principais tipos de escalonamento:

- **Normalização min/max**

- Os dados transformados estão em um intervalo fixo [0, 1]
- Ex: 73.600 em [12.000, 98.000] para [0,1] é
 - $(73.600 - 12.000) / (98.000 - 12.000) * (1 - 0) + 0 = 0.716$

$$X' = \frac{X - X_{min}}{X_{max} - X_{min}}$$

- **Padronização (z-score)**

- Os dados transformados têm distribuição com média 0 e desvio padrão 1
- Ex: média 54.000, stddev=16.000, v=7.3600
 - $v' = 1.225$

$$Z = \frac{X - \mu}{\sigma}$$


<https://www.digitalocean.com/community/tutorials/normalize-data-in-python>

Transformação de atributo

Normalização

Por que temos diferentes formas para normalização?

- Dependendo da técnica utilizada, podemos transformar o comportamento da variável



REDUÇÃO DE DADOS

Redução de dados

Visão geral das técnicas

Agregação

Seleção de objetos

- Amostragem

Redução de dimensionalidade

- Feature Selection
- Feature extraction
 - PCA

Redução de dados

Agregação

Combinando 2 ou mais atributos (ou objetos) em um único atributo (ou objeto)

Objetivos

- Redução de dados e adequação aos objetivos da análise
 - Reduz o número de atributos ou objetos
- Alteração de escala
 - Cidades agregadas em regiões, estados, países, etc
 - Hospitalizações agregadas a pacientes
 - Pacientes agregados em hospitais
 - Dias agregados em semanas

“O quê agregar”?

Depende da questão de pesquisa já definida!

Redução de dados

Agregação

Vantagens

- Gera bases de dados menores, que
 - exigem menos memória e tempo de processamento
 - permitem o uso de algoritmos de mineração mais custosos.
- Pode fornecer uma visão mais alto nível dos dados
- Dados mais estáveis


Desvantagens

- Potencial perda de detalhes interessantes


Redução de dados

Agregação

Variação de precipitação na Austrália



Standard Deviation of Average
Monthly Precipitation



Standard Deviation of Average
Yearly Precipitation

Redução de dados

Seleção de objetos

Pode ser necessário selecionar uma porção dos dados ou remover objetos

- Talvez o algoritmo escolhido não se comporte bem com a base original
- Utilizada também para uma investigação inicial dos dados e para uma análise final.

Técnicas

- Particionamento
 - separa a base em seções e trabalha com cada uma em separado
 - Só funciona quando o algoritmo é desenvolvido para isso
- Amostragem
 - seleciona um subconjunto aleatório dos dados
 - assume que seja uma amostra representativa

Redução de dados

Seleção por Amostragem

A idéia principal para uma amostragem eficiente:

- Se a amostra é representativa, usar a amostra funciona tão bem quanto usar a base toda
- Uma amostra é representativa se tem aproximadamente as mesmas propriedades do conjunto inicial de dados

Vantagens:

- custo proporcional ao número de objetos na amostra

Desvantagens:

- pode não ser uma amostra representativa
 - É preciso ter cuidado com o método de amostragem, para evitar vieses (*bias*)

Tipos de Amostragem quanto à reposição dos objetos

Amostragem aleatória sem reposição

- Seleciona n objetos, com a mesma probabilidade de selecionar cada um
- Os objetos selecionados são retirados

Amostragem aleatória com reposição

- Como a anterior, mas o objeto não é retirado, logo pode ser selecionado novamente

Tipos de Amostragem

quanto à estratégia de escolha dos objetos

Amostragem sistemática:

- seleciona aleatoriamente 1 objeto entre os K primeiros e, após esse, seleciona objetos de k em k .


Amostragem estratificada:

- baseada em um atributo em particular
- Agrupa os objetos de acordo com os valores possíveis de algum atributo (classe)
- Seleciona uma amostra aleatória para cada grupo

Amostragem baseada em agrupamentos

- Agrupa os dados em k -grupos
- Seleciona uma amostra de cada grupo (com ou sem reposição)
- Vantagem: se o algoritmo de agrupamento executar bem, possivelmente a amostra é representativa
- Desvantagem: agrupamento é caro...possivelmente mais caro do que usar todos os dados

Redução de dimensionalidade



Alta dimensão = muitas características (ou colunas)

Problema conhecido como “Curse of Dimensionality”

- análise dos dados fica complicada à medida que a dimensão da base cresce.
- Quando a dimensionalidade aumenta, os dados tornam-se mais esparsos

Densidade e distância entre pontos tornam-se insignificantes

- crítico para algoritmos de agrupamento e detecção de outliers

Redução de dimensionalidade

Proposta: reduzir a dimensionalidade para

- Evitar curse of dimensionality
- Reduzir o tempo total e a exigência de memória para os algoritmos de mineração de dados
- Permitir que os dados sejam mais bem visualizados
- Poder auxiliar na eliminação de características irrelevantes ou redução de ruído

Técnicas

- As técnicas mais comuns considerando dados contínuos são baseadas em álgebra linear para encontrar um novo atributo como sendo uma combinação de outros

Redução de dimensionalidade

Seleção do subconjunto de atributos

Outra forma de reduzir a dimensionalidade da base é utilizar somente um subconjunto dos atributos

- Nem sempre existe perda de informação, já que podem ser desconsiderados os atributos:
 - redundantes
 - Duplica a maioria ou toda a informação de um ou mais atributos
 - Ex: preço de compra de um produto e o total de taxas pagas
 - irrelevantes
 - Não contem informação que seja útil para a tarefa de mineração de dados em questão
 - Ex: matrícula geralmente é irrelevante para a tarefa de predição do CR de um aluno

Redução de dimensionalidade


Mesmo retirando atributos irrelevantes e redundantes ainda é necessário reduzir o conjunto de atributos.

O que fazer?

Seleção do subconjunto de atributos

Feature selection

- é baseada na omissão das features medidas que não contribuem para a separabilidade de classes (Maduranga, 2016).
- Consiste na identificação de um subconjunto de features que serão usados para aprender um modelo (Fernández. et al. 2018)
- O objetivo é encontrar um conjunto mínimo de atributos de forma que a distribuição de probabilidade resultante das classes seja o mais próximo possível da distribuição original obtida usando todos os atributos. (Han, et al. 2011)



Abordagens de *Feature selection*


Força-bruta:

- Tenta todos os subconjuntos de atributos como entrada para o algoritmo de mineração de dados
 - Muito custoso

Abordagens heurísticas...

- Stepwise selection
 - Stepwise Forward Selection
 - encontra o melhor atributo e adiciona, iterativamente
 - Stepwise Backward Elimination
 - encontre o pior atributo e remove, iterativamente
- Outros...
 - Indução de árvore de decisão
 - Algoritmos genéticos
- https://scikit-learn.org/stable/modules/feature_selection.html


Feature selection

Forward selection	Backward elimination	Decision tree induction
Initial attribute set: $\{A_1, A_2, A_3, A_4, A_5, A_6\}$ Initial reduced set: $\{\}$ $\Rightarrow \{A_1\}$ $\Rightarrow \{A_1, A_4\}$ $\Rightarrow$ Reduced attribute set: $\{A_1, A_4, A_6\}$	Initial attribute set: $\{A_1, A_2, A_3, A_4, A_5, A_6\}$ $\Rightarrow \{A_1, A_3, A_4, A_5, A_6\}$ $\Rightarrow \{A_1, A_4, A_5, A_6\}$ $\Rightarrow$ Reduced attribute set: $\{A_1, A_4, A_6\}$	Initial attribute set: $\{A_1, A_2, A_3, A_4, A_5, A_6\}$  <pre> graph TD A4["A4?"] -- Y --> A1["A1?"] A4 -- N --> A6["A6?"] A1 -- Y --> C1_1(("Class 1")) A1 -- N --> C2_1(("Class 2")) A6 -- Y --> C1_2(("Class 1")) A6 -- N --> C2_2(("Class 2")) </pre> $\Rightarrow$ Reduced attribute set: $\{A_1, A_4, A_6\}$

Seleção do subconjunto de atributos

Feature extraction

- Feature extraction considera todo o conteúdo da informação e mapeia o conteúdo da informação útil em um espaço dimensional inferior. (Maduranga, 2016).
- Permite eliminar subconjuntos de atributos – dos processos de análise subsequentes – do conjunto original de atributos. (Hair et al., 1995).
- Um conjunto reduzido de atributos artificiais é criado a partir dos aspectos mais informativos das features . (Fernández, A. *et al.*, 2018)



Abordagens de *Feature extraction*

Principal Component Analysis (PCA)

- Muito popular na prática!

Muitas outras...

- Linear Discriminant Analysis (LDA)
 - Análise Discriminante Linear
 - Usa as informações de vários recursos para criar um novo eixo e projeta os dados de forma a minimizar a variância e maximizar a distância entre as médias das classes. (Maduranga, 2016).
- t-distributed Stochastic Neighbor Embedding (t-SNE)
 - Visualiza dados de alta dimensão, dando a cada ponto de dados uma localização em um mapa bidimensional ou tridimensional. (Van Der Maaten, Hinton, 2008)
- Autoencoders
 - São uma família de algoritmos de aprendizado de máquina que podem ser usados como uma técnica de redução de dimensionalidade (Maduranga, 2016). Rede neural com capacidade de redução de dimensionalidade não linear. (Sakurada, Yairi, 2014)
- Singular Value Decomposition - (SVD)
 - É um caso particular da abordagem de fatoração de matrizes e, portanto, também está relacionado à PCA. A principal questão de uma decomposição SVD é encontrar um espaço de recurso dimensional inferior usando o produto da matriz $U \times S \times V$. (Houari, R. et al. 2016).
- Discrete Wavelet Transform (DWT)
 - É uma técnica de processamento linear que, quando aplicada a um vetor de dados X , o transforma em um vetor numericamente diferente, X' , de coeficientes wavelet. Funciona também para remover o ruído sem suavizar as características principais dos dados. (Han et al., 2011)

PCA

Objetivo

Descrever a estrutura de variância e covariância de variáveis correlacionadas $x_1, x_2, \dots, x_p$ em termos de um conjunto de novas variáveis $y_1, y_2, \dots, y_p$ não correlacionadas.

Cada y_i é uma combinação linear das variáveis $x_1, x_2, \dots, x_p$

$$y_i = a_{i1}x_1 + a_{i2}x_2 + \dots + a_{ip}x_p$$

Novas variáveis y_i ordenadas em ordem decrescente de importância:

- y_1 (1ª componente principal) concentra a maior parte da variação dos dados originais entre todas as combinações lineares de $x_1, x_2, \dots, x_p$.
- y_2 (2ª componente principal) é não correlacionada com y_1 e concentra a maior parte da variação restante
- y_3 (3ª componente principal) é não correlacionada com y_1 e y_2 e concentra uma parcela ainda menor da variação, e assim sucessivamente.

PCA

Utilização

- As primeiras k ($k \ll p$) componentes principais concentram uma proporção substancial da variação das variáveis originais e consequentemente podem ser usadas para prover uma representação dos dados em um espaço de dimensão k
 - menor que o espaço original de p dimensões.


Criação de novas variáveis para o dataset

- Criação de variáveis explicativas não correlacionadas
 - para um modelo de regressão linear, por exemplo

<https://scikit-learn.org/stable/modules/generated/sklearn.decomposition.PCA.html>

PCA

2-dimensional dataset with principal components



Criação de atributos

Feature Engineering

Cria novos atributos a partir da base de dados

- Objetivo é representar, de forma mais explícita, características do domínio potencialmente relevantes para a questão sendo investigada
- “Arte” + empirismo
- Um dos recursos mais críticos para o sucesso de um projeto de Data Science!!

Três abordagens clássicas

- Extração de atributo
- Mapeamento dos dados para um novo espaço
- Construção de atributos
 - combinação de atributos
 - Ex: $\text{densidade} = \text{massa} / \text{volume}$

Criação de atributos

Feature Engineering

Feature Engineering
(Video)

idade	renda	sexo	escolaridade	comprou
20	2000	M	Fundamental	Sim
56	8200	F	Médio	Sim
31	2500	NE	Médio	Não
12	900	F	Superior	Sim
24	500	M	Fundamental	Sim
78	4800	M	Pós-graduado	Não
24	2100	F	Médio	Sim
...				

idade	renda	sexo	escolaridade	renda/idade	comprou
20	2000	M	Fundamental	100.00	Sim
56	8200	F	Médio	146.43	Sim
31	2500	NE	Médio	80.65	Não
12	900	F	Superior	75.00	Sim
24	500	M	Fundamental	20.83	Sim
78	4800	M	Pós-graduado	61.54	Não
24	2100	F	Médio	87.50	Sim
...					

DADOS EXTERNOS



idade	renda	sexo	escolaridade	renda/idade	concorrência	comprou
20	2000	M	Fundamental	100.00	Não	Sim
56	8200	F	Médio	146.43	Não	Sim
31	2500	NE	Médio	80.65	Sim	Não
12	900	F	Superior	75.00	Não	Sim
24	500	M	Fundamental	20.83	Sim	Sim
78	4800	M	Pós-graduado	61.54	Não	Não
24	2100	F	Médio	87.50	Não	Sim
...						

At the end of the day, some machine learning projects succeed and some fail. What makes the difference? Easily the most important factor is the features used [Pedro Domingos]

Criação de atributos

Muito mais sobre o assunto...

- <https://www.kdnuggets.com/2018/12/feature-engineering-explained.html>
- <https://machinelearningmastery.com/discover-feature-engineering-how-to-engineer-features-and-how-to-get-good-at-it/>
- Zheng, A., & Casari, A. (2018). *Feature engineering for machine learning: principles and techniques for data scientists*. "O'Reilly Media, Inc."

