


# Classificação

Alimed Celecia, Álvaro Veiga, Fernanda  
Baião, Patrick Happ


# Lembrando...

## Ciclo de vida de Ciência de Dados

(Simplificado)









# O que é classificação?

---

É a tarefa de prever um atributo nominal (uma categoria, ou *class label*) para um objeto cujo valor é desconhecido

- Categorias são valores discretos, sem ordenação

## Cenários de aplicação

- detecção de fraudes
  - [“fraude”, “não fraude”]
- concessão de crédito
  - [“risco”, “seguro”]
- recomendação de tratamento médico
  - [“tratamento A”, “tratamento B”, “tratamento C”]
- (Brainstorming) que outros exemplos vocês teriam?

# Classificação Aprendizado

---


## Aprendizado supervisionado

- dados históricos (observações, medidas) são considerados para aprender um **classificador** ("o modelo")
  - dados de treinamento são usados para "treinar" o modelo
  - dados de teste são usados para "avaliar" o modelo
- **dados de treinamento são previamente classificados (labeled)**

# Lembrando...

## Aprendizado supervisionado

(eu sei, vocês já viram isso antes... agora um pouco mais detalhado)



# Classificação

## Variáveis preditoras e de classe

---

- Variável de **resposta (classe)**: variável a prever
- Variáveis **preditoras**: variáveis resultantes do pré-processamento, e que juntas predizem o valor da variável de classe

**Variáveis preditoras**


**Variável de classe**

| Idade | Distância domicílio-saque | Fraude |
|-------|---------------------------|--------|
| 27    | 5                         | não    |
| 35    | 100                       | sim    |
| 80    | 150                       | sim    |
| 45    | 20                        | não    |

# Aprendizado versus uso do modelo

- Em tempo de aprendizado do modelo...

| Idade | Distância domicílio-saque | Fraude |
|-------|---------------------------|--------|
| 27    | 5                         | não    |
| 35    | 100                       | sim    |
| 80    | 150                       | sim    |
| 45    | 20                        | não    |






# Aprendizado versus uso do modelo


- Em tempo de aprendizado ...

| Idade | Distância domicílio-saque | Fraude |
|-------|---------------------------|--------|
| 27    | 5                         | não    |
| 35    | 100                       | sim    |
| 80    | 150                       | sim    |
| 45    | 20                        | não    |



- Em tempo de uso ...

| Idade | Distância domicílio-saque |
|-------|---------------------------|
| 32    | 100                       |



valor de classe [sim]

valor numérico [ $P(\text{sim}) = 0.8$ ]

Um problema de Classificação pode ser definido informalmente como a busca por uma função matemática que permita associar corretamente cada registro  $X_i$  (representado por suas variáveis preditoras) de um conjunto de dados a um único rótulo categórico,  $Y_i$ , (denominado variável de classe).

Uma vez identificada, esta função pode ser aplicada a novos registros para prever suas classes.

# Classificação vs. Regressão

## *(Spoiler)*

---

### Classificação

- prediz a categoria de uma classe dado um conjunto finito de possibilidades
- categorias são **enumeráveis** e **não ordenáveis**
  - Tipicamente um atributo nominal
- Alguns algoritmos predizem mais de uma categoria
  - indicando a probabilidade de cada uma delas


### Regressão

- prediz um número dentro de um **intervalo contínuo**
- conjunto infinito e ordenado de possibilidades
  - atributo contínuo
  - também denominada “predição numérica”
- Pode ser representada como uma função matemática


Algumas técnicas são aplicáveis a problemas destas duas naturezas:  
(KNN, regressão logística, redes neurais, ...)

# Classificação vs. Regressão (Spoiler)

CLASSIFICAÇÃO



REGRESSÃO



# Abordagem de classificação “Ansiosa” vs. “Preguiçosa”

---

## Ansiosa (Eager)

- Constrói o modelo quando recebe os dados de treinamento.
- Aprende na etapa de treinamento
- Maioria das técnicas de classificação
  - Árvores de decisão, “Rule-based”, “Random Forests”, SVM, Redes Bayesianas, ...

## Preguiçosa (Lazy)

- Não constrói um modelo na etapa de treinamento
  - Classificação das novas instâncias em “tempo real”, sob demanda
  - Faz só o suficiente para assegurar que os dados podem ser comparados posteriormente
- Também denominado **aprendizado baseado em instância**
- Ex: KNN



# Técnicas de classificação

---

Algumas das técnicas são :

- KNN 
- Árvores de decisão 
- Florestas aleatórias (Random Forests)
- Redes Bayesianas
- Redes Neurais
- SVM
- Métodos combinados (ensemble)

Classificador KNN

# KNN

---

- O algoritmo KNN (*k-Nearest Neighbours* ou, em português, *k-Vizinhos Mais Próximos*) é um algoritmo simples de entender e que funciona muito bem na prática tanto para problemas de Classificação quanto para problemas de Regressão.
- Este é um algoritmo não paramétrico, ele não assume premissas sobre a distribuição dos dados.
- Sua ideia principal é considerar que os exemplos vizinhos são similares ao exemplo cuja informação se deseja inferir.

# KNN: k-nearest neighbors

---

- Técnica de classificação que segue a abordagem preguiçosa
- Requer base de registros numérica
- Similaridade baseada na noção de distância entre instâncias
- Medida de distância
  - fácil se os dados são numéricos
  - distância Euclidiana
    - $d = \sqrt{(x_{1i}-x_{1j})^2 + (x_{2i}-x_{2j})^2 + \dots}$  (i e j instâncias)
    - Mais comumente usada
  - distância Manhattan/City Block
    - $d = (x_{1i}-x_{1j}) + (x_{2i}-x_{2j}) + \dots$

# KNN: Exemplo

---

- Determinar se uma bolsa de estudo será concedida ou não, com base nos seguintes atributos:
  - Renda familiar (ganho anual)
  - Numero de irmãos na família
  - Nota ENEM (0-10)
- Base de treinamento
  - (15.000; 3; 2; Não)
  - (16.500; 4; 8; Sim)
  - (450.000; 1; 7; Não)
- Instância nova: (20.000; 4; 9; ?)

*Intuição (refletida nos dados): Concede bolsa para alunos de bons rendimentos e de baixa renda...*

# KNN: Medida de distância

---

- Escalas diferentes entre os atributos podem levar a resultados diferentes...
  - Como evitar esse viés?

# Normalização

---

- Função para normalização (Min-Max)

$$x' = \frac{x - x_{min}}{x_{max} - x_{min}}$$

- $x$ : valor original do atributo
  - $x'$ : valor normalizado do atributo  $i$  (entre 0 e 1)
  - $x_{min}$ : menor valor do atributo dentro do conjunto de dados.
  - $x_{max}$ : maior valor do atributo dentro do conjunto de dados.
- 
- Escalonamento para intervalo fixo, ex.: [0,1]
  - A determinação dos valores mínimos e máximos é feita com os dados de treinamento!
  - A nova instância, quando recebida, também deve ser normalizada!



# KNN: Distância não numérica

- Para atributos não numéricos, só podemos comparar se os valores são iguais ou não.
- Convertendo em atributos numéricos
  - Valores Booleanos => converte para 0 ou 1
    - Ex: Fumante: [sim, não] => [1, 0]
  - Valores nominais não-binários
    - Usa conhecimento do domínio, quando aplicável
      - Ex: nível de escolaridade: [EF, EM, G, MSC, PHD] => [1,2,3,4,5]
    - One-hot encoding: Transforma 1 variável com n valores em n variáveis binárias
      - Ex: região: [N, NE, CO, SE, S] => [0,1]

| Fumante | Escolaridade | Região |
|---------|--------------|--------|
| Sim     | Fundamental  | SE     |
| Não     | Graduação    | NE     |
| Sim     | Médio        | N      |
| Não     | Mestrado     | S      |
| Não     | Fundamental  | S      |
| Não     | Doutorado    | NE     |
| Sim     | Médio        | N      |



| Fumante | Escolaridade | N | NE | CO | SE | S |
|---------|--------------|---|----|----|----|---|
| 1       | 1            | 0 | 0  | 0  | 1  | 0 |
| 0       | 3            | 0 | 1  | 0  | 0  | 0 |
| 1       | 2            | 1 | 0  | 0  | 0  | 0 |
| 0       | 4            | 0 | 0  | 0  | 0  | 1 |
| 0       | 1            | 0 | 0  | 0  | 0  | 1 |
| 0       | 5            | 0 | 1  | 0  | 0  | 0 |
| 1       | 2            | 1 | 0  | 0  | 0  | 0 |

# KNN: Ideia geral


---

- O processo é direto:
  - Encontre as  $k$  instâncias mais próximas da instância sendo classificada
- Para classificação
  - Predizer a classe mais comum entre essas instâncias
- Para problemas de regressão
  - Prediz a média

# KNN: visualização gráfica


---

- 5-NN: classifique o ponto preto



# KNN: visualização gráfica

- 5-NN: encontre as 5 instâncias mais próximas do ponto preto: 3 azuis, 2 vermelhas, prediz azul



► E se fosse 1-NN?

# Algoritmo KNN

---

As etapas a seguir resumem o algoritmo KNN para problemas de Classificação:

Definir a métrica de distância, critério de desempate e valor de **k**.

Para cada novo registro  $x$

1. Calcular a distância de  $x$  a cada um dos registros existentes no conjunto de dados.
2. Selecionar os **k** registros do conjunto de dados com a menor distância em relação a  $x$  (mais similares).
3. Atribui a  $x$  a classe mais frequente entre os **k** registros selecionados no passo anterior (votação majoritária)
  1. Em caso de empate, aplicar critério de desempate

# KNN

## O que precisa ser definido:

---

### Parâmetros

1. Que medida de distância usar?
2. Qual o valor adequado de **k**?

### Conjunto de treinamento e teste

3. Quais dados usar para treinamento?

### Avaliação do modelo (Pós-Processamento)

4. Qual métrica usar para avaliar o modelo?

# *Spoiler*

---

Essas são perguntas que valem para qualquer técnica de aprendizado de máquina, em um projeto de Ciência de Dados

## Parâmetros

1. Que medida de distância usar?
2. Qual o valor adequado de **k**?

## Conjunto de treinamento e teste

3. Quais dados usar para treinamento?

## Avaliação do modelo (Pós-Processamento)

4. Qual métrica usar para avaliar o modelo?

# (Voltando ao) KNN

---

1. Que medida de distância usar?
  - mais comuns são Euclidiana, Manhattan e Minkowski
  - Assumindo-se que os registros são representados por J variáveis preditoras:

$$\textit{Euclidiana: } d(x, y) = \sqrt{\sum_{j=1}^J (x_j - y_j)^2}$$


$$\textit{Manhattan: } d(x, y) = \sum_{j=1}^J |x_j - y_j|$$

$$\textit{Minkowski: } d(x, y) = \max(|x_j - y_j|)$$



# KNN

1. Que medida de distância usar?




*Distância euclidiana*

$$\begin{aligned}d(x, y) &= \sqrt{(70 - 80)^2 + (165 - 173)^2} \\&= \sqrt{(-10)^2 + (-8)^2} \\&= \sqrt{100 + 64} \\&= \sqrt{164} = \mathbf{12,81}\end{aligned}$$

# KNN

1. Que medida de distância usar?




*Distância Manhattan*

$$\begin{aligned}d(x, y) &= |70 - 80| + |165 - 173| \\&= |-10| + |-8| \\&= 10 + 8 = \mathbf{18}\end{aligned}$$

# KNN

1. Que medida de distância usar?



*Distância Minkowski*

$$\begin{aligned}d(x, y) &= \max(|70 - 80|, |165 - 173|) \\&= \max(|-10|, |-8|) \\&= \max(10, 8) = \mathbf{10}\end{aligned}$$

# KNN

---

## 2. Qual o valor adequado de $k$ ?


- normalmente determinado em função do conjunto de dados.
- Uma boa prática é utilização de **um valor ímpar**
  - evita empate.
- Quanto **maior** o valor de  $k$ 
  - **menor** o **efeito** de eventuais **ruídos** (ou **outliers**) no conjunto de dados.
  - mais difusas as fronteiras entre as classes
- Na prática, deve-se testar (experimentalmente) vários valores
  - Com parcimônia
  - Comece com  $K=3, 5, 7, \dots$  e avalie o ganho obtido em cada cenário

# KNN

---

## 3. Quais dados usar para treinamento?

- A ideia geral é sempre separar as etapas de treinamento e de teste
  - Treinamento: aprendizado do modelo
  - Teste: avaliação do modelo aprendido
- Objetivo é evitar overfitting
  - que limita a generalização do modelo aprendido




Testar o modelo aprendido em apenas 1 dataset ainda é uma abordagem muito limitada...

Portanto, recomenda-se sempre utilizar  
**VALIDAÇÃO CRUZADA (CROSS VALIDATION)**

# Validação cruzada

- Com a etapa de validação cruzada, o aprendizado do modelo incorpora uma etapa de validação
  - Conjunto de treinamento é subdividido em **treino e validação**
  - Várias iterações são executadas para avaliar diferentes configurações de parâmetros
    - Cada iteração gera um modelo candidato
- Objetivo é tornar o modelo mais **robusto**
  - O modelo candidato com melhor desempenho é então avaliado no conjunto de teste




# Validação cruzada

## Cuidado com as diferentes terminologias...

a literatura é muito confusa nessa denominação dos conjuntos (treino, validação, teste)... É muito frequente encontrar explicações de validação cruzada mencionando treino + teste (considerando a validação como um “teste intermediário” durante a varredura de parâmetros, o que não é um erro).

A dica é sempre lembrar dos objetivos de tornar o modelo final mais robusto e generalizável, e de usar partições (i.e., conjuntos disjuntos) para aprendizado e avaliação



# Validação cruzada


---

- Consiste em
  - particionar os dados de entrada em  $p$  subconjuntos (folds)
  - executar o algoritmo  $p$  vezes
    - selecionando em cada execução um dos folds para validação (e todos os demais para treinamento)
    - em cada execução aprende-se 1 modelo candidato
    - avalia-se cada modelo candidato
  - escolher o modelo candidato de melhor desempenho
- É executada antes da etapa de teste
  - do modelo candidato escolhido
- Partições são definidas aleatoriamente
  - amostras estratificadas ou balanceadas (veremos depois)
- Número de partições
  - tipicamente 5 (5-fold cross validation) ou 10 (10-fold cross validation)
  - Outros valores também são possíveis




# Validação cruzada

- *K- Fold Cross-validation*



- *Leave One Out Cross-Validation ( $k=n$ )*



# Validação cruzada

---

Imagine que, no exemplo anterior, temos 30 exemplos rotulados disponíveis

Queremos decidir se utilizamos  $k = 1$ ,  $k = 3$  ou  $k = 5$  para na aplicação do KNN.

Se utilizarmos validação cruzada com 3 folds (3-fold cross validation), uma possível partição dos dados entre treino e validação é como na figura:

# Validação cruzada

| id  | Peso (kg) | Altura (cm) | Sexo |
|-----|-----------|-------------|------|
| 1   | 55        | 167         | F    |
| 2   | 52        | 160         | F    |
| 3   | 48        | 155         | F    |
| ... | ...       | ...         | ...  |
| 9   | 58        | 165         | F    |
| 10  | 64        | 169         | F    |
| 11  | 78        | 179         | M    |
| ... | ...       | ...         | ...  |
| 18  | 70        | 175         | M    |
| 19  | 74        | 170         | M    |
| 20  | 80        | 180         | M    |
| 21  | 57        | 162         | F    |
| 22  | 59        | 161         | F    |
| ... | ...       | ...         | ...  |
| 29  | 72        | 170         | M    |
| 30  | 69        | 165         | M    |


Lembre-se: esta é apenas uma das partições possíveis dos dados entre treino e validação, utilizando 3-fold cross validation e selecionando um dos folds para validação

} fold

# KNN

## Conjunto de treinamento e validação

A figura mostra os dados representados graficamente, destacando os escolhidos para validação:



## Avaliação do modelo

---

### 4. Qual métrica usar para avaliar o modelo?


- Deve-se definir a **métrica de qualidade**
  - Número de acertos (=acurácia), por exemplo
    - Só vale para aprendizado supervisionado
  - Outras métricas são possíveis (veremos depois)
- A métrica pode ser calculada sobre o conjunto de treinamento (incluindo validação) ou de teste
  - Treinamento: indica quando parar o aprendizado
    - acima de um *threshold* pré-definido, ou após n tentativas
  - Teste: indica o quanto o modelo é generalizável para dados desconhecidos
    - Geralmente é o valor reportado da qualidade do modelo
- Se for aplicada **validação cruzada**, a métrica de qualidade deve ser calculada como a **média entre todas as execuções**

# KNN

## Avaliação do modelo

### 4. Qual métrica usar para avaliar o modelo?

- Assume-se que não conhecemos os rótulos dos exemplos da partição de teste:



# KNN

## Avaliação do modelo

---

4. Qual métrica usar para avaliar o modelo?

- Aprende-se (=treina-se) um modelo para cada cenário de experimentação, usando apenas os dados de treinamento
- Calcula-se a métrica de teste de cada cenário
  - Por exemplo, aqui definimos cenários variando o valor de  $k$  ( $k = 1$ ,  $k = 3$  e  $k = 5$ ), e calculamos a **acurácia**:

| k | Acurácia          |
|---|-------------------|
| 1 | 6/10 = 60%        |
| 3 | 7/10 = <b>70%</b> |
| 5 | 6/10 = 60%        |

- Seleciona-se o **cenário** que obtém maior acurácia de teste (no caso,  $k = 3$ ).

# KNN

## Relembrando o que precisa ser definido

---

Resumindo:

1. Que medida de distância usar?
  2. Qual o valor adequado de  $k$ ?
  3. Quais dados usar para treinamento?
  4. Qual métrica usar para avaliar o modelo?
- Dependendo dos **parâmetros escolhidos** (distância, valor de  $k$ ), **dados de treinamento e métrica utilizados**, podemos obter **resultados diferentes...**
  - A recomendação portanto é **experimental**
    - devem ser definidos cenários **variando cada um dos parâmetros sistematicamente**
      - Fixa todos, e varia um de cada vez...
      - Há também funções para automatizar este processo (vide: *Parameter Tuning*)
    - Para cada cenário são aprendidos vários modelos usando validação cruzada, e seleciona-se o modelo com a melhor métrica de avaliação no teste
      - Média entre todas as partições de teste
    - Depois, seleciona-se como modelo final aquele que obteve a melhor métrica de teste, dentre os modelos selecionados em cada cenário



# KNN

## (Des)Vantagens

---

- Vantagens
  - simples de entender e interpretar.
  - muito útil para dados não lineares
    - não há suposição sobre dados
  - Versátil
    - classificação, regressão
  - precisão relativamente alta
    - (embora haja modelos melhores de aprendizagem supervisionada)

# KNN

## (Des)Vantagens

---

- Desvantagens
  - Aprendizado relativamente caro (computacionalmente)
    - Em uma implementação trivial, pode precisar de  $|D|$  comparações
    - Requer muita memória (em comparação com outros algoritmos supervisionados)
      - armazena todos os dados de treinamento
  - uso do modelo (neste caso, coincidente com o aprendizado), também é lento e não escalável
    - Especialmente com  $N$  muito grande
  - Pouco robusto
    - escala dos dados, características irrelevantes
- Otimizações possíveis
  - paralelismo
    - Comparações independentes entre si
  - pré-processamento
    - remover instâncias da base de dados que não são úteis
  - utilizar estruturas de dados avançadas para melhorar a velocidade de classificação, através do armazenamento apropriado da informação
    - Estruturas de indexação dos dados

# KNN

## Exemplos

---


- KNIME
  - <https://kni.me/n/XBb4xHehqT9wYCl4>
- R
  - <https://www.rdocumentation.org/packages/DMwR/versions/0.4.1/topics/kNN>
- Python
  - <https://scikit-learn.org/stable/modules/neighbors.html>

Métricas de avaliação para Classificação

# Avaliação do modelo

---

- Como saber se o aprendizado foi efetivo?
- Como saber se o modelo aprendido, de fato, ajuda quando novos objetos são examinados?
- Quais métricas utilizar?
- Quais dados utilizar?



[This Photo](#) by Unknown Author is licensed under [CC BY](#)

# Avaliação do modelo

---

## Métricas de avaliação


- Dependentes do modelo aprendido...
  - Supervisionadas
    - **Validação externa**
    - Medidas de Erro
  - Não supervisionadas
    - Validação interna
    - Medidas de interesse

## Quais dados podem ser utilizados para avaliar?

- Hold-out
- Validação cruzada

# Métricas de Validação externa

- Aplicáveis a técnicas supervisionadas
  - Classificação
  - Alguns casos de agrupamento
- Recorrem ao particionamento de referência
  - Classes “reais” (Ground truth)
  - versus
  - Classes previstas (pelo modelo)



# Classificação binária

## Exemplo: Predição de câncer

---

- Dataset com 10000 registros
  - 70% "sim", 30% "não"

*Classes preditas pelo modelo*

| <div>Classes Reais</div> |  | Câncer? | Sim  | Não  | Total |
|--------------------------|--|---------|------|------|-------|
|                          |  | Sim     | 6954 | 46   | 7000  |
|                          |  | Não     | 412  | 2588 | 3000  |
|                          |  | Total   | 7366 | 2634 | 10000 |

Ground  
truth



# Matriz de confusão

## Classificação binária

- Assume-se uma das classes como “positiva”, e a outra como “negativa”
  - Definem-se subconjuntos VP, VN, FP, FN

|                      |            | <i>Classes preditas pelo modelo</i> |                                   |
|----------------------|------------|-------------------------------------|-----------------------------------|
|                      |            | <b>Câncer?</b>                      |                                   |
| <i>Classes Reais</i> | <b>Sim</b> | <b>Verdadeiros Positivos (VP)</b>   | <b>Falsos Negativos (FN)</b>      |
|                      | <b>Não</b> | <b>Falsos Positivos (FP)</b>        | <b>Verdadeiros Negativos (VN)</b> |

# Matriz de Confusão

## Exemplo: Predição de fraude

---

- **VP** (Verdadeiros Positivos)
  - Quantos casos de fraude foram preditos pelo modelo corretamente?
- **VN** (Verdadeiros Negativos)
  - Quantos casos de não fraude foram preditos pelo modelo corretamente?
- **FN** (Falsos Negativos)
  - Quantos casos de fraude foram preditos como não fraude por engano?
- **FP** (Falsos Positivos)
  - Quantos casos de não fraude foram preditos como fraude por engano?

|            |            | Predição do modelo |            |
|------------|------------|--------------------|------------|
|            |            | Fraude             | Não Fraude |
| Valor real | Fraude     |                    |            |
|            | Não Fraude |                    |            |

# Matriz de Confusão

## Exemplo: Predição de fraude

---

- **VP** (Verdadeiros Positivos)
  - Quantos casos de fraude foram preditos pelo modelo corretamente?
  - “na mosca”
- **VN** (Verdadeiros Negativos)
  - Quantos casos de não fraude foram preditos pelo modelo corretamente?
- **FN** (Falsos Negativos)
  - Quantos casos de fraude foram preditos como não fraude por engano?
- **FP** (Falsos Positivos)
  - Quantos casos de não fraude foram preditos como fraude por engano?

|            |            | Predição do modelo      |            |
|------------|------------|-------------------------|------------|
|            |            | Fraude                  | Não Fraude |
| Valor real | Fraude     | <b>VP</b><br>“na mosca” |            |
|            | Não Fraude |                         |            |

# Matriz de Confusão

## Exemplo: Predição de fraude

---

- **VP** (Verdadeiros Positivos)
  - Quantos casos de fraude foram preditos pelo modelo corretamente?
  - “na mosca”
- **VN** (Verdadeiros Negativos)
  - Quantos casos de não fraude foram preditos pelo modelo corretamente?
  - “tudo tranquilo”
- **FN** (Falsos Negativos)
  - Quantos casos de fraude foram preditos como não fraude por engano?
- **FP** (Falsos Positivos)
  - Quantos casos de não fraude foram preditos como fraude por engano?

|            |            | Predição do modelo      |                               |
|------------|------------|-------------------------|-------------------------------|
|            |            | Fraude                  | Não Fraude                    |
| Valor real | Fraude     | <b>VP</b><br>“na mosca” |                               |
|            | Não Fraude |                         | <b>VN</b><br>“tudo tranquilo” |

# Matriz de Confusão

## Exemplo: Predição de fraude

- **VP** (Verdadeiros Positivos)
  - Quantos casos de fraude foram preditos pelo modelo corretamente?
  - “na mosca”
- **VN** (Verdadeiros Negativos)
  - Quantos casos de não fraude foram preditos pelo modelo corretamente?
  - “tudo tranquilo”
- **FN** (Falsos Negativos)
  - Quantos casos de fraude foram preditos como não fraude por engano?
  - “deixei passar”
- **FP** (Falsos Positivos)
  - Quantos casos de não fraude foram preditos como fraude por engano?

|            |            | Predição do modelo      |                               |
|------------|------------|-------------------------|-------------------------------|
|            |            | Fraude                  | Não Fraude                    |
| Valor real | Fraude     | <b>VP</b><br>“na mosca” | <b>FN</b><br>“deixei passar”  |
|            | Não Fraude |                         | <b>VN</b><br>“tudo tranquilo” |

# Interpretação da Matriz de Confusão

## Exemplo: Predição de fraude

- **VP** (Verdadeiros Positivos)
  - Quantos casos de fraude foram preditos pelo modelo corretamente?
  - “na mosca”
- **VN** (Verdadeiros Negativos)
  - Quantos casos de não fraude foram preditos pelo modelo corretamente?
  - “tudo tranquilo”
- **FN** (Falsos Negativos)
  - Quantos casos de fraude foram preditos como não fraude por engano?
  - “deixei passar”
- **FP** (Falsos Positivos)
  - Quantos casos de não fraude foram preditos como fraude por engano?
  - ops... me enganei

|            |            | Predição do modelo               |                               |
|------------|------------|----------------------------------|-------------------------------|
|            |            | Fraude                           | Não Fraude                    |
| Valor real | Fraude     | <b>VP</b><br>“na mosca”          | <b>FN</b><br>“deixei passar”  |
|            | Não Fraude | <b>FP</b><br>“ops... me enganei” | <b>VN</b><br>“tudo tranquilo” |

# Matriz de confusão

- Classes não precisam ser exclusivamente “sim” e “não”
  - Ex: “alto risco” x “baixo risco”; “confirmou pedido” x “cancelou pedido”, ...
- Mas é necessário assumir uma das classes como “positiva” para interpretar a matriz de confusão

|                      |            | <i>Classes preditas pelo modelo</i> |                       |
|----------------------|------------|-------------------------------------|-----------------------|
|                      |            | Predição do modelo                  |                       |
|                      |            | Classe1 (= positiva)                | Classe2 (= negativa)  |
| <i>Classes Reais</i> | Valor real | Verdadeiros Positivos               | Falsos Negativos      |
|                      |            | Falsos Positivos                    | Verdadeiros Negativos |

Queremos minimizar

Queremos maximizar

# Métricas

---

- A partir das medidas da matriz de confusão, é possível calcular diversas métricas de qualidade
- Acurácia e Taxa de Erro
  - Total de Acertos
  - Total de Erros
  - Acurácia
  - Taxa de Erro
- Sensibilidade e Especificidade
  - Sensibilidade
  - Especificidade
  - Eficiência
- Cobertura e Precisão
  - Cobertura
  - Precisão
  - Medida-F
- Taxa de Predição
  - VPP
  - VPN
  - MCC (pesquisem...)



# Acurácia

---

- Também chamada de taxa de reconhecimento
- Percentual dos elementos no conjunto de teste que são corretamente classificados

$$\text{Acurácia} = (VP + VN) / (VP + FP + VN + FN)$$

- Pode-se também calcular a acurácia de cada classe

$$\text{Acurácia (classe positiva)} = (VP) / (VP + FN)$$

$$\text{Acurácia (classe negativa)} = (VN) / (FP + VN)$$

|            |                       | Predição do modelo    |                       |
|------------|-----------------------|-----------------------|-----------------------|
|            |                       | Classe1<br>(positiva) | Classe2<br>(negativa) |
| Valor real | Classe1<br>(positiva) | VP                    | FN                    |
|            | Classe2<br>(negativa) | FP                    | VN                    |

# Acurácia

## Exemplo

*Classes previstas pelo modelo*

|                      |         |                               |      |       |              |
|----------------------|---------|-------------------------------|------|-------|--------------|
| <i>Classes Reais</i> | Classes | Classes previstas pelo modelo |      | Total | Acurácia (%) |
|                      | Sim     | 6954                          | 46   | 7000  | 99.34        |
|                      | Não     | 412                           | 2588 | 3000  | 86.27        |
|                      | Total   | 7366                          | 2634 | 10000 | 95.42        |

- Acurácia (total):  $6954 + 2588 / 10000 = 9542 / 10000 = 0.9542$
- Acurácia (sim):  $6954 / 6954 + 46 = 6954 / 7000 = 0.9934$
- Acurácia (não):  $2588 / 412 + 2588 = 2588 / 3000 = 0.8627$

|            |                    | Predição do modelo |                    |
|------------|--------------------|--------------------|--------------------|
|            |                    | Classe1 (positiva) | Classe2 (negativa) |
| Valor real | Classe1 (positiva) | VP                 | FN                 |
|            | Classe2 (negativa) | FP                 | VN                 |

# Acurácia

Medida absoluta ou relativa?

---

## Exemplo



Acurácia: 90%

*É um bom classificador?*

# Acurácia

Medida absoluta ou relativa?

---

## Exemplo



Conjunto de Treinamento: 3% de casos de câncer (97% saudáveis)

Acurácia: 90%

*É um bom classificador?*

# Sensibilidade e Especificidade

- Sensibilidade
  - proporção dos objetos positivos corretamente identificados

$$\frac{\text{\#verdadeiros positivos}}{\text{\#verdadeiros}} = \frac{VP}{VP+FN}$$

- Especificidade
  - proporção dos objetos negativos corretamente identificados

$$\frac{\text{\# verdadeiros negativos}}{\text{\# negativos}} = \frac{VN}{VN+FP}$$

- Eficiência
  - média entre Sensibilidade e Especificidade

|            |                       | Predição do modelo    |                       |
|------------|-----------------------|-----------------------|-----------------------|
|            |                       | Classe1<br>(positiva) | Classe2<br>(negativa) |
| Valor real | Classe1<br>(positiva) | VP                    | FN                    |
|            | Classe2<br>(negativa) | FP                    | VN                    |

# Precisão e Cobertura

- Precisão
  - proporção de objetos corretamente classificados como positivo

$$\frac{\# \text{ verdadeiros positivos}}{\# \text{ verd. pos.} + \# \text{ falsos pos.}} = \frac{VP}{VP+FP}$$

- Cobertura, ou Revocação (Recall):
  - proporção dos objetos positivos corretamente identificados

$$\frac{\# \text{ verdadeiros positivos}}{\# \text{ verdadeiros}} = \frac{VP}{VP+FN}$$

Obs: Sensibilidade = Revocação

- Medida-F (F-Measure):
  - média harmônica entre precisão e cobertura

|            |                       | Predição do modelo    |                       |
|------------|-----------------------|-----------------------|-----------------------|
|            |                       | Classe1<br>(positiva) | Classe2<br>(negativa) |
| Valor real | Classe1<br>(positiva) | VP                    | FN                    |
|            | Classe2<br>(negativa) | FP                    | VN                    |

# Exemplo

*Classes previstas*

*Classes  
Reais*

| Classes | A = yes | A = no | Total | Reconhecimento (%) |
|---------|---------|--------|-------|--------------------|
| A = yes | 6954    | 46     | 7000  | 99.34              |
| A = no  | 412     | 2588   | 3000  | 86.27              |
| Total   | 7366    | 2634   | 10000 | 95.42              |

Sensibilidade:  $6954/7000 = 0.9934$

Especificidade:  $2588/3000 = 0.8627$

Precisão:  $6954/7366 = 0.9441$

# F-measure

(a.k.a. F1-measure, F-score)

- Média harmônica ponderada entre precisão e cobertura
  - F1-measure
    - Média harmônica simples (precisão e recall com mesmo peso)

$$\frac{2 \times (prec \times rev)}{prec + rev} = \frac{2}{\frac{1}{prec} + \frac{1}{rev}}$$

- Fo.5-measure
  - Prioriza precisão
- F-2 measure
  - prioriza cobertura

- Genericamente...

$$\frac{(1 + \alpha) \times (prec \times rev)}{\alpha \times prec + rev}$$

|            |                       | Predição do modelo    |                       |
|------------|-----------------------|-----------------------|-----------------------|
|            |                       | Classe1<br>(positiva) | Classe2<br>(negativa) |
| Valor real | Classe1<br>(positiva) | VP                    | FN                    |
|            | Classe2<br>(negativa) | FP                    | VN                    |



# Exemplos práticos

---

- R
  - <https://www.rdocumentation.org/packages/caret/versions/3.45/topics/confusionMatrix>
  - [https://cran.r-project.org/web/packages/cvms/vignettes/creating\\_a\\_confusion\\_matrix.html](https://cran.r-project.org/web/packages/cvms/vignettes/creating_a_confusion_matrix.html)
- Python)
  - [https://scikit-learn.org/stable/auto\\_examples/model\\_selection/plot\\_confusion\\_matrix.html](https://scikit-learn.org/stable/auto_examples/model_selection/plot_confusion_matrix.html)
  - <https://github.com/pandas-ml/pandas-ml>
  - <https://pypi.org/project/pandas-ml/>
  - <https://stackoverflow.com/questions/2148543/how-to-write-a-confusion-matrix-in-python/30385488>
- KNIME
  - <https://www.knime.com/blog/from-modeling-to-scoring-confusion-matrix-and-class-statistics>
  - [video](#)

# PPV e NPV

- PPV (Positive Predicted Value)
  - VALOR PREDITIVO POSITIVO (VPP)
  - = Precisão
  - proporção de verdadeiros positivos em relação a todas as predições positivas
  - $PPV = VP / (VP + FP)$
- NPV (Negative Predicted Value)
  - VALOR PREDITIVO NEGATIVO (VPN)
  - proporção de verdadeiros negativos em relação a todas as predições negativas.
  - $NPV = VN / (VN + FN)$

medidas altamente suscetíveis a desbalanceamentos do conjunto de dados... podem induzir a uma conclusão errada sobre o desempenho do sistema

Dica: busquem pela métrica MCC  
*Matthews's correlation coefficient*

|            |                       | Predição do modelo    |                       |
|------------|-----------------------|-----------------------|-----------------------|
|            |                       | Classe1<br>(positiva) | Classe2<br>(negativa) |
| Valor real | Classe1<br>(positiva) | VP                    | FN                    |
|            | Classe2<br>(negativa) | FP                    | VN                    |

# ROC

- “Receiver Operating Characteristics”
- Medida de desempenho da área de processamento de sinais
  - Muito utilizada na área médica
- Mostra relação entre 2 métricas para um classificador
  - Ideia é contrastar os benefícios de uma classificação correta com o custo de uma classificação incorreta
  - Taxa de falsos positivos *versus* Taxa de verdadeiros positivos
    - $TFP = FP / (FP + VN)$
    - $TVP = VP / (VP + FN)$
  - Sensibilidade *versus* especificidade (muito comumente usadas)
    - Sensibilidade =  $VP / (VP + FN)$
    - Especificidade =  $VN / (VN + FP)$

|            |                       | Predição do modelo    |                       |
|------------|-----------------------|-----------------------|-----------------------|
|            |                       | Classe1<br>(positiva) | Classe2<br>(negativa) |
| Valor real | Classe1<br>(positiva) | VP                    | FN                    |
|            | Classe2<br>(negativa) | FP                    | VN                    |

# Gráfico ROC

---

- Plotar o gráfico ROC dos 3 classificadores abaixo

Classificador 1  
TVP = 0.4  
TFP = 0.3




Classificador2  
TVP = 0.7  
TFP = 0.5



Classificador 3  
TVP = 0.6  
TFP = 0.2




# Gráfico ROC



# Curva ROC e AUC-ROC)

- Muito comumente utilizada para comparar resultados de um mesmo classificador em diferentes cenários
  - vários pontos (cenários) formam uma curva



- Costuma-se calcular então a área sob a curva ROC
  - *Area Under the Curve (AUC-ROC)*
  - Quanto mais a curva estiver próxima do canto superior esquerdo, maior a área e portanto melhor o classificador.

# Exemplos práticos

---

- SciKit-learn (Python)
  - [https://scikit-learn.org/stable/auto\\_examples/model\\_selection/plot\\_roc.html](https://scikit-learn.org/stable/auto_examples/model_selection/plot_roc.html)
  - [https://scikit-learn.org/stable/modules/generated/sklearn.metrics.roc\\_curve.html](https://scikit-learn.org/stable/modules/generated/sklearn.metrics.roc_curve.html)
- ROC, pROC, ... (R)
  - <https://rviews.rstudio.com/2019/03/01/some-r-packages-for-roc-curves/>
- KNIME
  - <https://hub.knime.com/knime/extensions/org.knime.features.js.views/latest/org.knime.js.base.node.viz.plotter.roc.ROCCurveNodeFactory>

## Classificação por Indução de Árvore de Decisão



# Árvores de Decisão

---

É um dos modelos preditivos mais simples, inspirada na forma como humanos tomam decisão.

*(Spoiler)*


Árvores de decisão podem ser usadas em problemas de **Classificação** (*Árvores de Classificação*) também em problemas de **Regressão** (*Árvores de Regressão*)

## Vantagens

- (em geral) é mais interpretável
  - padrões descobertos podem ser visualizados de uma forma fácil de entender pelo ser humano
- Funciona para dados não linearmente separáveis, como no exemplo a seguir:

# Árvores de Decisão

---



# Aprendizado de árvore de decisão

- Exemplo: Play tennis?

| Variáveis de predição |             |          |       | Variável de resposta |
|-----------------------|-------------|----------|-------|----------------------|
| Outlook               | Temperature | Humidity | Windy | Play?                |
| Sunny                 | hot         | high     | false | no                   |
| Sunny                 | hot         | high     | true  | no                   |
| Overcast              | hot         | high     | false | yes                  |
| Rain                  | mild        | high     | false | yes                  |
| Rain                  | cool        | normal   | false | yes                  |
| Rain                  | cool        | normal   | true  | no                   |
| Overcast              | cool        | normal   | true  | yes                  |
| Sunny                 | mild        | high     | false | no                   |
| Sunny                 | cool        | normal   | false | yes                  |
| Rain                  | mild        | normal   | false | yes                  |
| Sunny                 | mild        | normal   | true  | yes                  |
| Overcast              | mild        | high     | true  | yes                  |
| Overcast              | hot         | normal   | false | yes                  |
| Rain                  | mild        | high     | true  | no                   |

# Classificadores baseados em Árvores

---

- Queremos “aprender” regras do tipo...

R1: if Outlook=overcast then Play=Yes

R2: if Outlook=sunny and Temperature = cool then Play=Yes


R3: if Humidity = high and Temperature = hot and Outlook = sunny then Play=No

R4: ...

- E visualizá-las como uma árvore...

# Árvore de Decisão


---



# Árvore de Decisão

---


- Outro exemplo...



# Árvore de Decisão

Um classificador pode ser uma árvore de decisão


- Regra = caminho na árvore
  - ✓ Nó = teste em um atributo
  - ✓ Arestas = valores possíveis do nó de origem



# Aprendizado (indução) de árvore de decisão

Aprendizado de árvore de decisão a partir de dados históricos classificados


- Árvore de decisão
  - Nó interno
    - ✓ Um teste de uma variável de predição
  - Aresta (Split)
    - ✓ Um possível resultado do teste
  - Nó Folha
    - ✓ Valor da variável de resposta
      - ✓ 1 valor por folha






# Uso da árvore de decisão (induzida)

| se sente bem | tem dor | temperatura | saudável |
|--------------|---------|-------------|----------|
| não          | não     | 36.8        | ?        |



# Uso da árvore de decisão (induzida)

| se sente bem | tem dor | temperatura | saudável |
|--------------|---------|-------------|----------|
| não          | não     | 36.8        | sim      |



# Algoritmo para Aprendizado de Árvore

---

- **Princípio**
  - Algoritmo básico "guloso" (ID3, C4.5, C5.0, J4.8, CART, CHAID, Ctree, Hoeffding Tree...)
  - Estratégia top down, dividir-para-conquistar
- **Algoritmo**
  - Seleciona um atributo para o nó raiz.
  - Cria uma aresta para cada possível valor do atributo
  - Divide os registros em subconjuntos: um para cada aresta a partir do nó
  - Repete recursivamente para cada aresta, usando somente os registros que alcançaram a aresta
- **CrITÉrios de parada**
  - Todos os registros de um nó pertencem à mesma classe
  - Não existem mais atributos para seleção
    - Votação por maioria para atribuir valor de classe ao nó folha
  - Não existem mais registros

Mas... como selecionar um atributo?

Abordagem inicial: aleatoriamente (depois veremos como melhorar...)

# Aprendizado de árvore de decisão

- Exemplo: Play tennis?


| Variáveis de predição |             |          |       | Variável de resposta |
|-----------------------|-------------|----------|-------|----------------------|
| Outlook               | Temperature | Humidity | Windy | Play?                |
| Sunny                 | hot         | high     | false | no                   |
| Sunny                 | hot         | high     | true  | no                   |
| Overcast              | hot         | high     | false | yes                  |
| Rain                  | mild        | high     | false | yes                  |
| Rain                  | cool        | normal   | false | yes                  |
| Rain                  | cool        | normal   | true  | no                   |
| Overcast              | cool        | normal   | true  | yes                  |
| Sunny                 | mild        | high     | false | no                   |
| Sunny                 | cool        | normal   | false | yes                  |
| Rain                  | mild        | normal   | false | yes                  |
| Sunny                 | mild        | normal   | true  | yes                  |
| Overcast              | mild        | high     | true  | yes                  |
| Overcast              | hot         | normal   | false | yes                  |
| Rain                  | mild        | high     | true  | no                   |

1ª questão: Qual variável de predição escolher para começar (como raiz da árvore)?

# Escolha aleatória do atributo


| Outlook  | Temperature | Humidity | Windy | Play? |
|----------|-------------|----------|-------|-------|
| Sunny    | hot         | high     | false | no    |
| Sunny    | hot         | high     | true  | no    |
| Overcast | hot         | high     | false | yes   |
| Rain     | mild        | high     | false | yes   |
| Rain     | cool        | normal   | false | yes   |
| Rain     | cool        | normal   | true  | no    |
| Overcast | cool        | normal   | true  | yes   |
| Sunny    | mild        | high     | false | no    |
| Sunny    | cool        | normal   | false | yes   |
| Rain     | mild        | normal   | false | yes   |
| Sunny    | mild        | normal   | true  | yes   |
| Overcast | mild        | high     | true  | yes   |
| Overcast | hot         | normal   | false | yes   |
| Rain     | mild        | high     | true  | no    |

Escolha aleatória  
'windy'?



# Escolha aleatória do atributo

Escolha aleatória  
'windy'?




Precisamos refinar novamente

Olhando apenas os subconjuntos de registros de cada folha

- 8 e 6, respectivamente

Para windy=false, escolha (aleatoriamente) outlook

# Escolha aleatória do atributo (por enquanto)




| Outlook  | Temperature | Humidity | Windy | Play? |
|----------|-------------|----------|-------|-------|
| Sunny    | hot         | high     | false | no    |
| Sunny    | hot         | high     | true  | no    |
| Overcast | hot         | high     | false | yes   |
| Rain     | mild        | high     | false | yes   |
| Rain     | cool        | normal   | false | yes   |
| Rain     | cool        | normal   | true  | no    |
| Overcast | cool        | normal   | true  | yes   |
| Sunny    | mild        | high     | false | no    |
| Sunny    | cool        | normal   | false | yes   |
| Rain     | mild        | normal   | false | yes   |
| Sunny    | mild        | normal   | true  | yes   |
| Overcast | mild        | high     | true  | yes   |
| Overcast | hot         | normal   | false | yes   |
| Rain     | mild        | high     | true  | no    |

- Aresta "outlook = overcast", "outlook = rainy"
  - Critério de parada: todos os registros da mesma classe
  - Label do nó folha = valor da classe
    - para todos os registros que satisfazem as condições desde a raiz da árvore
- Aresta "outlook = sunny"
  - continua...

# Ok. Mas e quanto à seleção do atributo?

- Medida para seleção de um atributo
  - critério de divisão dos registros que "melhor" particione um conjunto de dados de entrada
- Idealmente
  - partições "puras"
    - contém registros que pertençam a mesma classe
  - árvores reduzidas
    - Não queremos árvores gigantescas...
    - (Pode haver dezenas., centenas, milhares, ... de atributos)





# Como reduzir o número de nós na árvore?


---

- Queremos que cada caminho da árvore seja o mais curto possível...
- Nós com registros de apenas 1 classe (puros) interrompem um caminho
- Mas... como fazer com que esses nós apareçam mais cedo na árvore?

**Grau de "pureza"**


# Seleção de atributos - Pureza

- Qual desses atributos está separando melhor os dados?



- ... e selecionar o atributo que resulta em partições mais "puras"...

# Seleção de atributos - Pureza




- Selecione o atributo que gere os nós (partições) mais "puros"
  - Em caso de empate, escolha aleatoriamente
- Resolve completamente o problema da escolha do atributo?
  - Ainda não...
  - A maioria dos dados não contém nós puros por vários níveis...
    - É necessária uma medida para quantificar a "pureza"

# Entropia como indicador de Pureza

## O caso do algoritmo C4.5

- C4.5 é um dos algoritmos mais tradicionais para IDT (*Inductive Decision Tree*)
  - Outros são ID3, C5.0, J4.8, CART, ...
  - <https://scikit-learn.org/stable/modules/tree.html#tree-algorithms-id3-c4-5-c5-0-and-cart>
- Escolha dos atributos (“pontos de separação”) aplica o conceito de **entropia**
  - A entropia de um conjunto de dados é um valor entre **0** e **1** que representa sua “pureza”
  - se em um conjunto todos os registros são da mesma classe, a entropia é **0**, e se cada registro é de uma classe diferente, a entropia é **1**.



**Alta entropia**

**Baixa entropia**

# Índice Gini como indicador de Pureza

---

- Índice de Gini


- Mede a **impureza** de um conjunto de exemplos  $t$  baseado no valor de  $P$ , que é a probabilidade de se associar uma determinada classe  $i$  a elementos desse conjunto, onde
  - $i$  pertence ao conjunto  $J$  de classes possíveis a serem associadas aos exemplos em  $t$ .

$$Gini(t) = 1 - \sum_{i=1}^J P(i|t)^2$$

# Usando o Índice de Gini para construir uma árvore de decisão


- Para cada atributo do dataset
  - calcula-se o  $Gini(t)$  para cada partição  $t$  resultante da escolha deste atributo

| viu o anúncio | acessou o link | idade | comprou |
|---------------|----------------|-------|---------|
| sim           | sim            | 38    | sim     |
| sim           | não            | 50    | não     |
| não           | não            | 83    | não     |
| sim           | sim            | 7     | não     |
| sim           | não            | 12    | não     |
| não           | sim            | 18    | sim     |
| não           | sim            | 35    | sim     |



$$Gini(t) = 1 - \sum_{i=1}^j P(i|t)^2$$

$$Gini(\text{viu o anúncio [sim]}) = 1 - (1/4)^2 - (3/4)^2 = 0.375$$





0.375

# Usando o Índice de Gini para construir uma árvore de decisão

- Para cada atributo do dataset
  - calcula-se o  $Gini(t)$  para cada partição  $t$  resultante da escolha deste atributo

| viu o anúncio | acessou o link | idade | comprou |
|---------------|----------------|-------|---------|
| sim           | sim            | 38    | sim     |
| sim           | não            | 50    | não     |
| não           | não            | 83    | não     |
| sim           | sim            | 7     | não     |
| sim           | não            | 12    | não     |
| não           | sim            | 18    | sim     |
| não           | sim            | 35    | sim     |





$$Gini(\text{viu o anúncio [sim]}) = 1 - (1/4)^2 - (3/4)^2 = 0.375$$

$$Gini(\text{viu o anúncio [não]}) = 1 - (2/3)^2 - (1/3)^2 = 0.444$$

# Usando o Índice de Gini para construir uma árvore de decisão

- Para cada atributo do dataset
  - calcula-se o  $Gini(t)$  para cada partição  $t$  resultante da escolha deste atributo

| viu o anúncio | acessou o link | idade | comprou |
|---------------|----------------|-------|---------|
| sim           | sim            | 38    | sim     |
| sim           | não            | 50    | não     |
| não           | não            | 83    | não     |
| sim           | sim            | 7     | não     |
| sim           | não            | 12    | não     |
| não           | sim            | 18    | sim     |
| não           | sim            | 35    | sim     |





$$Gini(\text{acessou o link [sim]}) = 1 - (3/4)^2 - (1/4)^2 = 0.375$$

$$Gini(\text{acessou o link [não]}) = 1 - (0/3)^2 - (3/3)^2 = 0$$



# Usando o Índice de Gini para construir uma árvore de decisão



| viu o anúncio | acessou o link | idade | comprou |
|---------------|----------------|-------|---------|
| sim           | sim            | 38    | sim     |
| sim           | não            | 50    | não     |
| não           | não            | 83    | não     |
| sim           | sim            | 7     | não     |
| sim           | não            | 12    | não     |
| não           | sim            | 18    | sim     |
| não           | sim            | 35    | sim     |



Qual dessas 2 *features* está separando melhor os dados?

# Usando o Índice de Gini para construir uma árvore de decisão

| viu o anúncio | acessou o link | idade | comprou |
|---------------|----------------|-------|---------|
| sim           | sim            | 38    | sim     |
| sim           | não            | 50    | não     |
| não           | não            | 83    | não     |
| sim           | sim            | 7     | não     |
| sim           | não            | 12    | não     |
| não           | sim            | 18    | sim     |
| não           | sim            | 35    | sim     |





Qual dessas 2 *features* está separando melhor os dados?

# Usando o Índice de Gini para construir uma árvore de decisão

- Para cada atributo a do dataset
  - Calcula-se a média dos índices de Gini de cada partição determinada por a

| viu o anúncio | acessou o link | idade | comprou |
|---------------|----------------|-------|---------|
| sim           | sim            | 38    | sim     |
| sim           | não            | 50    | não     |
| não           | não            | 83    | não     |
| sim           | sim            | 7     | não     |
| sim           | não            | 12    | não     |
| não           | sim            | 18    | sim     |
| não           | sim            | 35    | sim     |



Qual dessas 2 *features* está separando melhor os dados?

**Média** de Gini(viu o anúncio [sim]) e Gini(viu o anúncio [não])



viu o anúncio =  $(0.375 + 0.444) / 2 = 0.409$

acessou o link =  $(0.375 + 0.000) / 2 = 0.187$

# Usando o Índice de Gini para construir uma árvore de decisão

- Para cada atributo a do dataset
  - Calcula-se a média dos índices de Gini de cada partição determinada por a
    - Ponderada pelo tamanho da partição em relação ao tamanho do dataset

| viu o anúncio | acessou o link | idade | comprou |
|---------------|----------------|-------|---------|
| sim           | sim            | 38    | sim     |
| sim           | não            | 50    | não     |
| não           | não            | 83    | não     |
| sim           | sim            | 7     | não     |
| sim           | não            | 12    | não     |
| não           | sim            | 18    | sim     |
| não           | sim            | 35    | sim     |



Qual dessas 2 *features* está separando melhor os dados?

**Média ponderada** de Gini(viu o anúncio [sim]) e Gini(viu o anúncio [não])

$$\text{viu o anúncio} = (0.375 * 4/7) + (0.444 * 3/7) = 0.405$$


$$\text{acessou o link} = (0.375 * 4/7) + (0.000 * 3/7) = 0.214$$

# Usando o Índice de Gini para construir uma árvore de decisão

- Como definir partições no caso de atributos numéricos?

| viu o anúncio | acessou o link | idade | comprou |
|---------------|----------------|-------|---------|
| sim           | sim            | 38    | sim     |
| sim           | não            | 50    | não     |
| não           | não            | 83    | não     |
| sim           | sim            | 7     | não     |
| sim           | não            | 12    | não     |
| não           | sim            | 18    | sim     |
| não           | sim            | 35    | sim     |




?



# Usando o Índice de Gini para construir uma árvore de decisão

- Como definir partições no caso de atributos numéricos?

| viu o anúncio | acessou o link | idade | comprou |
|---------------|----------------|-------|---------|
| sim           | sim            | 38    | sim     |
| sim           | não            | 50    | não     |
| não           | não            | 83    | não     |
| sim           | sim            | 7     | não     |
| sim           | não            | 12    | não     |
| não           | sim            | 18    | sim     |
| não           | sim            | 35    | sim     |





| idade |
|-------|
| 38    |
| 50    |
| 83    |
| 7     |
| 12    |
| 18    |
| 35    |

# Usando o Índice de Gini para construir uma árvore de decisão

- Como definir partições no caso de atributos numéricos?
  - Ordenam-se os valores do atributo

| viu o anúncio | acessou o link | idade | comprou |
|---------------|----------------|-------|---------|
| sim           | sim            | 38    | sim     |
| sim           | não            | 50    | não     |
| não           | não            | 83    | não     |
| sim           | sim            | 7     | não     |
| sim           | não            | 12    | não     |
| não           | sim            | 18    | sim     |
| não           | sim            | 35    | sim     |






idade

| idade |
|-------|
| 7     |
| 12    |
| 18    |
| 35    |
| 38    |
| 50    |
| 83    |

# Usando o Índice de Gini para construir uma árvore de decisão

- Como definir partições no caso de atributos numéricos?
  - definem-se possíveis pontos de quebra (assumindo partições binárias)

| viu o anúncio | acessou o link | idade | comprou |
|---------------|----------------|-------|---------|
| sim           | sim            | 38    | sim     |
| sim           | não            | 50    | não     |
| não           | não            | 83    | não     |
| sim           | sim            | 7     | não     |
| sim           | não            | 12    | não     |
| não           | sim            | 18    | sim     |
| não           | sim            | 35    | sim     |






| idade |
|-------|
| 7     |
| 12    |
| 18    |
| 35    |
| 38    |
| 50    |
| 83    |



# Usando o Índice de Gini para construir uma árvore de decisão

- Como definir partições no caso de atributos numéricos?
  - definem-se possíveis pontos de quebra (assumindo partições binárias)

| viu o anúncio | acessou o link | idade | comprou |
|---------------|----------------|-------|---------|
| sim           | sim            | 38    | sim     |
| sim           | não            | 50    | não     |
| não           | não            | 83    | não     |
| sim           | sim            | 7     | não     |
| sim           | não            | 12    | não     |
| não           | sim            | 18    | sim     |
| não           | sim            | 35    | sim     |






| idade |
|-------|
| 7     |
| 12    |
| 18    |
| 35    |
| 38    |
| 50    |
| 83    |

# Usando o Índice de Gini para construir uma árvore de decisão

- Como definir partições no caso de atributos numéricos?
  - definem-se possíveis pontos de quebra (assumindo partições binárias)

| viu o anúncio | acessou o link | idade | comprou |
|---------------|----------------|-------|---------|
| sim           | sim            | 38    | sim     |
| sim           | não            | 50    | não     |
| não           | não            | 83    | não     |
| sim           | sim            | 7     | não     |
| sim           | não            | 12    | não     |
| não           | sim            | 18    | sim     |
| não           | sim            | 35    | sim     |






| idade |
|-------|
| 7     |
| 12    |
| 18    |
| 35    |
| 38    |
| 50    |
| 83    |

# Usando o Índice de Gini para construir uma árvore de decisão

- Como definir partições no caso de atributos numéricos?
  - definem-se possíveis pontos de quebra (assumindo partições binárias)

| viu o anúncio | acessou o link | idade | comprou |
|---------------|----------------|-------|---------|
| sim           | sim            | 38    | sim     |
| sim           | não            | 50    | não     |
| não           | não            | 83    | não     |
| sim           | sim            | 7     | não     |
| sim           | não            | 12    | não     |
| não           | sim            | 18    | sim     |
| não           | sim            | 35    | sim     |






| idade |
|-------|
| 7     |
| 12    |
| 18    |
| 35    |
| 38    |
| 50    |
| 83    |

# Usando o Índice de Gini para construir uma árvore de decisão

- Como definir partições no caso de atributos numéricos?
  - definem-se possíveis pontos de quebra (assumindo partições binárias)

| viu o anúncio | acessou o link | idade | comprou |
|---------------|----------------|-------|---------|
| sim           | sim            | 38    | sim     |
| sim           | não            | 50    | não     |
| não           | não            | 83    | não     |
| sim           | sim            | 7     | não     |
| sim           | não            | 12    | não     |
| não           | sim            | 18    | sim     |
| não           | sim            | 35    | sim     |






| idade |
|-------|
| 7     |
| 12    |
| 18    |
| 35    |
| 38    |
| 50    |
| 83    |

# Usando o Índice de Gini para construir uma árvore de decisão

- Como definir partições no caso de atributos numéricos?
  - definem-se possíveis pontos de quebra (assumindo partições binárias)

| viu o anúncio | acessou o link | idade | comprou |
|---------------|----------------|-------|---------|
| sim           | sim            | 38    | sim     |
| sim           | não            | 50    | não     |
| não           | não            | 83    | não     |
| sim           | sim            | 7     | não     |
| sim           | não            | 12    | não     |
| não           | sim            | 18    | sim     |
| não           | sim            | 35    | sim     |






| idade |
|-------|
| 7     |
| 12    |
| 18    |
| 35    |
| 38    |
| 50    |
| 83    |

# Usando o Índice de Gini para construir uma árvore de decisão

- Como definir partições no caso de atributos numéricos?
  - definem-se possíveis pontos de quebra (assumindo partições binárias)
    - média entre valores subsequentes

| viu o anúncio | acessou o link | idade | comprou |
|---------------|----------------|-------|---------|
| sim           | sim            | 38    | sim     |
| sim           | não            | 50    | não     |
| não           | não            | 83    | não     |
| sim           | sim            | 7     | não     |
| sim           | não            | 12    | não     |
| não           | sim            | 18    | sim     |
| não           | sim            | 35    | sim     |





|      | idade |
|------|-------|
| 9.5  | 7     |
| 15   | 12    |
| 26.5 | 18    |
| 36.5 | 35    |
| 44   | 38    |
| 66.5 | 50    |
|      | 83    |

# Usando o Índice de Gini para construir uma árvore de decisão

- Como definir partições no caso de atributos numéricos?
  - Calcula-se a média ponderada dos índices de Gini de cada partição determinada pelo ponto de quebra

| viu o anúncio | acessou o link | idade | comprou |
|---------------|----------------|-------|---------|
| sim           | sim            | 38    | sim     |
| sim           | não            | 50    | não     |
| não           | não            | 83    | não     |
| sim           | sim            | 7     | não     |
| sim           | não            | 12    | não     |
| não           | sim            | 18    | sim     |
| não           | sim            | 35    | sim     |




# Usando o Índice de Gini para construir uma árvore de decisão

- Como definir partições no caso de atributos numéricos?
  - Calcula-se a média ponderada dos índices de Gini de cada partição determinada pelo ponto de quebra

| viu o anúncio | acessou o link | idade | comprou |
|---------------|----------------|-------|---------|
| sim           | sim            | 38    | sim     |
| sim           | não            | 50    | não     |
| não           | não            | 83    | não     |
| sim           | sim            | 7     | não     |
| sim           | não            | 12    | não     |
| não           | sim            | 18    | sim     |
| não           | sim            | 35    | sim     |

?



idade

|       |   |      |
|-------|---|------|
| 0.429 | → | 9.5  |
| 0.343 | → | 15   |
| 0.476 | → | 26.5 |
| 0.476 | → | 36.5 |
| 0.343 | → | 44   |
| 0.429 | → | 66.5 |




# Usando o Índice de Gini para construir uma árvore de decisão

- Como definir partições no caso de atributos numéricos?
  - Seleciona o ponto de quebra que determina partições com menor índice Gini

| viu o anúncio | acessou o link | idade | comprou |
|---------------|----------------|-------|---------|
| sim           | sim            | 38    | sim     |
| sim           | não            | 50    | não     |
| não           | não            | 83    | não     |
| sim           | sim            | 7     | não     |
| sim           | não            | 12    | não     |
| não           | sim            | 18    | sim     |
| não           | sim            | 35    | sim     |

?





idade

|              |   |           |
|--------------|---|-----------|
| 0.429        | → | 9.5       |
| <b>0.343</b> | → | <b>15</b> |
| 0.476        | → | 26.5      |
| 0.476        | → | 36.5      |
| <b>0.343</b> | → | <b>44</b> |
| 0.429        | → | 66.5      |

# Usando o Índice de Gini para construir uma árvore de decisão


- Como definir partições no caso de atributos numéricos?
  - Seleciona o ponto de quebra que determina partições com menor índice Gini

| viu o anúncio | acessou o link | idade | comprou |
|---------------|----------------|-------|---------|
| sim           | sim            | 38    | sim     |
| sim           | não            | 50    | não     |
| não           | não            | 83    | não     |
| sim           | sim            | 7     | não     |
| sim           | não            | 12    | não     |
| não           | sim            | 18    | sim     |
| não           | sim            | 35    | sim     |




# Usando o Índice de Gini para construir uma árvore de decisão

| viu o anúncio | acessou o link | idade | comprou |
|---------------|----------------|-------|---------|
| sim           | sim            | 38    | sim     |
| sim           | não            | 50    | não     |
| não           | não            | 83    | não     |
| sim           | sim            | 7     | não     |
| sim           | não            | 12    | não     |
| não           | sim            | 18    | sim     |
| não           | sim            | 35    | sim     |







Qual dos 3 candidatos eu devo escolher como meu *root node*?




# Usando o Índice de Gini para construir uma árvore de decisão

| viu o anúncio | acessou o link | idade | comprou |
|---------------|----------------|-------|---------|
| sim           | sim            | 38    | sim     |
| sim           | não            | 50    | não     |
| não           | não            | 83    | não     |
| sim           | sim            | 7     | não     |
| sim           | não            | 12    | não     |
| não           | sim            | 18    | sim     |
| não           | sim            | 35    | sim     |




# Usando o Índice de Gini para construir uma árvore de decisão

| viu o anúncio | acessou o link | idade | comprou |
|---------------|----------------|-------|---------|
| sim           | sim            | 38    | sim     |
| sim           | não            | 50    | não     |
| não           | não            | 83    | não     |
| sim           | sim            | 7     | não     |
| sim           | não            | 12    | não     |
| não           | sim            | 18    | sim     |
| não           | sim            | 35    | sim     |




# Usando o Índice de Gini para construir uma árvore de decisão

| viu o anúncio | acessou o link | idade | comprou |
|---------------|----------------|-------|---------|
| sim           | sim            | 38    | sim     |
| sim           | não            | 50    | não     |
| não           | não            | 83    | não     |
| sim           | sim            | 7     | não     |
| sim           | não            | 12    | não     |
| não           | sim            | 18    | sim     |
| não           | sim            | 35    | sim     |




# Usando o Índice de Gini para construir uma árvore de decisão

| viu o anúncio | acessou o link | idade | comprou |
|---------------|----------------|-------|---------|
| sim           | sim            | 38    | sim     |
| sim           | não            | 50    | não     |
| não           | não            | 83    | não     |
| sim           | sim            | 7     | não     |
| sim           | não            | 12    | não     |
| não           | sim            | 18    | sim     |
| não           | sim            | 35    | sim     |



# Usando o Índice de Gini para construir uma árvore de decisão



| viu o anúncio | acessou o link | idade | comprou |
|---------------|----------------|-------|---------|
| sim           | sim            | 38    | sim     |
| sim           | não            | 50    | não     |
| não           | não            | 83    | não     |
| sim           | sim            | 7     | não     |
| sim           | não            | 12    | não     |
| não           | sim            | 18    | sim     |
| não           | sim            | 35    | sim     |






# Usando o Índice de Gini para construir uma árvore de decisão

| viu o anúncio | acessou o link | idade | comprou |
|---------------|----------------|-------|---------|
| sim           | sim            | 38    | sim     |
| sim           | não            | 50    | não     |
| não           | não            | 83    | não     |
| sim           | sim            | 7     | não     |
| sim           | não            | 12    | não     |
| não           | sim            | 18    | sim     |
| não           | sim            | 35    | sim     |



# Usando o Índice de Gini para construir uma árvore de decisão


| viu o anúncio | acessou o link | idade | comprou |
|---------------|----------------|-------|---------|
| sim           | sim            | 38    | sim     |
| sim           | não            | 50    | não     |
| não           | não            | 83    | não     |
| sim           | sim            | 7     | não     |
| sim           | não            | 12    | não     |
| não           | sim            | 18    | sim     |
| não           | sim            | 35    | sim     |



# Usando o Índice de Gini para construir uma árvore de decisão

Dadas as informações de interação em uma propaganda de um produto, quero treinar um modelo que preveja se uma pessoa vai ou não comprar esse produto


| viu o anúncio | acessou o link | idade | comprou |
|---------------|----------------|-------|---------|
| sim           | sim            | 38    | sim     |
| sim           | não            | 50    | não     |
| não           | não            | 83    | não     |
| sim           | sim            | 7     | não     |
| sim           | não            | 12    | não     |
| não           | sim            | 18    | sim     |
| não           | sim            | 35    | sim     |



# Usando o Índice de Gini para construir uma árvore de decisão

Dadas as informações de interação em uma propaganda de um produto, quero treinar um modelo que preveja se uma pessoa vai ou não comprar esse produto

| viu o anúncio | acessou o link | idade | comprou |
|---------------|----------------|-------|---------|
| sim           | sim            | 38    | sim     |
| sim           | não            | 50    | não     |
| não           | não            | 83    | não     |
| sim           | sim            | 7     | não     |
| sim           | não            | 12    | não     |
| não           | sim            | 18    | sim     |
| não           | sim            | 35    | sim     |



# Usando o Índice de Gini para construir uma árvore de decisão


Dadas as informações de interação em uma propaganda de um produto, quero treinar um modelo que preveja se uma pessoa vai ou não comprar esse produto

| viu o anúncio | acessou o link | idade | comprou |
|---------------|----------------|-------|---------|
| sim           | sim            | 38    | sim     |
| sim           | não            | 50    | não     |
| não           | não            | 83    | não     |
| sim           | sim            | 7     | não     |
| sim           | não            | 12    | não     |
| não           | sim            | 18    | sim     |
| não           | sim            | 35    | sim     |

TREINAMENTO

INFERÊNCIA

| viu o anúncio | acessou o link | idade | vai comprar |
|---------------|----------------|-------|-------------|
| sim           | sim            | 20    | ?           |



# Usando o Índice de Gini para construir uma árvore de decisão


Dadas as informações de interação em uma propaganda de um produto, quero treinar um modelo que preveja se uma pessoa vai ou não comprar esse produto

| viu o anúncio | acessou o link | idade | comprou |
|---------------|----------------|-------|---------|
| sim           | sim            | 38    | sim     |
| sim           | não            | 50    | não     |
| não           | não            | 83    | não     |
| sim           | sim            | 7     | não     |
| sim           | não            | 12    | não     |
| não           | sim            | 18    | sim     |
| não           | sim            | 35    | sim     |

TREINAMENTO


INFERÊNCIA

| viu o anúncio | acessou o link | idade | vai comprar |
|---------------|----------------|-------|-------------|
| sim           | sim            | 20    | sim         |




# Alternativas para o particionamento

- Binário versus multi-valorado




# Tendências no aprofundamento da árvore de decisão







# Tendências no aprofundamento da árvore de decisão




# Problemas de classificação



**Underfitting:** modelo com falta de complexidade para o problema




**Overfitting:** modelo com excesso de complexidade para o problema




Modelo adequado para o problema

# Como prevenir overfitting?




# Como prevenir overfitting?

Definir uma quantidade mínima de dados para o *splitting*




# Como prevenir overfitting?

Definir uma profundidade máxima da árvore




# Qual *feature* é a mais importante?

| viu o anúncio | acessou o link | idade | comprou |
|---------------|----------------|-------|---------|
| sim           | sim            | 38    | sim     |
| sim           | não            | 50    | não     |
| não           | não            | 83    | não     |
| sim           | sim            | 7     | não     |
| sim           | não            | 12    | não     |
| não           | sim            | 18    | sim     |
| não           | sim            | 35    | sim     |




# Qual *feature* é a mais importante?

| viu o anúncio | acessou o link | idade | comprou |
|---------------|----------------|-------|---------|
| true          | true           | 38    | 1       |
| true          | false          | 50    | 0       |
| false         | false          | 83    | 0       |
| true          | true           | 7     | 0       |
| true          | false          | 12    | 0       |
| false         | true           | 18    | 1       |
| false         | true           | 35    | 1       |




# Qual *feature* é a mais importante?

| viu o anúncio | acessou o link | idade | renda | comprou |
|---------------|----------------|-------|-------|---------|
| true          | true           | 38    | 4000  | 1       |
| true          | false          | 50    | 8500  | 0       |
| false         | false          | 83    | 4200  | 0       |
| true          | true           | 7     | 0     | 0       |
| true          | false          | 12    | 200   | 0       |
| false         | true           | 18    | 1500  | 1       |
| false         | true           | 35    | 2600  | 1       |
| false         | true           | 65    | 3600  | 1       |
| false         | true           | 19    | 1300  | 1       |
| ...           |                |       |       |         |






# Qual *feature* é a mais importante?



Qual *feature* é a mais importante?




# Qual *feature* é a mais importante?


$\Delta \text{impureza}$  = gini do nó de decisão - média ponderada do gini dos seus filhos

$\Delta \text{impureza} = 0.490 - ((0.444 * 450/700) + (0.480 * 250/700))$

$\Delta \text{impureza} = 0.033$




# Qual *feature* é a mais importante?



# Qual *feature* é a mais importante?

$$\text{Feature Importance}(f) = \frac{\sum \Delta \text{impureza de } f}{\sum \Delta \text{impureza}}$$




# Qual *feature* é a mais importante?

Feature Importance(*idade*) = 0.606

Feature Importance(*acessou o link*) = 0.217


Feature Importance(*renda*) = 0.093

Feature Importance(*viu o anúncio*) = 0.083



# Explicabilidade

| se sente bem | tem dor | temperatura | saudável |
|--------------|---------|-------------|----------|
| não          | não     | 36.8        | ?        |



# Árvores de decisão


## Exemplos

---

- KNIME
  - Training a Decision Tree - <https://kni.me/w/wjBRbBRnly6fu4gw>
- R
  - <https://cran.r-project.org/web/packages/C50/index.html>
- Python
  - <https://scikit-learn.org/stable/modules/tree.html>



# “Bagging/Boosting” – ideia geral



# Bagging/Boosting – vantagens

---

- Cada classificador resulta em uma predição
- $f_i(x)$
- Espera-se reduzir o erro utilizando os múltiplos classificadores...

# Random Forest

---

- $t$  amostras de subconjunto dos dados
  - Selecione amostras dos objetos, com repetição,  $n' < n$
- $p'$  amostras dos atributos
  - Selecione um subconjunto de atributos para cada subconjunto dos dados
- Construção de  $t$  árvores
  - Para cada subconjunto dos dados, usando um subconjunto de atributos
- Combinação das predições
  - Votação, média, média ponderada, ...

# Random Forests

## Exemplos

---

- KNIME
  - [https://kni.me/w/Sim-pKlioDWrgj\\_T](https://kni.me/w/Sim-pKlioDWrgj_T)
- R
  - <https://cran.r-project.org/web/packages/ranger/index.html>
  - <https://www.rdocumentation.org/packages/ranger/versions/0.12.1/topics/ranger>
- Python
  - <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html>

# XGBoost

---

**Gradient boosting** is a [machine learning](#) technique for [regression](#) and [classification](#) problems, which produces a prediction model in the form of an [ensemble](#) of weak prediction models, typically [decision trees](#). It builds the model in a stage-wise fashion like other [boosting](#) methods do, and it generalizes them by allowing optimization of an arbitrary [differentiable loss function](#)

- Exemplo prático
  - <https://xgboost.ai/about>
  - <https://blog.exploratory.io/introduction-to-extreme-gradient-boosting-in-exploratory-7bbec554ac7>