


Aprendizado de Regras de Associação


Alimed Celecia, Álvaro Veiga, Fernanda
Baião, Patrick Happ

Lembrando...

Ciclo de vida de Ciência de Dados

(Simplificado)





Quais questões/perguntas de pesquisa podem ser endereçadas com um dataset desta natureza?

- Quais perfis de compras são feitas na loja? Quais clientes mais se parecem entre si?
- Quais características dos pedidos mais bem explicam o tipo de entrega selecionada (ou: quais os veículos mais adequados para serem incluídos no contrato com a empresa de entrega da minha loja?)
- Mais alguma?

<i>Transaction#</i>	<i>Client</i>	<i>ProductBought</i>	<i>Price</i>	<i>Delivery mode</i>	<i>Payment mode</i>
1	John Smith	Computer	1500	Regular	Cash
1	John Smith	Monitor	200	Express	Cash
2	Steven	Notebook	2500	On site	Credit
3	Carol Hudson	Computer	20000	Regular	Credit
3	Carol Hudson	Monitor	400	Regular	Credit
4	Susan Davidson	Monitor	200	Express	Cash
5	John Mayer	Computer	2000	Regular	Credit
6	John Mayer	Monitor	400	Regular	Credit
7	Carol Hudson	Printer	300	Regular	Cash
8	Carol Hudson	No-break	500	Express	Cash

Quais questões/perguntas de pesquisa podem ser endereçadas com um dataset desta natureza?

- Quais perfis de compras são feitas na loja? Quais clientes mais se parecem entre si?
- Quais características dos pedidos mais bem explicam o tipo de entrega selecionada (ou: quais os veículos mais adequados para serem incluídos no contrato com a empresa de entrega da minha loja?)
- Mais alguma?

<i>Transaction#</i>	<i>Client</i>	<i>ProductBought</i>	<i>Price</i>	<i>Delivery mode</i>	<i>Payment mode</i>
1	John Smith	Computer	1500	Regular	Cash
1	John Smith	Monitor	200	Express	Cash
2	Steven	Notebook	2500	On site	Credit
3	Carol Hudson	Computer	20000	Regular	Credit
3	Carol Hudson	Monitor	400	Regular	Credit
4	Susan Davidson	Monitor	200	Express	Cash
5	John Mayer	Computer	2000	Regular	Credit
5	John Mayer	Monitor	400	Regular	Credit
6	Carol Hudson	Printer	300	Regular	Cash
7	Carol Hudson	No-break	500	Express	Cash

Mineração de Regras de associação

- Objetivos
 - Encontrar padrões de co-ocorrência de valores dos atributos entre as instâncias
 - Encontrar padrões frequentes, **associações, correlações** (eventualmente estruturas causais) entre **conjuntos de itens** ou objetos em **transações** no dataset de entrada
- Ao invés de prever um valor desconhecido, gostaríamos de encontrar fatos interessantes sobre o relacionamento entre os valores já conhecidos
- Requer base de dados de transações

Base de dados de transações

id	items
T1	meia, bola, cenoura, martelo, chave
T2	papel, peixe, vinho, limão
T3	cenoura, martelo, chave, rolo, maçã
T4	martelo, chave, peixe, vinho
T5	bola, peixe, vinho

id	meia	bola	cenoura	martelo	vinho	..
T1	1	1	1	1	0	...
T2	0	0	0	0	1	...
T3	0	0	1	1	0	...
T4	0	0	0	1	1	...
T5	0	1	0	0	1	...

Base de dados de registros -> Base de dados de transações

<i>Transaction#</i>	<i>Client</i>	<i>ProductBought</i>	<i>Price</i>	<i>Delivery mode</i>	<i>Payment mode</i>
1	John Smith	Computer	1500	Regular	Cash
1	John Smith	Monitor	200	Express	Cash
2	Steven	Notebook	2500	On site	Credit
3	Carol Hudson	Computer	20000	Regular	Credit
3	Carol Hudson	Monitor	400	Regular	Credit
4	Susan Davidson	Monitor	200	Express	Cash
5	John Mayer	Computer	2000	Regular	Credit
5	John Mayer	Monitor	400	Regular	Credit
6	Carol Hudson	Printer	300	Regular	Cash
7	Carol Hudson	No-break	500	Express	Cash



<i>Transaction#</i>	<i>Products</i>	<i>...</i>
1	Computer, Monitor	
2	Notebook	
3	Computer, Monitor	
4	Monitor	
5	Computer, Monitor	
6	Printer	
7	No-break	

Mineração de Regras de associação

Aprendizado não supervisionado

- dados de treinamento NÃO são previamente classificados
 - Não há “gabarito”

O que é uma regra de associação?

Estrutura formal composta por um *antecedente* e um *consequente*, e ambos consistem em conjunto de itens (itemsets).

$$\{P\tilde{a}o, manteiga\} \rightarrow \{Leite\}$$

Genericamente:

$$\{X_1, X_2, \dots, X_n\} \rightarrow \{Y_1, Y_2, \dots, Y_m\}$$

Usando regras de associação na prática

Aplicações

- Análise de “carrinho de compras”, marketing cruzado
 - Encontrar padrões de itens que são adquiridos em conjunto em um estabelecimento
 - “Quem compra fralda também compra...” 😊
- Análise de comportamento temporal
 - Como antecipar as necessidades de um cliente?
 - Ex: t1: (fralda = sim) -> t2: (berço = sim)
- Obs: também pode ser aplicada para problemas de Classificação!!!!
 - Vamos ver um pouco mais tarde...

Aplicações de regras de associação

- Análise de “carrinho de compras”, marketing cruzado
 - Encontrar itens adquiridos conjuntamente
 - “Quem compra fralda também compra...” 😊 → E VICE VERSA....
- Análise de comportamento temporal
 - Como antecipar as necessidades de um cliente?
 - Ex: t1: (fralda = sim) -> t2: (berço = sim)
- Obs: também pode ser aplicada Classificação!!!!
 - Vamos ver um pouco mais tarde...

Aplicações de regras de associação

- Análise de “carrinho de compras”, marketing cruzado
 - Encontrar itens adquiridos conjuntamente
 - “Quem compra fralda também compra...” 😊 → E VICE VERSA....

- Análise de comportamento temporal
 - Como antecipar as necessidades de um cliente?
 - Ex: t1: (fralda = sim) -> t2: (berço = sim)

Cerca de 35% da receita da Amazon é gerada por seu mecanismo de recomendação (2024)

- Obs: também pode ser aplicada Classificação!!!!
→ Vamos ver um pouco mais tarde...

Usando regras de associação na prática

“Insights” distintos para o negócio, a partir de uma mesma regra

- $X \rightarrow Y$
- Cenário 1: Fixando o **consequente** (regras do tipo “ $? \rightarrow Y$ ”)
 - Como aumentar as vendas de um determinado produto ou serviço?
 - Ex: como alavancar a contratação de garantia estendida?
 - $X \rightarrow (\text{Garantia estendida} = \text{Sim})$
 - $(\text{setor} = \text{Eletronico}) \rightarrow (\text{Garantia estendida} = \text{Sim})$
 - Como otimizar recursos do meu hospital?
 - Ex: quais características dos pacientes estão mais associadas ao uso de ventiladores na UTI?
 - $X \rightarrow (\text{ventilacao} = \text{Sim})$
 - $(\text{idade} > 50 \text{ and } \text{perdaOlfato} = \text{sim}) \rightarrow (\text{ventilacao} = \text{Sim})$
- Cenário 2: Fixando o **antecedente** (regras do tipo “ $X \rightarrow ?$ ”)
 - Como melhorar a gestão do meu estoque, o layout das minhas lojas?
 - Ex: a que outros produtos a venda de fraldas está associada?
 - $(\text{fralda} = \text{sim}) \rightarrow Y$
 - $(\text{fralda} = \text{sim}) \rightarrow (\text{cerveja} = \text{sim})$

Ok, mas como descobrir associações?

Basket1: bread, butter, jam

Basket2: bread, butter

Basket3: bread, butter, milk

Basket4: beer, bread

Basket5: beer, milk

O que podemos afirmar a partir deste histórico?

Estatísticas simples

“bread” acontece em 80% das vezes

“butter” acontece em 60% das vezes

Algumas relações, ainda simples também...

100% dos carrinhos que têm butter também têm bread

100% dos carrinhos que têm butter e jam também têm bread

100% dos carrinhos que têm jam também têm butter

Regras de associação

Basket1: bread, butter, jam

Basket2: bread, butter

Basket3: bread, butter, milk

Basket4: beer, bread

Basket5: beer, milk

if (butter jam) then bread

if butter then bread

if bread then butter

Como encontrar as regras?

1. Encontrar conjuntos de itens (**itemsets**) que ocorrem juntos

Itemset

<i>TID</i>	<i>Items</i>
1	Bread, Milk
2	Bread, Diaper, Beer, Eggs
3	Milk, Diaper, Beer, Coke
4	Bread, Milk, Diaper, Beer
5	Bread, Milk, Diaper, Coke

Itemset

- conjunto de 0 ou mais itens
 - {Milk, Bread, Diaper}

k-itemset

- itemset com k itens
- dão origem a regras
 - a regra {Milk, Diaper} -> {Beer} tem origem no 3-itemset {Milk, Diaper, Beer}

Encontrando os itemsets

Para $k = 1, 2, \dots$

Todos os k-itemsets!

TID	Items				
1	Bread, Milk				
2	Bread, Diaper, Beer, Eggs				
3	Milk, Diaper, Beer, Coke				
4	Bread, Milk, Diaper	K=1	K=2	K=3	K=4
5	Bread, Milk, Diaper, Beer	{Bread}	{Bread, Milk}	{Bread, Milk, Diaper}	{Bread, Milk, Diaper, Beer}
		{Milk}	{Bread, Diaper}	{Bread, Milk, Beer}	{Bread, Milk, Diaper, Eggs}
		{Diaper}	{Bread, Beer}	{Bread, Milk, Eggs}	{Bread, Milk, Diaper, Coke}
		{Beer}	{Bread, Eggs}	{Bread, Milk, Coke}	{Milk, Diaper, Beer, Eggs}
		{Eggs}	{Bread, Coke}	{Bread, Diaper, Beer}	{Milk, Diaper, Beer, Coke}
		{Coke}	{Milk, Diaper}	{Bread, Diaper, Eggs}	{Diaper, Beer, Eggs, Coke}
			{Milk, Beer}	{Bread, Diaper, Coke}	
			{Milk, Eggs}	{Bread, Beer, Eggs}	K=5
			{Milk, Coke}	{Bread, Beer, Coke}	{Bread, Milk, Diaper, Beer, Eggs}
			{Diaper, Beer}	{Bread, Eggs, Coke}	{Bread, Milk, Diaper, Beer, Coke}
			{Diaper, Eggs}	{Milk, Diaper, Beer}	{Bread, Milk, Diaper, Eggs, Coke}
			{Diaper, Coke}	{Milk, Diaper, Eggs}	{Bread, Milk, Beer, Eggs, Coke}
			{Beer, Eggs}	{Milk, Diaper, Coke}	{Bread, Diaper, Beer, Eggs, Coke}
			{Beer, Coke}	{Diaper, Beer, Eggs}	{Milk, Diaper, Beer, Eggs, Coke}
			{Eggs, Coke}	{Diaper, Beer, Coke}	
				{Diaper, Eggs, Coke}	K=6
				{Beer, Eggs, Coke}	{Bread, Milk, Diaper, Beer, Eggs, Coke}

Regras de associação

Basket1: bread, butter, jam

Basket2: bread, butter

Basket3: bread, butter, milk

Basket4: beer, bread

Basket5: beer, milk

if (butter jam) then bread

if butter then bread

if bread then butter

Como encontrar as regras?

1. Encontrar conjuntos de itens (itemsets) que ocorrem simultaneamente
2. Para cada itemset **frequente**, gerar regras
3. Avalia as regras geradas, eliminando aquelas que não são **“boas”** o suficiente

Regras de associação

Como:

- Determinar se um itemset é “frequente”?
 - quantas vezes ele ocorre no dataset?
 - (quanto maior a frequência com que os itens acontecem, melhor será a regra gerada)
- Determinar se uma regra é “boa”?
 - Proporção de vezes em que o antecedente está associado ao consequente?
 - (quanto maior, melhor a regra)
- Algumas métricas bastante usadas (Pós-processamento)
 - suporte, confiança, lift

Suporte (rSuporte)

- Suporte (absolute):
 - número de ocorrências
 - `sup( )`
- Suporte relativo:
 - frequência relativa de ocorrências
 - `rsup( )`
- Obs.: Na literatura, é comum encontrar a medida de “suporte” referindo-se ao percentual
 - Daqui em diante, não faremos diferença entre `sup` e `rsup`...

Suporte (rSuporte)

Suporte de um itemset

Percentual de transações em que o itemset ocorre

$$\text{sup}(\text{itemset}) = \frac{\text{Número de transações com o itemset}}{\text{Número total de transações}}$$

$$\text{sup}\{\text{bread}\} = 4/5 = 80\%,$$

$$\text{sup}\{\text{beer}\} = 3/5 = 60\%,$$

$$\text{sup}\{\text{bread, beer}\} = 2/5 = 40\%$$

TID	Items
1	Bread, Milk
2	Bread, Diaper, Beer, Eggs
3	Milk, Diaper, Beer, Coke
4	Bread, Milk, Diaper, Beer
5	Bread, Milk, Diaper, Coke

Suporte de uma regra $X \rightarrow Y$

Percentual de transações que contêm o itemset $\{X, Y\}$

$$\text{sup}(\text{bread} \rightarrow \text{beer}) = \text{sup}\{\text{bread, beer}\} = 40\%$$

Confiança

Confiança de uma regra $X \rightarrow Y$

- Número de transações que contêm o itemset $\{X, Y\}$...
- ... dividido pelo número de transações que contêm o itemset $\{X\}$.

TID	Items
1	Bread, Milk
2	Bread, Diaper, Beer, Eggs
3	Milk, Diaper, Beer, Coke
4	Bread, Milk, Diaper, Beer
5	Bread, Milk, Diaper, Coke

$$conf(x \rightarrow y) = \frac{sup(x, y)}{sup(x)}$$

- “O quanto acreditamos que esta regra seja verdadeira”
 - beer $\rightarrow$ bread é verdadeira em 67% dos carrinhos que contêm beer
 - bread $\rightarrow$ beer é verdadeira em 50% dos carrinhos que contêm bread

Lift

Lift de uma regra $X \rightarrow Y$

- Razão da probabilidade conjunta observada de X e Y...
- ... pela probabilidade conjunta esperada, caso eles fossem estatisticamente independentes

$$\text{lift}(x \rightarrow y) = \frac{P(XY)}{P(X)P(Y)} = \frac{\text{conf}(x \rightarrow y)}{\text{sup}(y)}$$

<i>TID</i>	<i>Items</i>
1	Bread, Milk
2	Bread, Diaper, Beer, Eggs
3	Milk, Diaper, Beer, Coke
4	Bread, Milk, Diaper, Beer
5	Bread, Milk, Diaper, Coke

Lift

$$lift(x \rightarrow y) = \frac{P(XY)}{P(X)P(Y)} = \frac{conf(x \rightarrow y)}{sup(y)}$$

<i>TID</i>	<i>Items</i>
1	Bread, Milk
2	Bread, Diaper, Beer, Eggs
3	Milk, Diaper, Beer, Coke
4	Bread, Milk, Diaper, Beer
5	Bread, Milk, Diaper, Coke

“O quão mais freqüente Y ocorre quando X está presente”

- $conf(\text{beer} \rightarrow \text{bread}) = 67\%$
- $sup(\text{bread}) = 80\%$

O quanto “beer” contribuiu para a ocorrência de “bread”?

$$lift(\text{beer} \rightarrow \text{bread}) = 67\% / 80\% = 0,83 < 1$$

→ A chance de **bread** ocorrer **DIMINUI** quando **beer** ocorre

Lift

Lift de uma regra $X \rightarrow Y$

- Se $\text{lift} > 1$:
 - X contribui positivamente para Y
- Se $\text{lift} < 1$:
 - X contribui negativamente para Y
- Se $\text{lift} = 1$:
 - X não contribui positivamente nem negativamente para Y (é neutro)


<i>TID</i>	<i>Items</i>
1	Bread, Milk
2	Bread, Diaper, Beer, Eggs
3	Milk, Diaper, Beer, Coke
4	Bread, Milk, Diaper, Beer
5	Bread, Milk, Diaper, Coke

Mineração de regras de associação (ARM)

Algoritmo

- Assume valores (thresholds) mínimos de suporte e confiança
 - minsup, minconf
- Gera todos os itemsets frequentes
 - para $k = 1$ ao número de itens distintos no dataset
 - gera os k-itemsets
 - Elimine os k-itemsets com suporte $< \text{minsup}$
- Gera regras
 - Para cada k-itemset frequente
 - Gere uma regra para cada partição do k-itemset
 - Elimine as regras com confiança $< \text{minconf}$


Melhorando o desempenho do algoritmo



Dado d itens, existem 2^d possíveis itemsets candidatos

Geração de itemsets frequentes

- Abordagem força bruta:
 - Cada itemset no lattice é um candidato a itemset mais frequente
 - Calcula o suporte de cada candidato através da base de dados




- Avalia cada transação e cada item de uma transação considerando cada candidato
- Complexidade é proporcional ao tamanho do dataset * tamanho da lista de candidatos * tamanho máximo do itemset ($N * M * W$)
 - $O(N * M * W)$
 - Muito custoso!

Geração de itemsets frequentes

- Para evitar ter que calcular suporte de todos os k-itemsets candidatos, usa-se uma heurística:
 - *Subconjuntos de itemsets frequentes são frequentes*
 - Ex: se {bread, milk, butter, beer} é frequente então os itemsets a seguir são também frequentes
 - {bread, milk, butter}
 - {bread, butter, beer}
 - {bread, milk, beer}
 - {bread, milk}
 - {bread}
 - ...
 - *Superconjuntos de itemsets não frequentes são não frequentes*
 - Ex: se {bread, milk, butter, beer} é não-frequente, então o itemset a seguir é também não frequente
 - {bread, milk, butter, beer, coke}


Geração de itemsets frequentes



Geração de itemsets frequentes

Exemplo

Suporte mínimo (threshold): 2



Geração de regras

Exemplo

Considere {Milk, Diaper, Beer}
um 3-itemset frequente...

Regras geradas (partições do itemset)

- {Milk,Diaper} $\rightarrow$ {Beer} ($s=0.4$, $c=0.67$)
- {Milk,Beer} $\rightarrow$ {Diaper} ($s=0.4$, $c=1.0$)
- {Diaper,Beer} $\rightarrow$ {Milk} ($s=0.4$, $c=0.67$)
- {Beer} $\rightarrow$ {Milk,Diaper} ($s=0.4$, $c=0.67$)
- {Diaper} $\rightarrow$ {Milk,Beer} ($s=0.4$, $c=0.5$)
- {Milk} $\rightarrow$ {Diaper,Beer} ($s=0.4$, $c=0.5$)

Obs: Regras originadas a partir do mesmo itemset têm suporte idêntico, mas podem ter confiança diferente

Regras resultantes são aquelas com confiança $>$ minconf

<i>TID</i>	<i>Items</i>
1	Bread, Milk
2	Bread, Diaper, Beer, Eggs
3	Milk, Diaper, Beer, Coke
4	Bread, Milk, Diaper, Beer
5	Bread, Milk, Diaper, Coke

Extração de regras

Algoritmo

A extração das regras de associação consiste em dois passos:

1. Geração de conjuntos frequentes: procura-se apenas os conjuntos de itens significativos, geralmente são conjuntos que atingem um suporte mínimo.
2. Geração de regras para os conjuntos: para cada conjunto da etapa anterior são identificadas regras que estão acima de um limite mínimo de confiança.

A geração de conjuntos frequentes pode ser um processo muito demorado dependendo do tamanho da base de dados. Afim solucionar esse problema foram desenvolvidos vários algoritmos para melhorar a eficiência nesta etapa.

A maioria das técnicas de Association Rule Mining (ARM) se baseia nos algoritmos: Apriori e FP Growth

Apriori

O Apriori possui dois passos fundamentais:

1. Junção: geração de conjuntos com k-itens.
2. Poda: os conjuntos que não atingem o suporte mínimo não são considerados conjuntos frequentes, e não passam para próxima iteração.


APLICANDO ARM EM PROBLEMAS DE CLASSIFICAÇÃO

Classificação através de regras de associação

Base de registros pode ser tratada como base de transações

- Atributo = item
- Objeto = transação (conjunto de itens, ou itemset)

Outlook	Temp	Humidity	Windy	Play
Sunny	Hot	High	False	No
Sunny	Hot	High	True	No
Overcast	Hot	High	False	Yes




<i>TID</i>	<i>Items</i>
1	Outlook=Sunny, Temp=hot, Humidity=High, Windy=False, Play=Yes
2	Outlook=Sunny, Temp=hot, Humidity=High, Windy=True, Play=No
3	Outlook=Overcast, Temp=hot, Humidity=High, Windy=False, Play=Yes

Classificação através de regras de associação

Regras de classificação

- ? -> categoria
- Ex: ? -> (Play=Yes)

Outlook	Temp	Humidity	Windy	Play
Sunny	Hot	High	False	No
Sunny	Hot	High	True	No
Overcast	Hot	High	False	Yes



<i>TID</i>	<i>Items</i>
1	Outlook=Sunny, Temp=hot, Humidity=High, Windy=False, Play=Yes
2	Outlook=Sunny, Temp=hot, Humidity=High, Windy=True, Play=No
3	Outlook=Overcast, Temp=hot, Humidity=High, Windy=False, Play=Yes

Classificação através de regras de associação

Exemplo

Outlook	Temp	Humidity	Windy	Play
Sunny	Hot	High	False	No
Sunny	Hot	High	True	No
Overcast	Hot	High	False	Yes
Rainy	Mild	High	False	Yes
Rainy	Cool	Normal	False	Yes
Rainy	Cool	Normal	True	No
Overcast	Cool	Normal	True	Yes

	One-item sets	Two-item sets	Three-item sets	Four-item sets
Sunny	Outlook = Sunny (5)	Outlook = Sunny Temperature = Hot (2)	Outlook = Sunny Temperature = Hot Humidity = High (2)	Outlook = Sunny Temperature = Hot Humidity = High Play = No (2)
Sunny				
Rainy				
Sunny	Temperature = Cool (4)	Outlook = Sunny Humidity = High (3)	Outlook = Sunny Humidity = High Windy = False (2)	Outlook = Rainy Temperature = Mild Windy = False Play = Yes (2)
Overcast				
Overcast				
Rainy	...	...	...	...

Classificação através de regras de associação

Exemplo

Outlook	Temp	Humidity	Windy	Play
Sunny	Hot	High	False	No
Sunny	Hot	High	True	No
Overcast	Hot	High	False	Yes
Rainy	Mild	High	False	Yes
Rainy	Cool	Normal	False	Yes

`humidity = normal, windy = false, play = yes`

• única com confiança 100%

`If humidity = normal and windy = false then play = yes`

4/4

`If humidity = normal and play = yes then windy = false`

4/6

`If windy = false and play = yes then humidity = normal`

4/6

`If humidity = normal then windy = false and play = yes`

4/7

`If windy = false then humidity = normal and play = yes`

4/8

`If play = yes then humidity = normal and windy = false`

4/9

`If - then humidity = normal and windy = false and play = yes`

4/12

• nº de instâncias onde o antecedente é verdadeiro

Classificação através de regras de associação

Exemplo

Regras com suporte > 1 e confiança 100%

	Association rule	Sup.	Conf.
1	Humidity=Normal Windy=False $\Rightarrow$ Play=Yes	4	100%
2	Temperature=Cool $\Rightarrow$ Humidity=Normal	4	100%
3	Outlook=Overcast $\Rightarrow$ Play=Yes	4	100%
4	Temperature=Cold Play=Yes $\Rightarrow$ Humidity=Normal	3	100%
	...	...	...
58	Outlook=Sunny Temperature=Hot $\Rightarrow$ Humidity=High	2	100%

Resumindo:

- 3 regras com suporte 4
- 5 regras com suporte 3
- 50 regras com suporte 2

Exemplos de ARM

KNiME

- <https://hub.knime.com/knime/extensions/org.knime.features.base/latest/org.knime.base.node.mine.subgroupminer.SubgroupMinerFactory2>

Python

- <https://pypi.org/project/efficient-apriori/>

R

- <http://www.rdatamining.com/examples/association-rules>

Temas relacionados

Contrast sets

- SCR-Apriori for Mining ‘Sets of Contrasting Rules’

Treatment Learning

- Data Mining for Very Busy People
- Just enough learning (of association rules): the TAR2 “Treatment” learner

Descoberta de regras descritivas

- Supervised Descriptive Rule Discovery: A Survey of the State-of-the-Art

Leitura complementar

Han 5.1, 5.2

Dunham 6.3

Berry e Browne, capítulo 14

Zhang, capítulos 2,3