

Clustering (Agrupamento)

Alimed Celecia, Álvaro Veiga,
Fernanda Baião, Patrick Happ

Introdução


Dado um conjunto de dados, que conhecimento poderíamos querer extrair?

- *Classificação (aprender a categoria de algum objeto)*
- *Regressão (estimar um valor contínuo de algum atributo para um objeto)*
- *Algo mais?*

<i>Transaction#</i>	<i>Client</i>	<i>ProductBought</i>	<i>Price</i>	<i>Delivery mode</i>	<i>Payment mode</i>
1	John Smith	Computer	1500	Regular	cash
1	John Smith	Monitor	200	Regular	cash
2	Steven	Notebook	2500	...	...
3	Carol Hudson	Computer	2000	Regular	Check
3	Carol Hudson	Monitor	400	Regular	Check
4	Susan Davidson	Monitor	200	Express	Cash
5	John Mayer	Computer	2000	Regular	Check
6	John Mayer	Monitor	400	Regular	Check
7	Carol Hudson	Printer	300	Regular	Check
...					

Agrupamento

- Clustering = processo de “descoberta” de grupos de objetos (clusters)
- Algoritmo de agrupamento deve atribuir cada registro a um *cluster* (grupo), tal que os objetos de um mesmo *cluster* sejam mais similares entre si do que aos registros dos outros *clusters*



O que não é clustering?



Classificação supervisionada

- Tem (e usa) informação sobre uma classe
- Agrupar pacientes com relação ao risco de desenvolver uma doença

Agrupamentos Segundo critérios pré-definidos

- Agrupar indivíduos segundo indicadores sócio-econômicos

Agrupamento



Exemplo de dois agrupamentos em um plano com duas dimensões (X,Y).
Observam-se 3 grupos em a) e 8 grupos em b)


Agrupamento

Dadas as informações sobre os clientes de uma loja, gostaríamos de descobrir quais os perfis de clientes que comprem na loja para construir campanhas publicitárias focadas nesses perfis.

						
idade: 15	idade: 32	idade: 46	idade: 75	idade: 17	idade: 55	idade: 65



Agrupamento

Dadas as informações sobre os clientes de uma loja, gostaríamos de descobrir quais os perfis de clientes que comprem na loja para construir campanhas publicitárias focadas nesses perfis.



Agrupamento

Dadas as informações sobre os clientes de uma loja, gostaríamos de descobrir quais os perfis de clientes que comprem na loja para construir campanhas publicitárias focadas nesses perfis.



Agrupamento

Dadas as informações sobre os clientes de uma loja, gostaríamos de descobrir quais os perfis de clientes que comprem na loja para construir campanhas publicitárias focadas nesses perfis.

						
idade: 15 renda: 500	idade: 32 renda: 8k	idade: 46 renda: 12k	idade: 75 renda: 7k	idade: 17 renda: 800	idade: 55 renda: 13k	idade: 65 renda: 9k

Agrupamento

Dadas as informações sobre os clientes de uma loja, gostaríamos de descobrir quais os perfis de clientes que comprem na loja para construir campanhas publicitárias focadas nesses perfis.

						
idade: 15 renda: 500	idade: 32 renda: 8k	idade: 46 renda: 12k	idade: 75 renda: 7k	idade: 17 renda: 800	idade: 55 renda: 13k	idade: 65 renda: 9k

	
idade: 15 renda: 500	idade: 17 renda: 800

		
idade: 32 renda: 8k	idade: 65 renda: 9k	idade: 75 renda: 7k

	
idade: 46 renda: 12k	idade: 55 renda: 13k

Agrupamento

Dadas as informações sobre os clientes de uma loja, gostaríamos de descobrir quais os perfis de clientes que comprem na loja para construir campanhas publicitárias focadas nesses perfis.


						
idade: 15 renda: 500 compras: 14 sexo: M filhos: 0 ...	idade: 32 renda: 8k compras: 32 sexo: F filhos: 0 ...	idade: 46 renda: 12k compras: 54 sexo: M filhos: 2 ...	idade: 75 renda: 7k compras: 10 sexo: F filhos: 3 ...	idade: 17 renda: 800 compras: 34 sexo: M filhos: 0 ...	idade: 55 renda: 13k compras: 2 sexo: M filhos: 0 ...	idade: 65 renda: 9k compras: 52 sexo: F filhos: 2 ...


Aplicações de clustering

- De forma geral...
 - **Perceber similaridades entre objetos** que não são intuitivas ou previamente conhecidas (não supervisionado, lembra?)
 - Gerar hipóteses, detectar anomalias, identificar características salientes
 - Para **compressão**: como um método para organizar os dados e resumi-los (protótipos)
- Em domínios específicos
 - **Marketing**: Agrupar consumidores considerando hábitos de consumo
 - **Planejamento de cidades**: Agrupar edificações (combinando natureza, valor, localização, características dos moradores, características geológicas, ...)
 - **Análise de documentos**: Agrupar documentos similares
 - **Processamento de imagens**: Agrupar imagens que podem explicar o mesmo fenômeno: diagnóstico médico, detecção de suspeitos), ...
 - **Biologia**: Agrupar plantas/animais com propriedades similares para estudo, estudar relações filogenéticas

Cluster vs Clustering

- Cluster
 - Conjunto de objetos que são
 - Similares (ou relacionados) uns aos outros dentro do mesmo conjunto, e
 - Dissimilares (ou não relacionados) aos objetos dos outros conjuntos
 - resultado do clustering
- Clustering (ou análise de clusters, agrupamento, segmentação de dados, ...)
 - processo de “descoberta” (ou aprendizado) de clusters
 - Técnica (implementada por algoritmos) que
 - Divide um conjunto de objetos em sub-conjuntos que sejam tão similares quanto possível
 - atribui cada objeto a um cluster (grupo), tal que os objetos de um mesmo cluster sejam mais similares entre si do que aos objetos dos outros clusters






Exemplo

Dataset com 3 atributos


- x, y, forma ({quadrado, círculo})




Quantos clusters podem ser identificados?

Exemplo



- Alguns quadrados e círculos misturados no mesmo cluster...





Noção de agrupamento não é absoluta





Quantos clusters?



6 Clusters



2 Clusters




4 Clusters

(Não supervisionado, lembra?)


Qualidade do Agrupamento

Geralmente as medidas (ou índices) de qualidade buscam refletir

- Alta similaridade intra-grupo
- Baixa similaridade inter-grupo



(a) Good



(b) Bad

(veremos quais – e como - mais adiante...)

Como as abordagens de agrupamento se caracterizam?

- Estratégia de agrupamento
 - Partição (ex.: K-means)
 - Hierárquico (ex.: AGNES)
 - Baseado em densidade (ex.: DBSCAN)
 - Baseado em grid (ex.: STING)
 - Baseado em modelo (ex.: EM, GMM)

Como as abordagens de agrupamento se caracterizam?

- Forma de atribuição dos pontos
 - Exclusivo vs Não Exclusivo
 - Exclusivo: cada ponto pertence a um único cluster.
 - Não-exclusivo: pontos podem pertencer a vários clusters (ex.: pontos de fronteira).
 - Fuzzy × Não-fuzzy
 - Fuzzy: pontos têm graus de pertinência entre 0 e 1; similar a clustering probabilístico.
 - Não-fuzzy: atribuição rígida.

Como as abordagens de agrupamento se caracterizam?

- Cobertura do agrupamento
 - Completo: todos os dados são agrupados.
 - Parcial: apenas uma parte dos dados é agrupada; útil para identificar padrões em subconjuntos.
- Tipos de clusters descobertos
 - Bem separados
 - Baseados em centro
 - Contíguos (baseados em conectividade)
 - Baseados em densidade
 - De formas arbitrárias


Clusters bem separados

- cluster = conjunto de pontos tal que qualquer ponto de um cluster é mais próximo (mais similar) a qualquer outro ponto do cluster do que a qualquer ponto em outro cluster



Clusters Baseados em “centros”


- cluster = conjunto de pontos tal que qualquer ponto de um cluster é mais próximo (mais similar) ao “centro” do cluster do que a qualquer centro de outro cluster
 - “centro” do cluster
 - o seu centroide (a média de todos os pontos do cluster), ou
 - o seu medoide (o ponto mais representativo do cluster)



**4 clusters baseados em
centros**

Clusters contíguos


- cluster = conjunto de pontos tal que qualquer ponto de um cluster é mais próximo (mais similar) a um ou mais pontos do cluster do que a qualquer ponto fora do cluster



8 clusters contíguos

Clusters baseados em densidade

- cluster = região densa de pontos, separadas por regiões de baixa densidade de outras regiões de alta densidade
 - Útil quando os clusters são irregulares ou entrelaçados, ou na presença de ruído e de outliers



**6 clusters baseados em
densidade**

Requisitos gerais desejados para abordagens de clustering

- Robustez
 - diferentes tipos de atributo:
 - Numéricos, nominais, intervalo, razão, textos, multimedia, series temporais, streams
 - ruídos e outliers
 - ordem das instâncias de entrada
- Interpretabilidade e usabilidade
 - Dificuldade de visualização de clusters com mais de 3 dimensões
 - Várias iterações de visualização, 1 para cada perspectiva
(como no final do vídeo <https://pt.coursera.org/lecture/process-mining/1-7-cluster-analysis-wbOgW>)
- Escalabilidade
 - Agrupar grandes volume de dados
 - Alta dimensionalidade
 - Muitos datasets (a maioria, na realidade) possuem grande número de atributos, e geram clusters de dimensão muito alta
 - Abordagens mais comuns para tratar alta dimensionalidade
 - Dividir em “subespaços”: encontrar clusters em cada subespaço
 - PCA
 - Amostragem
 - (técnicas de pré-processamento, lembram?)

Exemplo:

Cientes de um restaurante

<new process> - RapidMiner 5.3.015 @ nbwin1027

File Edit Process Tools View Help

Result Overview ExampleSet (/Local Repository/data/food-poisoning-simple)

Data View Meta Data View Plot View Advanced Charts Annotations

ExampleSet (5000 examples, 1 special attribute, 6 regular attributes) View Filter (5000 / 5000): all

Row No.	class	pizza margh.	pizza sicilia.	lasagna	spaghetti c.	vino rosso	birra
1	not sick	0	0	1	2	0	2
2	not sick	0	0	1	2	0	1
3	not sick	1	1	0	0	1	0
4	not sick	2	1	0	0	2	0
5	not sick	1	0	0	0	1	0
6	not sick	0	0	2	0	0	1
7	not sick	0	0	1	1	0	1
8	not sick	2	1	0	0	2	0
9	not sick	0	0	2	0	0	2
10	not sick	1	1	0	0	1	0
11	not sick	0	0	2	2	0	1
12	not sick	0	1	0	0	2	0
13	not sick	1	1	0	0	0	0
14	not sick	1	1	0	0	2	0
15	not sick	0	0	1	1	0	2

only 6 items



Exemplo:

Cientes de um restaurante



RapidMiner 5.3.015 @ nbwin1027

File Edit Process Tools View Help

Result Overview ExampleSet (/Local Repository/data/food-poisoning-simple)

Data View Meta Data View Plot View Advanced Charts Annotations

ExampleSet (5000 examples, 1 special attribute, 6 regular attributes) View Filter (5000 / 5000): all

Row No.	class	pizza margh.	pizza sicilia.	lasagna	spaghetti c.	vino rosso	birra
1	not sick	0	0	1	2	0	2
2	not sick	0	0	1	2	0	1
3	not sick	1	1	0	0	1	0
4	not sick	2	1	0	0	2	0
5	not sick	1	0	0	0	1	0
6	not sick	0	0	2	0	0	1
7	not sick	0	0	1	1	0	1
8	not sick	2	1	0	0	2	0
9	not sick	0	0	2	0	0	2
10	not sick	1	1	0	0	1	0
11	not sick	0	0	2	2	0	1
12	not sick	0	1	0	0	2	0
13	not sick	1	1	0	0	0	0
14	not sick	1	1	0	0	2	0
15	not sick	0	0	1	1	0	2

only 6 items

Results k -means clustering ($k=2$)

- Two clusters:
 - Cluster 0: 2551 instances
 - Cluster 1: 2449 instances
- Centroids

Text View Folder View Graph View **Centroid Table** Centroid Plot View

Attribute	cluster_0	cluster_1
pizza margherita	0.008	1.026
pizza siciliana	0.011	1.028
lasagna	0.987	0.011
spaghetti carbonara	0.984	0.008
vino rosso	0.011	1.046
birra	0.995	0.007

Exemplo:

Cientes de um restaurante



RapidMiner 5.3.015 @ nbwin1027

ExampleSet (5000 examples, 1 special attribute, 6 regular attributes)

View Filter (5000 / 5000): all

Row No.	class	pizza margh.	pizza sicilia.	lasagna	spaghetti c.	vino rosso	birra
1	not sick	0	0	1	2	0	2
2	not sick	0	0	1	2	0	1
3	not sick	1	1	0	0	1	0
4	not sick	2	1	0	0	2	0
5	not sick	1	0	0	0	1	0
6	not sick	0	0	2	0	0	1
7	not sick	0	0	1	1	0	1
8	not sick	2	1	0	0	2	0
9	not sick	0	0	2	0	0	2
10	not sick	1	1	0	0	1	0
11	not sick	0	0	2	2	0	1
12	not sick	0	1	0	0	2	0
13	not sick	1	1	0	0	0	0


only 6 items

Results k -means clustering ($k=2$)

- Two clusters:
 - Cluster 0: 2551 instances
 - Cluster 1: 2449 instances
- Centroids

Centroid Table

Attribute	cluster_0	cluster_1
pizza margherita	0.008	1.026
pizza siciliana	0.011	1.028
lasagna	0.987	0.011
spaghetti carbonara	0.984	0.008
vino rosso	0.011	1.046
birra	0.995	0.007



Encontrando clusters...

Ideia geral

- Métrica de (dis)similaridade
 - Similaridade é expressa como uma função de distância $d(i, j)$ = distância entre os objetos i e j
 - Cada objeto é um ponto em um espaço multidimensional
- Funções de distância
 - Específicas dependendo do tipo do dado
 - Categórico (nominal, ordinal, booleano), Intervalo, razão

$$\begin{bmatrix} 0 & & & & \\ d(2,1) & 0 & & & \\ d(3,1) & d(3,2) & 0 & & \\ : & : & : & & \\ d(n,1) & d(n,2) & \dots & \dots & 0 \end{bmatrix}$$

Matriz de dissimilaridade

Variáveis de Intervalo

(Dis)Similaridade entre objetos

Ex: salário, idade (absoluta), dosagem prescrita do medicamento...

(dis)Similaridade calculada pela distância entre os objetos

Importante padronizar os dados no pré-processamento

(Lembrando)

- Distâncias são normalmente utilizadas para medir a (dis)similaridade
- Algumas medidas de distância populares incluem a distância de *Minkowski*

$$d(i, j) = \sqrt[q]{(|x_{i1} - x_{j1}|^q + |x_{i2} - x_{j2}|^q + \dots + |x_{ip} - x_{jp}|^q)}$$

- Onde
 - $i = (x_{i1}, x_{i2}, \dots, x_{ip})$ e $j = (x_{j1}, x_{j2}, \dots, x_{jp})$ são pontos em um espaço p – dimensional
 - q é inteiro positivo

Variáveis de Intervalo

(Dis)Similaridade entre objetos

- Distância de Manhattan (= distância de *Minkowski*, $q=1$)

$$d(i,j) = |x_{i1} - x_{j1}| + |x_{i2} - x_{j2}| + \dots + |x_{ip} - x_{jp}|$$

- Distância Euclideana (= distância de *Minkowski*, $q=2$)

$$d(i,j) = \sqrt{(|x_{i1} - x_{j1}|^2 + |x_{i2} - x_{j2}|^2 + \dots + |x_{ip} - x_{jp}|^2)}$$

propriedades

- $d(i,j) \geq 0$
- $d(i,i) = 0$
- $d(i,j) = d(j,i)$
- $d(i,j) \geq d(i,k) + d(k,j)$

Outras medidas de distância
também são possíveis

- Distância ponderada, coeficiente de correlação de Pearson

Variáveis não numéricas (Lembrando do KNN)

- Para variáveis não numéricas, precisamos transformá-las de modo a poder comparar os objetos e calcular as distâncias
 - Exatamente como fizemos no caso do KNN, que também se baseava em distância...
- (Lembrando) Convertendo em variáveis numéricas
 - Valores booleanos => converte para 0 ou 1
 - Ex: Fumante: [sim, não] => [1, 0]
 - Valores nominais não-binários
 - Variáveis ordinais
 - Substituir por números com alguma lógica, one-hot encoding, rank...
 - Ex: nível de escolaridade: [EF, EM, G, MSC, PHD]
 - Variáveis nominais: One-hot encoding:
 - Transforma 1 variável com n valores em n variáveis binárias
 - Ex: região: [N, NE, CO, SE, S] => [0,1]

Fumante	Escolaridade	Região
Sim	Fundamental	SE
Não	Graduação	NE
Sim	Médio	N
Não	Mestrado	S
Não	Fundamental	S
Não	Doutorado	NE
Sim	Médio	N



Fumante	Escolaridade	N	NE	CO	SE	S
1	1	0	0	0	1	0
0	3	0	1	0	0	0
1	2	1	0	0	0	0
0	4	0	0	0	0	1
0	1	0	0	0	0	1
0	5	0	1	0	0	0
1	2	1	0	0	0	0

Variáveis binárias

(Dis)Similaridade entre objetos

Ex: ehEstudante, testouPositivo, temPressaoAlta, ...

Se o dataset só tem variáveis binárias, pode-se calcular distâncias usando uma tabela de contingência entre os objetos do dataset

		Object <i>j</i>		
		1	0	<i>sum</i>
Object <i>i</i>	1	<i>a</i>	<i>b</i>	<i>a+b</i>
	0	<i>c</i>	<i>d</i>	<i>c+d</i>
	<i>sum</i>	<i>a+c</i>	<i>b+d</i>	<i>p</i>

Escolhe-se uma métrica e calcula-se a distância

- Coeficiente de matching simples
- invariante, se a variável é simétrica

$$d(i, j) = \frac{b + c}{a + b + c + d}$$

Variáveis ordinais

(Dis)Similaridade entre objetos

Ex: [péssimo, ruim, neutro, bom, ótimo], BI-RADS=[1,2,3,4,5]

Pode-se definir um “ranking” entre os valores da variável...

$$r_{if} \in \{1, \dots, M_f\}$$

... e então tratá-las como variável de intervalo

- Passo 1: Substitua o valor em si da variável pelo “ranking” deste valor
 - Ex: [péssimo, ruim, neutro, bom, ótimo] -> [1,2,3,4,5]
- Passo 2: Mapeie o intervalo de cada variável em [0, 1]
 - Ex: [1,2,3,4,5] -> [0, 0.2, 0.4, 0.6, 0.8, 1]
- Passo 3: Calcule a (dis)similaridade usando os métodos para variável de intervalo

PRINCIPAIS MÉTODOS DE CLUSTERING

Métodos de agrupamento

Mais
comuns

- Cluster por partição
 - Divide os objetos em subconjuntos disjuntos, e avalia segundo algum critério
- Cluster hierárquico
 - Decompõe o conjunto de dados segundo algum critério, e o organiza como uma árvore hierárquica
- Baseado em densidade
 - Utiliza Funções de conectividade e densidade
- Baseado em grid
 - Baseado em uma estrutura de granularidades em múltiplos níveis
- Baseado em modelo
 - Define-se um modelo hipotético para cada cluster e encontra o melhor ajuste aos outros

Algoritmos de Partição

Ideia básica

Método de particionamento

- Construir uma partição do dataset D com n registros em um conjunto de k clusters

Dado um k

- Encontre a partição de k clusters que otimiza o critério de qualidade definido
 - Ótimo global: busca exaustiva de todas as partições
 - Métodos heurísticos: k-means, k-medoids

Algoritmos clássicos

- k-means (MacQueen'67)
 - cada cluster é representado pelo seu centro
- k-medoids ou PAM (Partition around medoids) (Kaufman & Rousseeuw'87)
 - cada cluster é representado por um dos seus objetos

Algoritmo K-means


Algoritmo de agrupamento iterativo

- Itens (instâncias da entrada) são movidos entre clusters até os clusters estabilizarem
- “k” define quantos clusters serão gerados
 - parâmetro de entrada (pré-definido)
- Ponto central (média) de cada cluster serve como referência do cluster
 - Centro de gravidade do cluster
 - para determinar a atribuição de uma instância ao cluster

Exemplo (k=3)

- Atribua cada item ao centroide mais próximo

Definição dos centros de cada grupo




Para sabermos em qual grupo o objeto será atribuído, basta usar uma medida de distância e verificar qual centroide está mais próximo deste objeto.

Por exemplo, seja o objeto que está na posição (3,2 ; 1)

Exemplo (k=3)

Temos:

Definição dos centros de cada grupo



$$x_{obj} = 3.2$$

$$y_{obj} = 1.0$$

$$x_{c1} = 1.5$$

$$y_{c1} = 1.3$$

$$x_{c2} = 4.3$$

$$y_{c2} = 1.7$$

$$x_{c3} = 2.7$$

$$y_{c3} = 3.3$$

$$dist_{c1} = \sqrt{(x_{obj} - x_{c1})^2 + (y_{obj} - y_{c1})^2} \approx 1.73$$


$$dist_{c2} = \sqrt{(x_{obj} - x_{c2})^2 + (y_{obj} - y_{c2})^2} \approx 1.30$$

$$dist_{c3} = \sqrt{(x_{obj} - x_{c3})^2 + (y_{obj} - y_{c3})^2} \approx 2.35$$

Exemplo (k=3)

- Atribua cada item ao centroide mais próximo

Atribuição dos objetos a cada grupo




Para sabermos em qual grupo o objeto será atribuído basta usar uma medida de distância e verificar qual centroide está mais próximo deste objeto. Por exemplo, seja o objeto que está na posição (3,2;1)

Exemplo (k=3)

Temos:

Atribuição dos objetos a cada grupo



$$x_{obj} = 3.2$$

$$y_{obj} = 1.0$$

$$x_{c1} = 1.5$$

$$y_{c1} = 1.3$$

$$x_{c2} = 4.3$$

$$y_{c2} = 1.7$$

$$x_{c3} = 2.7$$

$$y_{c3} = 3.3$$

$$dist_{c1} = \sqrt{(x_{obj} - x_{c1})^2 + (y_{obj} - y_{c1})^2} \approx 1.73$$


$$dist_{c2} = \sqrt{(x_{obj} - x_{c2})^2 + (y_{obj} - y_{c2})^2} \approx 1.30$$

$$dist_{c3} = \sqrt{(x_{obj} - x_{c3})^2 + (y_{obj} - y_{c3})^2} \approx 2.35$$

Exemplo (k=3)


- Recalcule o ponto central de cada cluster (o centro de gravidade)
 - Atribua cada centroide ao ponto central recalculado

Atribuição dos objetos a cada grupo




Legenda

- Grupo 1
- Grupo 2
- Grupo 3



Verificação de atualização do centroide



Exemplo (k=3)

- Calcule o ponto central de cada cluster (o centro de gravidade)
 - Após a atribuição, o centroide é recalculado com base nos objetos do grupo (Figura).
 - Podemos usar medidas estatísticas, como a média para achar a nova posição do centroide.
 - Se ao menos 1 centroide for alterado, o processo se repete
 - Caso não haja alterações nos centroides, o algoritmo pára.

Algoritmo K-means

K-means(k , D)

// k é o número de clusters, D é a base de dados de itens

Selecione k pontos aleatórios como centros

Repita

 Atribua cada item ao centro mais próximo

 Calcule o ponto central de cada cluster // o centro de gravidade

Até que não haja mais alteração nos centros // convergência dos clusters

Analizando o K-Means

Vantagem

- Eficiência (relativa)
 - $O(tkn)$, onde
 - n = # objetos
 - k = # clusters
 - t = # iterações
 - (normalmente, $k, t \ll n$)

Observações


- Comparando eficiência
 - PAM: $O(k(n-k)^2)$, CLARA: $O(k^2 + k(n-k))$
- Geralmente termina em um ótimo local

Desvantagens

- Aplicável apenas em cenários onde a média (mean) é definida
 - Variáveis categóricas?
- Precisa pré-definir k
- Sensível a ruídos e outliers
- Não é capaz de encontrar clusters com formas não convexas

Como definir a quantidade de clusters?


Método do cotovelo



O número ideal de grupos se dá quando o ponto forma uma curva semelhante de um cotovelo, que é o ponto considerado ideal. Pois os pontos acima do cotovelo estão em uma região de *underfitting* e abaixo dele em *overfitting*.

Como definir a quantidade de clusters?

Método de Silhueta



O método de Silhueta determina o quão bem cada objeto está alocado em um grupo, ou seja, a homogeneidade de um grupo.

O índice de Silhueta varia de -1 a 1. Valores próximos a 1 indicam que o objeto possui semelhança com objetos de seu grupo e dissimilaridade com objetos de outros grupos.

Discutiremos essa métrica com mais profundidade mais adiante...

Variações do K-Means


Algumas variantes do k-means se diferem em:

- Seleção dos k iniciais
- Cálculo da (dis)similaridade
- Estratégias para calcular as médias dos clusters


Tratamento de dados categóricos (k-modes, Huang'98)

- Substitui as médias dos clusters pelas modas
- Usa medidas de (dis)similaridade adequadas para objetos categóricos
- Método baseado em frequência para atualizar as modas dos clusters
- k-prototype
 - Combina variáveis categóricas e numéricas em um único algoritmo.
 - Integra a lógica do k-means e k-modes para lidar com bases de dados mistas.



Importância da escolha dos centroides iniciais...



Assign
points to
clusters



Recompute
cluster
centers



Abordagens para o problema dos centróides iniciais

Execuções múltiplas...

- Ajuda, mas não muito (a probabilidade não está a nosso favor...)

Determina centroides iniciais usando amostragem + clustering hierárquico

Inicia com mais do que k centroides iniciais e seleciona entre eles

- Os mais distantes entre si

”Pós-processamento”


- Pós-pós-processamento (i.e., depois da construção dos clusters)
- Inicializa os centroides aleatoriamente ou usando outros métodos

K-Medoids


k-means é muito sensível a outliers...

K-Medoids

- Ao invés de considerar o valor médio dos objetos de um cluster como ponto de referência, considera o medoide:
 - O objeto mais central do cluster
 - O medoide é o objeto real do cluster cuja soma das distâncias para todos os outros objetos do mesmo cluster é mínima.




PAM: A Typical K-Medoids Algorithm




$K = 2$


Arbitrary
choose
 K object
as initial
medoids




Assign
each
remaining
object to
nearest
medoids



Randomly select a non-
medoid object, O_{random}



Compute
total cost of
swapping



Swapping O
and O_{random}
If quality is
improved

Select initial K medoids randomly

Repeat


Object re-assignment

Swap medoid m with o_i if it
improves the clustering quality


Until convergence criterion is satisfied

Limitações do K-means/K-medoids

Densidades diferentes




Original Points




K-means (3 Clusters)

Limitações do K-means/K-medoids

Formas não globulares



Original Points



K-means (2 Clusters)

Algoritmos Hierárquicos





Ideia básica

- Usa matriz de distância como critério de clustering
- Não requer o número de clusters (k) como entrada, mas sim uma condição de término


Abordagens

- Aglomerativas (bottom-up)
 - AGNES (do inglês, *Agglomerative Nesting*)
- Divisivas (top-down)
 - DIANA (do inglês, *Divide Analysis*)

Hierárquico




Algoritmos Hierárquicos



Exemplo do processo de criação de grupos baseado nas técnicas de agrupamento hierárquicas.

Algoritmos Hierárquicos

Dendrograma




Distância entre agrupamentos

- Diferentes medidas de similaridade entre os agrupamentos
 - Single link (nearest neighbor)
 - Complete link (diameter)
 - Average link (group average)
 - Centroid link (centroid similarity)


Distância entre agrupamentos

- **Single link** (nearest neighbor)



- A distância entre dois agrupamentos é a semelhança entre seus membros mais semelhantes (vizinhos mais próximos)
- Baseado em similaridade local: enfatizando mais em regiões próximas, ignorando a estrutura geral do cluster
- Capaz de agrupar grupos de objetos em forma não elíptica
- Sensível a ruídos e outliers

- **Complete link** (diameter)




- A distância entre dois agrupamentos é a semelhança entre seus membros mais diferentes
- Mescle dois clusters para formar um com o menor diâmetro
- Comportamento não-local, obtendo aglomerados compactos
- Sensível a ruído e outliers

Distância entre agrupamentos


- Average link

- A distância média entre um elemento em um cluster e um elemento no outro (ou seja, todos os pares em dois clusters)
 - Computacionalmente custoso



- Centroid link

- A distância entre os centroides de dois clusters






- Group Averaged Agglomerative Clustering (GAAC)


- Let two clusters C_a and C_b be merged into $C_a \cup C_b$
- The new centroid is $c_{a \cup b} = \frac{N_a c_a + N_b c_b}{N_a + N_b}$, where N_a and c_a are the cardinality and centroid of cluster C_a , respectively
- The similarity measure for GAAC is the average of their distances

AGNES (Agglomerative Nesting)


- Introduzido por Kaufmann and Rousseeuw (1990)
- Usa método Single-Link e matriz de dissimilaridade
- Junta nós com menor dissimilaridade
- No final, todos os nós pertencem ao mesmo cluster



Algoritmos Hierárquicos




Cálculo da distância euclidiana do objeto A entre todos os objetos




Repare que é necessário calcular as distâncias entre os outros objetos: B→C, B→E, B→F, B→D, C→D, C→E, C→F, D→E, D→F e E→F.

Algoritmos Hierárquicos




Dendrograma



Algoritmos Hierárquicos


A)

Junção dos grupos por meio da **Ligação Completa**




B)

Junção dos grupos por meio da **Ligação Única**





C)

Junção dos grupos por meio da **Média**




Algoritmos Hierárquicos

Junção dos grupos por meio da **Ligação Completa**




Dendrograma




Algoritmos Hierárquicos

Junção dos grupos por meio da **Ligação Completa**



Dendrograma




Algoritmos Hierárquicos


Método	Vantagens	Desvantagens
Ligação única	Consegue lidar com formas não elípticas	Sensível a ruídos e outliers
Ligação Completa	Consegue lidar melhor com ruídos e outliers	Tende a quebrar grandes grupos; Possui viés para agrupamentos com dados circulares.
Distância baseada em média	Consegue lidar melhor com ruídos e outliers	Possui viés para agrupamentos com dados circulares.

Como visualizar os grupos no dendrograma?


Dendrograma de grupos (k = 2)




Dendrograma de grupos (k = 3)



Dendrograma de grupos (k = 5)



Dendrograma de grupos (k = 7)




DIANA (Divisive Analysis)

Introduzido por Kaufmann and Rousseeuw (1990)

Ordem inversa do AGNES...

No final, cada nó forma um cluster



Clustering Hierárquico

Limitações e extensões

Maior desvantagem é que eles em geral não escalam tão bem


- No mínimo $O(n^2)$, $n = \#$ total de objetos

Vários algoritmos integrando abordagem hierárquica com baseada em distância

- BIRCH (1996)
 - CF-tree, ajuste incremental da qualidade dos sub-clusters
- CURE (1998):
 - Seleciona pontos espalhados do cluster e o compacta na direção do centro, segundo fração definida
- CHAMELEON (1999)
 - Modelagem dinâmica

Desvantagem dos métodos baseados em distância

- Quando a conformação dos objetos no espaço não segue distribuição globular, com formas complexas de clusters (vide a)...
- ...os métodos de clustering baseados em distância tendem a encontrar clusters que não refletem adequadamente esta distribuição (vide b).
 - Consideram apenas um objeto como sendo o mais representativo do cluster
- Desta forma, outros métodos de clustering foram propostos, de forma a representar a distribuição de modo mais fidedigno (vide c)



Clustering baseado em densidade

Usa critério local

- Como pontos conectados por regiões densas

Vantagens

- Descobre clusters de formas arbitrárias
- Lidam bem com ruído
- Escaláveis (One scan)
- Precisam de parâmetros de densidade como condição de término

Algumas propostas

- **DBSCAN**
- OPTICS
- DENCLUE
- CLIQUE


DBSCAN: Density Based Spatial Clustering of Applications with Noise

Conceitos básicos

- Densidade
 - Número de pontos dentro de um raio especificado (Eps)
- Core point
 - Ponto com mais do que um número de pontos especificado (MinPts) dentro do Eps
 - Pontos dentro do cluster
- Border point
 - Pontos com menos do que MinPts dentro do Eps, mas na vizinhança de um core point
- Noise point
 - Ponto que não é nem core point e nem border point.
 - “Outlier”


DBSCAN: Density Based Spatial Clustering of Applications with Noise

Cluster é definido como um conjunto maximal de pontos conectados por densidade (“density-connected”)




DBSCAN: Density Based Spatial Clustering of Applications with Noise


Density-reachable



Density-connected




DBSCAN: Core, Border, and Noise Points



DBSCAN: Core, Border and Noise Points



Dataset original



Core points,
border points,
noise points

Eps = 10, MinPts = 4


Quando DBSCAN funciona bem...

Robusto a ruídos e outliers

Lida com clusters de diferentes formas e tamanhos




Dataset original




Clusters resultantes

Quando DBSCAN **não** funciona bem...


- densidades variadas
- dados com alta dimensionalidade



Dataset original



(MinPts=4, Eps=9.75).



(MinPts=4, Eps=9.92)

Clustering baseado em modelos

- Abordagem estatística
- Assume-se que os dados (multivariados) foram gerados a partir de uma combinação finita de modelos componentes
- Cada modelo componente corresponde a uma distribuição de probabilidade, geralmente paramétrica e multivariada.
- Exemplo
 - **GMM (Gaussian mixture model) multivariado**
 - Cada componente é uma distribuição Gaussiana multivariada
- Assume-se que os dados gerados pelo mesmo modelo fazem parte de um mesmo cluster
- A tarefa central do aprendizado é determinar qual componente gerou cada observação, definindo assim a associação de cada ponto ao seu cluster.
- <https://scikit-learn.org/stable/modules/mixture.html>

Self-organizing feature maps (SOMs)

Abordagem competitiva

Várias unidades competindo pelo objeto corrente

- A unidade cujo vetor de pesos for mais próximo, ganha
- O vencedor e seus vizinhos aprendem, ajustando os pesos
- Inspiração no cérebro humano

Considerações sobre Clustering em geral

Muito progresso quanto à escalabilidade

- Partição: k-means, k-medoids, k-modes
- Hierárquicos: DIANA, AGNES
- Baseados em densidade: DBSCAN

Ainda muitas limitações

- Nem todos os requisitos são completamente atendidos adequadamente


Resumo

Resumo

- Clustering de Partição
 - Divide os dados em grupos distintos (não sobrepostos), onde cada objeto pertence a exatamente um grupo.
- Como funciona:
 - Define-se um número k de clusters desejados
 - Organiza os objetos em k grupos distintos
 - Avalia a qualidade dos agrupamentos usando métricas como distância entre pontos


K-means

1 - Escolha k pontos aleatórios para serem os centróides dos clusters



K-means

- 1 - Escolha k pontos aleatórios para serem os centróides dos clusters
- 2 - Crie k clusters, associando cada ponto ao centróide do cluster **mais próximo**




K-means

- 1 - Escolha k pontos aleatórios para serem os centróides dos clusters
- 2 - Crie k clusters, associando cada ponto ao centróide do cluster **mais próximo**

Distância euclidiana

$$d(\mathbf{p}, \mathbf{q}) = \sqrt{\sum_{i=1}^n (p_i - q_i)^2}$$




K-means

- 1 - Escolha k pontos aleatórios para serem os centróides dos clusters
- 2 - Crie k clusters, associando cada ponto ao centróide do cluster mais próximo




K-means

- 1 - Escolha k pontos aleatórios para serem os centróides dos clusters
- 2 - Crie k clusters, associando cada ponto ao centróide do cluster mais próximo
- 3 - Calcule o novo centróide de cada cluster como sendo o ponto médio do cluster




K-means

- 1 - Escolha k pontos aleatórios para serem os centróides dos clusters
- 2 - Crie k clusters, associando cada ponto ao centróide do cluster mais próximo
- 3 - Calcule o novo centróide de cada cluster como sendo o ponto médio do cluster
- 4 - Repita os passos 2 e 3




K-means

- 1 - Escolha k pontos aleatórios para serem os centróides dos clusters
- 2 - Crie k clusters, associando cada ponto ao centróide do cluster mais próximo
- 3 - Calcule o novo centróide de cada cluster como sendo o ponto médio do cluster
- 4 - Repita os passos 2 e 3




K-means

- 1 - Escolha k pontos aleatórios para serem os centróides dos clusters
- 2 - Crie k clusters, associando cada ponto ao centróide do cluster mais próximo
- 3 - Calcule o novo centróide de cada cluster como sendo o ponto médio do cluster
- 4 - Repita os passos 2 e 3 por N iterações ou até não ver mais mudanças no centróide




K-medoids

1 - Escolha k pontos aleatórios para serem os medóides (nome de um centróide no k-medoids) dos clusters




K-medoids

- 1 - Escolha k pontos aleatórios para serem os medóides (nome de um centróide no k-medoids) dos clusters
- 2 - Crie k clusters, associando cada ponto ao medóide do cluster mais próximo




K-medoids

- 1 - Escolha k pontos aleatórios para serem os medóides (nome de um centróide no k-medoids) dos clusters
- 2 - Crie k clusters, associando cada ponto ao medóide do cluster mais próximo
- 3 - Calcule o custo da solução encontrada, dado pela soma total das distâncias entre os pontos e os medóides do clusters a qual eles pertencem




K-medoids

- 1 - Escolha k pontos aleatórios para serem os medóides (nome de um centróide no k-medoids) dos clusters
- 2 - Crie k clusters, associando cada ponto ao medóide do cluster mais próximo
- 3 - Calcule o custo da solução encontrada, dado pela soma total das distâncias entre os pontos e os medóides do clusters a qual eles pertencem
- 4 - Para cada cluster formado, troque um dos medóides por um ponto não-medóide e re-execute o passo 2 e 3




K-medoids

- 1 - Escolha k pontos aleatórios para serem os medóides (nome de um centróide no k-medoids) dos clusters
- 2 - Crie k clusters, associando cada ponto ao medóide do cluster mais próximo
- 3 - Calcule o custo da solução encontrada, dado pela soma total das distâncias entre os pontos e os medóides do clusters a qual eles pertencem
- 4 - Para cada cluster formado, troque um dos medóides por um ponto não-medóide e re-execute o passo 2 e 3
- 5 - Reverta a troca se o custo da nova solução for maior que a antiga




VS




K-medoids

- 1 - Escolha k pontos aleatórios para serem os medóides (nome de um centróide no k-medoids) dos clusters
- 2 - Crie k clusters, associando cada ponto ao medóide do cluster mais próximo
- 3 - Calcule o custo da solução encontrada, dado pela soma total das distâncias entre os pontos e os medóides do clusters a qual eles pertencem
- 4 - Para cada cluster formado, troque um dos medóides por um ponto não-medóide e re-execute o passo 2 e 3
- 5 - Reverta a troca se o custo da nova solução for maior que a antiga



K-medoids

- 1 - Escolha k pontos aleatórios para serem os medóides (nome de um centróide no k-medoids) dos clusters
- 2 - Crie k clusters, associando cada ponto ao medóide do cluster mais próximo
- 3 - Calcule o custo da solução encontrada, dado pela soma total das distâncias entre os pontos e os medóides do clusters a qual eles pertencem
- 4 - Para cada cluster formado, troque um dos medóides por um ponto não-medóide e re-execute o passo 2 e 3
- 5 - Reverta a troca se o custo da nova solução for maior que a antiga
- 6 - Repita os passos 4 e 5 por N iterações ou até não ver mais mudanças nos medóides



Resumo

- **Clustering Hierárquico**
 - Cria uma hierarquia de clusters, organizados em formato de árvore (dendrograma).
- **Como funciona:**
 - Não precisa definir número de clusters antecipadamente
 - Constrói uma estrutura em árvore que mostra relações entre clusters
 - Pode ser aglomerativo (de baixo para cima) ou divisivo (de cima para baixo)

Abordagem hierárquica

Método aglomerativo: cada ponto de dados começa como seu próprio cluster, e pares de clusters são fundidos à medida que se sobe na hierarquia.



1 - Associe cada ponto nos dados a um cluster (tendo N pontos você terá N clusters)



Abordagem hierárquica

Método aglomerativo: cada ponto de dados começa como seu próprio cluster, e pares de clusters são fundidos à medida que se sobe na hierarquia.



- 1 - Associe cada ponto nos dados a um cluster (tendo N pontos você terá N clusters)
- 2 - Encontre o par de clusters mais similares e junte-os em um único clusters



Abordagem hierárquica

Método aglomerativo: cada ponto de dados começa como seu próprio cluster, e pares de clusters são fundidos à medida que se sobe na hierarquia.



- 1 - Associe cada ponto nos dados a um cluster (tendo N pontos você terá N clusters)
- 2 - Encontre o par de clusters mais similares e junte-os em um único clusters



Abordagem hierárquica

Método aglomerativo: cada ponto de dados começa como seu próprio cluster, e pares de clusters são fundidos à medida que se sobe na hierarquia.



- 1 - Associe cada ponto nos dados a um cluster (tendo N pontos você terá N clusters)
- 2 - Encontre o par de clusters mais similares e junte-os em um único clusters



Abordagem hierárquica

Método aglomerativo: cada ponto de dados começa como seu próprio cluster, e pares de clusters são fundidos à medida que se sobe na hierarquia.



- 1 - Associe cada ponto nos dados a um cluster (tendo N pontos você terá N clusters)
- 2 - Encontre o par de clusters mais similares e junte-os em um único clusters



Abordagem hierárquica


Método aglomerativo: cada ponto de dados começa como seu próprio cluster, e pares de clusters são fundidos à medida que se sobe na hierarquia.

- 1 - Associe cada ponto nos dados a um cluster (tendo N pontos você terá N clusters)
- 2 - Encontre o par de clusters mais similares e junte-os em um único clusters




Abordagem hierárquica


Single-linkage: considera a distância entre os clusters como sendo a distância entre os membros mais próximos entre os clusters




Complete-linkage: considera a distância entre os clusters como sendo a distância entre os membros mais distantes entre os clusters



Average-linkage: considera a distância entre os clusters como sendo a distância média entre um elemento de cluster e um elemento no outro cluster (ou seja, calcula todas as combinações de distâncias entre os clusters e tira a média)





Centroid-linkage: considera a distância entre os clusters como sendo a distância entre os centróides do clusters



Abordagem hierárquica

Método aglomerativo: cada ponto de dados começa como seu próprio cluster, e pares de clusters são fundidos à medida que se sobe na hierarquia.



- 1 - Associe cada ponto nos dados a um cluster (tendo N pontos você terá N clusters)
- 2 - Encontre o par de clusters mais similares e junte-os em um único clusters



Abordagem hierárquica

Método aglomerativo: cada ponto de dados começa como seu próprio cluster, e pares de clusters são fundidos à medida que se sobe na hierarquia.



- 1 - Associe cada ponto nos dados a um cluster (tendo N pontos você terá N clusters)
- 2 - Encontre o par de clusters mais similares e junte-os em um único clusters
- 3 - Repita o passo 2 até não haver mais clusters para serem unidos (todos os dados estão em um único cluster)



Abordagem hierárquica

Método aglomerativo: cada ponto de dados começa como seu próprio cluster, e pares de clusters são fundidos à medida que se sobe na hierarquia.



- 1 - Associe cada ponto nos dados a um cluster (tendo N pontos você terá N clusters)
- 2 - Encontre o par de clusters mais similares e junte-os em um único clusters
- 3 - Repita o passo 2 até não haver mais clusters para serem unidos (todos os dados estão em um único cluster)



Abordagem hierárquica

Método aglomerativo: cada ponto de dados começa como seu próprio cluster, e pares de clusters são fundidos à medida que se sobe na hierarquia.



- 1 - Associe cada ponto nos dados a um cluster (tendo N pontos você terá N clusters)
- 2 - Encontre o par de clusters mais similares e junte-os em um único clusters
- 3 - Repita o passo 2 até não haver mais clusters para serem unidos (todos os dados estão em um único cluster)



Abordagem hierárquica

Método aglomerativo: cada ponto de dados começa como seu próprio cluster, e pares de clusters são fundidos à medida que se sobe na hierarquia.



- 1 - Associe cada ponto nos dados a um cluster (tendo N pontos você terá N clusters)
- 2 - Encontre o par de clusters mais similares e junte-os em um único clusters
- 3 - Repita o passo 2 até não haver mais clusters para serem unidos (todos os dados estão em um único cluster)



Abordagem hierárquica

Método aglomerativo: cada ponto de dados começa como seu próprio cluster, e pares de clusters são fundidos à medida que se sobe na hierarquia.



- 1 - Associe cada ponto nos dados a um cluster (tendo N pontos você terá N clusters)
- 2 - Encontre o par de clusters mais similares e junte-os em um único clusters
- 3 - Repita o passo 2 até não haver mais clusters para serem unidos (todos os dados estão em um único cluster)



Abordagem hierárquica

Método aglomerativo: cada ponto de dados começa como seu próprio cluster, e pares de clusters são fundidos à medida que se sobe na hierarquia.



- 1 - Associe cada ponto nos dados a um cluster (tendo N pontos você terá N clusters)
- 2 - Encontre o par de clusters mais similares e junte-os em um único clusters
- 3 - Repita o passo 2 até não haver mais clusters para serem unidos (todos os dados estão em um único cluster)



Abordagem hierárquica


Método aglomerativo: cada ponto de dados começa como seu próprio cluster, e pares de clusters são fundidos à medida que se sobe na hierarquia.

- 1 - Associe cada ponto nos dados a um cluster (tendo N pontos você terá N clusters)
- 2 - Encontre o par de clusters mais similares e junte-os em um único clusters
- 3 - Repita o passo 2 até não haver mais clusters para serem unidos (todos os dados estão em um único cluster)




Limitações do K-means/K-medoids

Densidades diferentes




Original Points




K-means (3 Clusters)

Limitações do K-means/K-medoids

Formas não globulares



Original Points



K-means (2 Clusters)


Resumo

- **Clustering Baseado em Densidade**
 - Agrupa objetos com base na sua densidade no espaço de dados, identificando regiões densas separadas por regiões de baixa densidade.
- **Como funciona:**
 - Define-se um raio (ϵ) e número mínimo de pontos (MinPts)
 - Identifica pontos em regiões densas (com muitos vizinhos próximos)
 - Pode detectar clusters de formatos irregulares e identificar ruídos

Abordagem baseada em densidade

DBSCAN: Algoritmo de clustering que identifica clusters baseados na densidade de pontos em uma região, agrupando regiões densas conectadas e tratando pontos isolados como ruído.


1 - Identificar cada ponto como um **Core Point** se tiver **MinPts** ou mais pontos dentro de sua vizinhança **Eps**.



Abordagem baseada em densidade

DBSCAN: Algoritmo de clustering que identifica clusters baseados na densidade de pontos em uma região, agrupando regiões densas conectadas e tratando pontos isolados como ruído.


1 - Identificar cada ponto como um **Core Point** se tiver **MinPts** ou mais pontos dentro de sua vizinhança **Eps**.



Abordagem baseada em densidade

DBSCAN: Algoritmo de clustering que identifica clusters baseados na densidade de pontos em uma região, agrupando regiões densas conectadas e tratando pontos isolados como ruído.


1 - Identificar cada ponto como um **Core Point** se tiver **MinPts** ou mais pontos dentro de sua vizinhança **Eps**.



Abordagem baseada em densidade

DBSCAN: Algoritmo de clustering que identifica clusters baseados na densidade de pontos em uma região, agrupando regiões densas conectadas e tratando pontos isolados como ruído.


1 - Identificar cada ponto como um **Core Point** se tiver **MinPts** ou mais pontos dentro de sua vizinhança **Eps**.



Abordagem baseada em densidade

DBSCAN: Algoritmo de clustering que identifica clusters baseados na densidade de pontos em uma região, agrupando regiões densas conectadas e tratando pontos isolados como ruído.


1 - Identificar cada ponto como um **Core Point** se tiver **MinPts** ou mais pontos dentro de sua vizinhança **Eps**.



Abordagem baseada em densidade

DBSCAN: Algoritmo de clustering que identifica clusters baseados na densidade de pontos em uma região, agrupando regiões densas conectadas e tratando pontos isolados como ruído.


1 - Identificar cada ponto como um **Core Point** se tiver **MinPts** ou mais pontos dentro de sua vizinhança **Eps**.



Abordagem baseada em densidade

DBSCAN: Algoritmo de clustering que identifica clusters baseados na densidade de pontos em uma região, agrupando regiões densas conectadas e tratando pontos isolados como ruído.


1 - Identificar cada ponto como um **Core Point** se tiver **MinPts** ou mais pontos dentro de sua vizinhança **Eps**.



Abordagem baseada em densidade

DBSCAN: Algoritmo de clustering que identifica clusters baseados na densidade de pontos em uma região, agrupando regiões densas conectadas e tratando pontos isolados como ruído.


1 - Identificar cada ponto como um **Core Point** se tiver **MinPts** ou mais pontos dentro de sua vizinhança **Eps**.



Abordagem baseada em densidade

DBSCAN: Algoritmo de clustering que identifica clusters baseados na densidade de pontos em uma região, agrupando regiões densas conectadas e tratando pontos isolados como ruído.


1 - Identificar cada ponto como um **Core Point** se tiver **MinPts** ou mais pontos dentro de sua vizinhança **Eps**.



Abordagem baseada em densidade

DBSCAN: Algoritmo de clustering que identifica clusters baseados na densidade de pontos em uma região, agrupando regiões densas conectadas e tratando pontos isolados como ruído.


1 - Identificar cada ponto como um **Core Point** se tiver **MinPts** ou mais pontos dentro de sua vizinhança **Eps**.



Abordagem baseada em densidade

DBSCAN: Algoritmo de clustering que identifica clusters baseados na densidade de pontos em uma região, agrupando regiões densas conectadas e tratando pontos isolados como ruído.


1 - Identificar cada ponto como um **Core Point** se tiver **MinPts** ou mais pontos dentro de sua vizinhança **Eps**.



Abordagem baseada em densidade

DBSCAN: Algoritmo de clustering que identifica clusters baseados na densidade de pontos em uma região, agrupando regiões densas conectadas e tratando pontos isolados como ruído.


1 - Identificar cada ponto como um **Core Point** se tiver **MinPts** ou mais pontos dentro de sua vizinhança **Eps**.



Abordagem baseada em densidade

DBSCAN: Algoritmo de clustering que identifica clusters baseados na densidade de pontos em uma região, agrupando regiões densas conectadas e tratando pontos isolados como ruído.


1 - Identificar cada ponto como um **Core Point** se tiver **MinPts** ou mais pontos dentro de sua vizinhança **Eps**.



Abordagem baseada em densidade

DBSCAN: Algoritmo de clustering que identifica clusters baseados na densidade de pontos em uma região, agrupando regiões densas conectadas e tratando pontos isolados como ruído.


1 - Identificar cada ponto como um **Core Point** se tiver **MinPts** ou mais pontos dentro de sua vizinhança **Eps**.



Abordagem baseada em densidade

DBSCAN: Algoritmo de clustering que identifica clusters baseados na densidade de pontos em uma região, agrupando regiões densas conectadas e tratando pontos isolados como ruído.


1 - Identificar cada ponto como um **Core Point** se tiver **MinPts** ou mais pontos dentro de sua vizinhança **Eps**.



Abordagem baseada em densidade

DBSCAN: Algoritmo de clustering que identifica clusters baseados na densidade de pontos em uma região, agrupando regiões densas conectadas e tratando pontos isolados como ruído.


1 - Identificar cada ponto como um **Core Point** se tiver **MinPts** ou mais pontos dentro de sua vizinhança **Eps**.



Abordagem baseada em densidade

DBSCAN: Algoritmo de clustering que identifica clusters baseados na densidade de pontos em uma região, agrupando regiões densas conectadas e tratando pontos isolados como ruído.


1 - Identificar cada ponto como um **Core Point** se tiver **MinPts** ou mais pontos dentro de sua vizinhança **Eps**.



Abordagem baseada em densidade

DBSCAN: Algoritmo de clustering que identifica clusters baseados na densidade de pontos em uma região, agrupando regiões densas conectadas e tratando pontos isolados como ruído.


1 - Identificar cada ponto como um **Core Point** se tiver **MinPts** ou mais pontos dentro de sua vizinhança **Eps**.



Abordagem baseada em densidade

DBSCAN: Algoritmo de clustering que identifica clusters baseados na densidade de pontos em uma região, agrupando regiões densas conectadas e tratando pontos isolados como ruído.


- 1 - Identificar cada ponto como um **Core Point** se tiver **MinPts** ou mais pontos dentro de sua vizinhança **Eps**.
- 2 - Classificar pontos que estão dentro da vizinhança Eps de um Core Point, mas que têm menos de MinPts como Border Points.



Abordagem baseada em densidade

DBSCAN: Algoritmo de clustering que identifica clusters baseados na densidade de pontos em uma região, agrupando regiões densas conectadas e tratando pontos isolados como ruído.


- 1 - Identificar cada ponto como um **Core Point** se tiver **MinPts** ou mais pontos dentro de sua vizinhança **Eps**.
- 2 - Classificar pontos que estão dentro da vizinhança Eps de um Core Point, mas que têm menos de MinPts como Border Points.



Abordagem baseada em densidade

DBSCAN: Algoritmo de clustering que identifica clusters baseados na densidade de pontos em uma região, agrupando regiões densas conectadas e tratando pontos isolados como ruído.


- 1 - Identificar cada ponto como um **Core Point** se tiver **MinPts** ou mais pontos dentro de sua vizinhança **Eps**.
- 2 - Classificar pontos que estão dentro da vizinhança Eps de um Core Point, mas que têm menos de MinPts como Border Points.



Abordagem baseada em densidade

DBSCAN: Algoritmo de clustering que identifica clusters baseados na densidade de pontos em uma região, agrupando regiões densas conectadas e tratando pontos isolados como ruído.


- 1 - Identificar cada ponto como um **Core Point** se tiver **MinPts** ou mais pontos dentro de sua vizinhança **Eps**.
- 2 - Classificar pontos que estão dentro da vizinhança Eps de um Core Point, mas que têm menos de MinPts como Border Points. Marcar todos os outros pontos como Noise.



Abordagem baseada em densidade

DBSCAN: Algoritmo de clustering que identifica clusters baseados na densidade de pontos em uma região, agrupando regiões densas conectadas e tratando pontos isolados como ruído.


- 1 - Identificar cada ponto como um **Core Point** se tiver **MinPts** ou mais pontos dentro de sua vizinhança **Eps**.
- 2 - Classificar pontos que estão dentro da vizinhança Eps de um Core Point, mas que têm menos de MinPts como Border Points. Marcar todos os outros pontos como Noise.
- 3 - Para cada Core Point não visitado, iniciar um novo cluster, e recursivamente adicionar todos os pontos conectados (diretamente alcançáveis) a esse cluster.
- 4 - Repetir o passo 3 até todos os Core Points serem visitados.



Abordagem baseada em densidade

DBSCAN: Algoritmo de clustering que identifica clusters baseados na densidade de pontos em uma região, agrupando regiões densas conectadas e tratando pontos isolados como ruído.


- 1 - Identificar cada ponto como um **Core Point** se tiver **MinPts** ou mais pontos dentro de sua vizinhança **Eps**.
- 2 - Classificar pontos que estão dentro da vizinhança Eps de um Core Point, mas que têm menos de MinPts como Border Points. Marcar todos os outros pontos como Noise.
- 3 - Para cada Core Point não visitado, iniciar um novo cluster, e recursivamente adicionar todos os pontos conectados (diretamente alcançáveis) a esse cluster.
- 4 - Repetir o passo 3 até todos os Core Points serem visitados.



Abordagem baseada em densidade

DBSCAN: Algoritmo de clustering que identifica clusters baseados na densidade de pontos em uma região, agrupando regiões densas conectadas e tratando pontos isolados como ruído.


- 1 - Identificar cada ponto como um **Core Point** se tiver **MinPts** ou mais pontos dentro de sua vizinhança **Eps**.
- 2 - Classificar pontos que estão dentro da vizinhança Eps de um Core Point, mas que têm menos de MinPts como Border Points. Marcar todos os outros pontos como Noise.
- 3 - Para cada Core Point não visitado, iniciar um novo cluster, e recursivamente adicionar todos os pontos conectados (diretamente alcançáveis) a esse cluster.
- 4 - Repetir o passo 3 até todos os Core Points serem visitados.



Abordagem baseada em densidade

DBSCAN: Algoritmo de clustering que identifica clusters baseados na densidade de pontos em uma região, agrupando regiões densas conectadas e tratando pontos isolados como ruído.


- 1 - Identificar cada ponto como um **Core Point** se tiver **MinPts** ou mais pontos dentro de sua vizinhança **Eps**.
- 2 - Classificar pontos que estão dentro da vizinhança Eps de um Core Point, mas que têm menos de MinPts como Border Points. Marcar todos os outros pontos como Noise.
- 3 - Para cada Core Point não visitado, iniciar um novo cluster, e recursivamente adicionar todos os pontos conectados (diretamente alcançáveis) a esse cluster.
- 4 - Repetir o passo 3 até todos os Core Points serem visitados.



Abordagem baseada em densidade

DBSCAN: Algoritmo de clustering que identifica clusters baseados na densidade de pontos em uma região, agrupando regiões densas conectadas e tratando pontos isolados como ruído.


- 1 - Identificar cada ponto como um **Core Point** se tiver **MinPts** ou mais pontos dentro de sua vizinhança **Eps**.
- 2 - Classificar pontos que estão dentro da vizinhança Eps de um Core Point, mas que têm menos de MinPts como Border Points. Marcar todos os outros pontos como Noise.
- 3 - Para cada Core Point não visitado, iniciar um novo cluster, e recursivamente adicionar todos os pontos conectados (diretamente alcançáveis) a esse cluster.
- 4 - Repetir o passo 3 até todos os Core Points serem visitados.



Abordagem baseada em densidade

DBSCAN: Algoritmo de clustering que identifica clusters baseados na densidade de pontos em uma região, agrupando regiões densas conectadas e tratando pontos isolados como ruído.


- 1 - Identificar cada ponto como um **Core Point** se tiver **MinPts** ou mais pontos dentro de sua vizinhança **Eps**.
- 2 - Classificar pontos que estão dentro da vizinhança Eps de um Core Point, mas que têm menos de MinPts como Border Points. Marcar todos os outros pontos como Noise.
- 3 - Para cada Core Point não visitado, iniciar um novo cluster, e recursivamente adicionar todos os pontos conectados (diretamente alcançáveis) a esse cluster.
- 4 - Repetir o passo 3 até todos os Core Points serem visitados.



Abordagem baseada em densidade

DBSCAN: Algoritmo de clustering que identifica clusters baseados na densidade de pontos em uma região, agrupando regiões densas conectadas e tratando pontos isolados como ruído.


- 1 - Identificar cada ponto como um **Core Point** se tiver **MinPts** ou mais pontos dentro de sua vizinhança **Eps**.
- 2 - Classificar pontos que estão dentro da vizinhança Eps de um Core Point, mas que têm menos de MinPts como Border Points. Marcar todos os outros pontos como Noise.
- 3 - Para cada Core Point não visitado, iniciar um novo cluster, e recursivamente adicionar todos os pontos conectados (diretamente alcançáveis) a esse cluster.
- 4 - Repetir o passo 3 até todos os Core Points serem visitados.



Resumo

Tipos de Clustering


Clustering de Partição



Características:

- Número fixo de clusters (k)
- Clusters convexos
- Centroides representam clusters
- Ex: K-means, PAM


Clustering Hierárquico



Características:

- Estrutura em árvore
- Diferentes níveis de granularidade
- Não precisa especificar k
- Ex: AGNES, DIANA

Clustering por Densidade



Características:

- Baseado em densidade
- Detecta clusters de formato arbitrário
- Identifica ruídos
- Ex: DBSCAN, OPTICS

Métricas de avaliação para Clustering

Qualidade do Agrupamento

- Um bom método de agrupamento produz clusters de alta qualidade, i.e.:
 - Alta similaridade intra-grupo
 - Baixa similaridade inter-grupo

Avaliação do modelo (Lembrando)

Métricas de avaliação

- Dependentes do modelo aprendido...
 - Supervisionadas
 - Validação externa
 - Medidas de Erro
 - Não supervisionadas
 - Validação interna
 - Medidas de interesse

Quais dados podem ser utilizados para avaliar?

- Hold-out
- Validação cruzada

Avaliação do modelo (Lembrando)

Métricas de avaliação

- Dependentes do modelo aprendido...
 - Supervisionadas
 - Validação externa
 - Medidas de Erro
 - **Não supervisionadas**
 - **Validação interna**
 - Medidas de interesse



Clustering

Quais dados podem ser utilizados para avaliar?

- Hold-out
- Validação cruzada

Métricas de validação interna

- Não supervisionada
 - Não precisa da classificação de referência (ground truth)
 - Foco em dimensões de qualidade do modelo
 - similaridade e compactação "intracluster"
 - separação e conectividade "intercluster"
 - Exemplos:
 - Inércia
 - Índice Silhouette
 - BetaCV
 - C-index
 - Corte normalizado (normalized cut)
 - Modularidade
 - Índices Dunn, Davies-Bouldin
 - Estabilidade
 - Histogramas espaciais (PMF)
 - ...


Validação interna

- Inércia (Inertia)
 - Calcula a soma das distâncias quadradas de cada ponto ao seu centroide, agregando os resultados de todos os clusters para fornecer uma medida única de dispersão interna.

$$\text{Inércia} = \sum_{i=1}^k \sum_{x \in C_i} \|x - \mu_i\|^2$$

Onde

- k é o número de clusters,
 - C_i representa o conjunto de pontos no cluster i , e
 - μ_i é o centroide do cluster i .
- Valor positivo
 - Quanto menor, melhor...




Validação interna

- Índice (coeficiente) Silhouette
 - Mede quão semelhante um objeto é ao seu próprio cluster comparado a outros clusters.

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}$$

Onde

- $a(i)$ é a distância média entre uma amostra i e todas as outras no mesmo cluster
- $b(i)$ é a distância média entre uma amostra i e todas as outras no cluster mais próximo.



- O valor varia de -1 a 1, onde um valor alto indica que o objeto está bem ajustado ao seu próprio cluster e mal ajustado aos vizinhos.
 - Quanto maior, melhor...

Validação interna

- Índice Davies-Bouldin (DB index)
 - Mede o quão compactos são os clusters, comparando-os segundo as médias
 - Sejam:
 - $\mu_i = \frac{1}{n_i} \sum_{x_j \in C_i} x_j$ a média do cluster i , $\delta(\mu_i, \mu_j)$ a distância entre μ_i e μ_j
 - $\sigma_{\mu_i} = \sqrt{\frac{\sum_{x_j \in C_i} d(x_j, \mu_i)^2}{n_i}}$ a dispersão (espalhamento) dos pontos ao redor da média do cluster
 - A medida DB para cada par de clusters C_i e C_j :

$$DB_{ij} = \frac{\sigma_{\mu_i} + \sigma_{\mu_j}}{\delta(\mu_i, \mu_j)}$$

- Então

$$DB = \frac{1}{k} \sum_{i=1}^k \max_{j \neq i} \{DB_{ij}\}$$

- Quanto menor, melhor...


Validação interna

- Outras medidas de qualidade
 - Medida BetaCV
 - Razão entre as médias das distâncias intracluster e intercluster
 - Quanto maior, melhor...
 - Corte normalizado (Normalized cut)
 - Razão entre a soma das distâncias de cada ponto de um cluster para todos os pontos fora do cluster, e a soma das distâncias de cada ponto do cluster para todos os pontos do dataset
 - Quanto maior, melhor...
 - C-index
 - Medida que reflete o quanto o agrupamento mantém juntos os pontos que são os mais próximos dentro de cada cluster
 - Entre $[0,1]$. Quanto menor, melhor...
 - Modularidade
 - Medida que reflete o quão modular é o agrupamento, através da noção de densidade de pontos. Agrupamentos com modularidade alta têm alta densidade intra-cluster (conexões densas entre os objetos dentro do mesmo cluster) e alta esparsidade entre-clusters (conexões esparsas entre objetos de clusters diferentes)
 - Quanto maior, melhor...


De volta à noção de experimentação no ciclo de vida de Ciência de Dados

- As métricas de validação são usadas para avaliar os clusters resultantes de cada cenário experimentado
 - Com uma determinada configuração dos parâmetros
 - “hyperparameter tuning”

Iris Data: Good vs. Bad Clustering



(a) Good



(b) Bad

	Lower better				Higher better				
	<i>BetaCV</i>	<i>Cindex</i>	<i>Q</i>	<i>DB</i>	<i>NC</i>	<i>Dunn</i>	<i>SC</i>	Γ	Γ_n
(a) Good	0.24	0.034	-0.23	0.65	2.67	0.08	0.60	8.19	0.92
(b) Bad	0.33	0.08	-0.20	1.11	2.56	0.03	0.55	7.32	0.83


Fonte: slides do livro: Zaki, Meira, DATA MINING AND ANALYSIS. Fundamental concepts and algorithms , Cambridge University Press, 2014

Avaliando cenários

Método do cotovelo

Por exemplo, para definir o número de clusters (k) do algoritmo k-means

Método do cotovelo




O número ideal de grupos se dá quando o ponto forma uma curva semelhante de um cotovelo, que é o ponto considerado ideal. Pois os pontos acima do cotovelo estão em uma região de *underfitting* e abaixo dele em *overfitting*.

Avaliando cenários

Índice Silhouette (Silhueta)

Por exemplo, para definir o número de clusters (k) do algoritmo k-means



(Lembrando...)

O índice Silhouette determina o quão bem cada objeto está alocado em um grupo, ou seja, a homogeneidade de um grupo.

O índice Silhouette varia de -1 a 1.


Valores próximos a 1 indicam que o objeto possui semelhança com objetos de seu grupo e dissimilaridade com objetos de outros grupos.

Exemplos práticos

- SciKit-learn (Python)
 - <https://scikit-learn.org/stable/modules/clustering.html#clustering-performance-evaluation>
 - <https://scikit-learn.org/stable/modules/classes.html#module-sklearn.cluster>
- R
 - <https://cran.r-project.org/web/views/Cluster.html>
 - pacote ClusterCrit , por exemplo
 - <https://cran.r-project.org/web/packages/clValid/vignettes/clValid.pdf>
- KNIME
 - <https://www.knime.com/blog/distance-measures-in-knime>

Resumindo

Comparando alguns algoritmos de clustering...



<https://scikit-learn.org/stable/modules/clustering.html>

Recapitulando...

- A **análise de clusters** agrupa objetos com base em sua **similaridade** e tem amplas aplicações
- Medidas de similaridade dependem do **tipo de dado das features consideradas**
- Algoritmos de clustering podem ser divididos em métodos de **particionamento**, métodos **hierárquicos**, métodos baseados em **densidade**, métodos baseados em **grid**, e métodos baseados em **modelos**
- Análise e detecção de **outliers** são muito úteis para detecção de fraudes, etc. e podem ser realizados através de abordagens estatísticas, baseadas em distância ou baseadas em desvios
- Avaliação de clustering é realizada através de **medidas de avaliação internas**, que medem a qualidade do cluster segundo **dimensões**