


Regressão

Alimed Celecia, Álvaro Veiga,
Fernanda Baião, Patrick Happ

Lembrando...


Ciclo de vida de Ciência de Dados

(Simplificado)



Motivação

Considere um grupo varejista com esta região de negócios:



onde abrir uma
nova filial?

A resposta para esta pergunta pode ser determinada usando como métrica seu ***Faturamento Médio Anual***.

Esta métrica é conhecida nas regiões onde o grupo já tem filiais, mas desconhecida nas regiões onde não tem.

Este é um problema de Regressão

Um problema de Regressão seria estimar estes valores de regiões em potencial para novas filiais.

Para tal, o primeiro passo seria **levantar variáveis** que estão tanto presentes **nos bairros com e sem filiais**, tais como:

1. Renda per capita
2. IDH
3. Número de concorrentes
4. Número de habitantes
5. Preço do ***m²***, etc.


A seguir, separamos nossos dados em dois conjuntos: com e sem faturamento, como ilustra a tabela a seguir:

O que é um problema de Regressão?

	Bairro	Renda/Hab.	...	Preço m^2	Faturamento
COM	A	1500	...	2500	105.000
	H	2400	...	5300	180.000
	:	:	:	:	:
	L	3400	...	2750	150.000
SEM	B	2500	...	1780	NA
	C	1000	...	3500	NA
	D	4300	...	6500	NA
	:	:	:	:	:
	K	7000	...	8900	NA
	M	2800	...	3900	NA

O que é um problema de Regressão?

Com estes dados em mãos, basta elaborarmos um modelo de Regressão para obter os valores estimados para as regiões sem filiais:



Como construir este Modelo de Regressão?

O que é um problema de Regressão?

- A partir do modelo, seleciona-se o bairro com Maior Faturamento Esperado para abrir uma nova filial:

	Bairro	Renda/Hab.	...	Preço m^2	Faturamento
Observado	A	1500	...	2500	105.000
	H	2400	...	5300	180.000
	⋮	⋮	⋮	⋮	⋮
	L	3400	...	2750	150.000
Estimado	B	2500	...	1780	125.000
	C	1000	...	3500	200.000
	D	4300	...	6500	160.000
	⋮	⋮	⋮	⋮	⋮
	K	7000	...	8900	180.000
	M	2800	...	3900	120.000

Regressão *versus* Classificação

- Assim como na Classificação, a Regressão consiste em realizar o aprendizado **supervisionado** a partir de dados históricos

Há duas diferenças entre classificação e regressão:

- Tipo de resultado (saída da regressão):
 - Classificação: variável categórica
 - **Regressão: variável numérica**
 - Obs: Regressão logística é tipo específico de regressão que estima a probabilidade de uma variável binária valer 1
- Medida de qualidade
 - Classificação: **acurácia** (ou precisão, cobertura, sensibilidade, especificidade, TPR, TNR, VPP, VPN, ...)
 - Regressão: usa-se o **erro** de predição
 - Erro = valor observado – valor predito

Métricas de desempenho

- Em problemas de classificação, a variável resposta/target é uma variável categórica.
 - Logo a métrica vai se referir a proporções de acerto/erro.
- Em problemas de regressão, a variável resposta/target é numérica.
 - A métrica de avaliação será uma função do erro de predição (erro = valor observado – valor previsto)

Métricas de desempenho

- Formalmente, sejam:
 - o objeto i ($i = 1, \dots, n$) representado pelas entradas $\langle x_{i1}, \dots, x_{ij} \rangle$ (ou seja, o padrão x_i)
 - y_i a resposta desejada para o objeto i , e
 - $\hat{y}_i$ a resposta predita do algoritmo, obtida a partir do objeto i .
- Assim:
 - $e_i = y_i - \hat{y}_i$ é o erro observado na saída do sistema para o objeto i .
- O processo de treinamento consiste em determinar os parâmetros do modelo que minimizem o erro de predição
- O mais frequente é o ERRO QUADRÁTICO = soma erros ao quadrado

Métricas de desempenho

- Erro absoluto
- Erro absoluto médio (Mean Absolute Error - MAE)
- Erro quadrático
- Erro quadrático médio (Mean squared error - MSE)
- Raiz do erro quadrático médio (Root Mean Squared Error - RMSE)
- Coeficiente de determinação (R^2)

Métricas de desempenho

- Erro Absoluto (Absolute error - AE)

$$AE = (\sum_{i=1}^n |e_i|)$$

- Erro Absoluto Médio (Mean Absolute Error - MAE)

$$MAE = (\sum_{i=1}^n |e_i|)/n$$

- Erro quadrático (Squared error - SE)

$$SE = (\sum_{i=1}^n e_i^2)$$

- Erro quadrático médio (Mean squared error - MSE)

$$MSE = (\sum_{i=1}^n e_i^2)/n$$

Métricas de desempenho

- RMSE (Root Mean Squared Error), ou raiz do erro quadrático médio:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n e_i^2}$$

- R^2 , ou Coeficiente de Determinação:

$$R^2 = 1 - \frac{SSE}{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}$$

Sendo: SSE (*Sum of Squared Errors*), ou Soma dos quadrados dos erros, e $\bar{y}$ a média dos dados observados:

$$SSE = \sum_{j=1}^n e_j^2$$

$$\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$$

No melhor caso, os valores estimados são idênticos aos valores observados o que resulta em $SSE = 0$ e $R^2 = 1$.

Um modelo de regressão que sempre estima a média ($\bar{y}$) terá $R^2 = 0$.

Modelos que façam estimativas piores que a média terão R^2 negativo

Ou seja: Quanto mais próximo de 1 é o R^2 ,
melhor o ajuste (fit) do modelo de Regressão aos dados.

Exemplos práticos

- SciKit-learn (Python)
 - https://scikit-learn.org/stable/modules/generated/sklearn.metrics.mean_absolute_error.html
 - https://scikit-learn.org/stable/modules/generated/sklearn.metrics.mean_squared_error.html?highlight=mean%20squared%20error#sklearn.metrics.mean_squared_error

Modelos de regressão

Algoritmos

Algoritmos de aprendizado de modelos de regressão

- KNN
- Árvores de regressão
- Métodos de *ensemble*
 - Bagging
 - Florestas aleatórias
- Regressão linear
- Regressão logística


KNN – k vizinhos mais próximos

- O KNN também pode ser usado para problemas de Regressão
- Neste caso, o valor estimado é uma medida estatística, geralmente **a média aritmética**, dos valores da variável dependente/target correspondente aos dos k-vizinhos mais próximos

*As perguntas sobre qual o **valor de k adequado** e qual **métrica de distância** usar também são aplicáveis aqui...*


KNN

- 5-NN



KNN


- 5-NN
 - Agora, a predição seria a média dos valores da variável target/dependente dos 5 vizinhos mais próximos....



Árvores de Regressão

- Árvores de decisão também podem ser usadas para problemas de Regressão
- Neste caso, a predição é baseada em uma medida estatística, geralmente a média, dos valores da variável dependente em cada folha.

Construção da árvore



Quantificando o erro em árvores de regressão

- Erro quadrático

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2$$


N é o número total de observações (tuplas, objetos) na folha

x_i são os valores individuais de cada observação, e

μ é a média da população que será usada como valor previsto para a folha

Quantificando a homogeneidade em árvores de regressão

1. Calcula-se a média da variância das partições determinadas por cada variável explicativa (co-variável)
2. Seleciona-se a variável explicativa com o menor valor



Árvores de regressão

Exemplo de uso


Dadas as informações de interação em uma propaganda de um produto, quero treinar um modelo que **preveja quanto uma pessoa vai gastar na minha loja**

viu o anúncio	acessou o link	idade	gastou
sim	sim	38	33.50
sim	não	50	24.10
não	não	83	24.20
sim	sim	7	8.90
sim	não	12	5.20
não	sim	18	10.20
não	sim	35	16.55

TREINAMENTO


INFERÊNCIA

viu o anúncio	acessou o link	idade	vai gastar
sim	sim	20	10.21




Árvores de regressão


- De forma geral, uma árvore vai dividir o espaço de n covariáveis em “partições” (ou grids n -dimensionais):



Árvores de regressão



Árvore de regressão



Superfície de previsão

Vantagens da árvore de regressão

- Fácil interpretação e visualização
 - Combinações de intervalos aplicados aos atributos
- Representa naturalmente efeitos de interação entre atributos
 - Regras do tipo: If ($X_1 < 3$ and $X_2 > 4$) then
 - Em uma regressão linear, seria necessário criar uma nova variável $W = X_1 * X_2$
- Fácil incluir variáveis categóricas

Árvores de regressão

- Ideia: dividir o espaço dos atributos em uma partição $R_1, \dots, R_j$
- Se $x \in R_k$ ($1 \leq k \leq j$), o valor predito para x é dado por:

$$g(x) = \hat{y} = \frac{1}{|\{i: x_i \in R_k\}|} \sum_{i: x_i \in R_k} y_i \quad ,$$

O maior desafio é encontrar qual a melhor partição

Queremos minimizar o erro mas sem *overfitting*.

Como determinar as regiões $R_1, \dots, R_j$?

Algoritmo

1. Cria uma árvore “grande”
2. Poda a árvore

Etapa 1:

Medida de qualidade de ajuste de uma árvore T :

$$MSE(T) = \sum_R \sum_{i; x_i \in R} \frac{(y_i - \hat{y}_R)^2}{n_R}$$

$\hat{y}_R$: valor predito para uma observação pertencente à região R .

Objetivo é minimizar $MSE(T)$


... Mas sem overfitting

Como determinar as regiões $R_1, \dots, R_j$?

Etapa 1: Divisões binárias recursivas

Prossegue até criar uma árvore que minimize o MSE dentro do conjunto de dados de treinamento fixando a profundidade máxima da árvore.

Problema?



Como determinar as regiões $R_1, \dots, R_j$?

Etapa 2: Poda

Retira cada nó folha da árvore, um por vez.

Avalia como varia o erro estimado (RMSE, por exemplo) no conjunto de dados de validação

se o erro diminui

retira o nó da árvore e segue com a poda neste ramo

senão

mantém o nó na árvore

prossegue para a poda em outro ramo da árvore

Ensemble,
Bagging/Boosting,
Florestas aleatórias
(para regressão)

Previsão por 'ensemble'

Motivação...

Ajuste vários modelos diferentes de previsão e faça a média das previsões.

Esta será a previsão de 'ensemble'

Previsão por 'ensemble'

Motivação...

Imagine que temos duas funções de predição para Y , $g_1(x)$ e $g_2(x)$

Previsão por 'ensemble

- Se $g_1(x)$ e $g_2(x)$ são:
 - i. Não correlacionados
 - ii. Não viesados

$$g(x) = \frac{g_1(x) + g_2(x)}{2}$$

Assim, **é melhor combinar as previsões!**

Bagging e previsão por ensemble

- Selecione B sub-amostras dos dados de treinamento por amostragem aleatória com reposição
- Para cada sub-amostra ajuste um modelo com função previsão $g_i(x), i = 1, \dots, B$
- Calcule a previsão final como a média das previsões

$$g(x) = \frac{g_1(x) + \dots + g_B(x)}{B}$$

Se os $g_i(x)$'s forem fracamente relacionados, MELHOR
Isso vai fazer a variância do erro diminuir.

Florestas aleatórias

- Random Forests (Breiman 2001)
- Usa Bagging para criar B árvores pouco profundas (weak learner)
- Adicionalmente, para cada árvore, sorteia um subconjunto de variáveis
 - Com isso, busca diminuir a correlação entre os diferentes $g_i(x)$'s.

Regressão Linear

Exemplos de uso de análise de regressão

- **Previsão de vendas**

- Uma empresa de varejo pode analisar o histórico de vendas, considerando fatores como gastos com publicidade, sazonalidade e indicadores econômicos. Ao criar um modelo de regressão, eles podem prever vendas futuras, alocar recursos de forma eficaz e planejar os níveis de estoque.

- **Otimização de preços (estratégias de precificação)**

- Como as alterações nas variáveis de preços (por exemplo, custo do produto, preços dos concorrentes, descontos) afetam as vendas e a receita?

- **Análise do Comportamento do Cliente**

- Uma empresa de comércio eletrônico pode analisar como o design do site, as avaliações de produtos e os tempos de envio afetam as taxas de conversão (percentual de clientes que compraram, dentre os que entraram no site).

- **Análise da eficácia de campanhas de marketing**

- Quais canais ou estratégias de marketing fornecem o maior retorno sobre o investimento (ROI), considerando dados sobre gastos com publicidade, engajamento em mídias sociais e tráfego no site?

- **Estimativa de Indicadores de Qualidade**

- Considerando variáveis do processo de produção, como temperatura, pressão, tempo de processamento, uma indústria pode usar regressão para estimar o valor de uma variável-chave de qualidade (por exemplo, dureza, viscosidade ou teor de um componente)..

Regressão Linear

Formalmente,

Regressão **modela** a relação entre a variável de resposta (Y) e as variáveis preditoras ou explicativas (X).

Explicativas (X)			Resposta (Y)
x_{11}	...	x_{1j}	y_1
x_{21}	...	x_{2j}	y_2
$\vdots$	$\vdots$	$\vdots$	$\vdots$
x_{i1}	...	x_{ij}	y_i
$\vdots$	...	$\vdots$	$\vdots$
x_{n1}	...	x_{nj}	y_n

A **Regressão Linear** corresponde ao problema de estimar uma função a partir de pares entrada-saída e considera que Y **pode ser explicado por uma combinação linear de X** .


A equação (modelo de regressão linear simples) é dada por:

$$y = \beta_0 + \beta_1 x + \text{erro}$$

(onde β_0 é chamado de intercepto, e β_1 de slope, ou inclinação)

Regressão Linear

- Vamos voltar ao exemplo
 - escolha de um bairro para abrir uma nova filial
- Vamos olhar primeiro apenas para os dados que possuem valores para a variável resposta
 - para simplificar, vamos somente considerar as variáveis "Renda per Capita" e "Faturamento"




A Regressão Linear busca uma reta que melhor passe pelos pontos...

Regressão Linear


A equação está dada por:

$$\widehat{Fat} = \beta_0 + \beta_1 \times Renda$$

Vamos começar com a primeira tentativa, fazendo uma reta simples



Modelo: $\widehat{Fat} = 190$




Modelo: $\widehat{Fat} = 120$

Regressão Linear

Ao ajustamos a reta (aleatoriamente), o faturamento estimado:

$$\widehat{Fat} = 120 - 2 \times Renda$$

Percebemos que agora a reta sumiu do gráfico!



Como estimar os coeficientes?

Regressão Linear

- Os parâmetros de um modelo de regressão são exclusivamente os coeficientes $\hat{\beta}$ (“vetor beta estimado”).

$$Y = X\hat{\beta} + \hat{\varepsilon}$$

sendo $\hat{\varepsilon}$ o vetor de **resíduos**.

- O modelo de regressão linear estimado e o vetor de resíduos são, respectivamente:

$$\hat{Y} = X\hat{\beta}$$

$$\hat{\varepsilon} = Y - \hat{Y}$$


- Para estimar $\hat{\beta}$ usa-se o método dos mínimos quadrados ordinários (*OLS - ordinary least squares*):
 - objetivo é encontrar o vetor $\hat{\beta}$ que minimiza a soma dos erros ao quadráticos $(\hat{\varepsilon}^T \hat{\varepsilon})^2$

Regressão Linear

- No exemplo, a melhor solução para os β_0 e β_1 ótimos são:

$$\widehat{Fat} = -24,49 + 0,15 \times Renda$$

- Esta solução é dita ótima porque minimiza o erro de predição



É possível calcular um intervalo de confiança para a previsão

Regressão Linear

- Então...
 - Regressão Linear consiste em escolher β_0 e β_1 para construir uma reta que minimize a soma dos quadrados dos erros (SSE).

E se tivéssemos mais de uma variável preditora?


Regressão Linear

- Se quiséssemos adicionar uma nova variável (como preço do m^2), teríamos um modelo da forma:

$$\widehat{Fat} = \beta_0 + \beta_1 \times Renda + \beta_2 Pre\breve{ço}M^2$$


Regressão Linear

- Graficamente temos:



Regressão Linear Múltipla

- A solução passa por construir um plano (em vez de uma reta) que melhor se ajuste aos pontos:



- Neste caso, dizemos que temos uma **Regressão Linear múltipla**.
- Basta adicionar ao modelo as demais variáveis preditoras ($x_1, x_2, \dots, x_n$) e seus coeficientes correspondentes ($\beta_1, \beta_2, \dots, \beta_n$), além de β_0
 - que continuam a poder ser estimados pelo *Método dos Mínimos Quadrados* (que já vimos)

Regressão logística

Regressão Logística

- É um algoritmo utilizado para problemas de **Classificação Binária**.
 - (o/1, sim/não, verdadeiro/falso)
- Regressão Logística é usada para estimar a probabilidade de uma variável binária assumir o valor 1 para um dados um conjunto de atributos $x_1, \dots, x_p$.
- A regressão logística utiliza uma função **logit**

$$\text{logit}(p) = \ln \left(\frac{p}{1-p} \right)$$

para montar um um modelo de regressão linear como abaixo


$$y = \uparrow \ln \left(\frac{p}{1-p} \right) = \beta_0 + \beta_1 x_1 + \dots \beta_p x_p$$

Só para conforto

Regressão Logística

- Como a regressão responde com uma estimativa do calor da função logit, é necessário fazer transformação inversa, chamada função logística, dada por

$$f(x) = \frac{1}{1+e^{-x}} \rightarrow p = \frac{1}{1+e^{-y}}$$



→ Sigmoid: qualquer curva em forma de **S** que mapeia o números reais em um intervalo (0 , 1)

Regressão Logística

- De forma similar à Regressão Linear, a Regressão Logística usa uma equação como representação: os valores de entrada ($\mathbf{x}$) são combinados linearmente usando pesos ou valores de coeficiente para prever um valor de saída ($\mathbf{y}$).
 - A principal diferença é que o valor de saída usa uma Função Sigmoid (ou Logística) que retorna um valor entre 0 e 1.
 - Definindo um limiar de decisão (geralmente 0,5), é possível realizar uma classificação binária, atribuindo cada observação a uma das duas classes.
- Dessa forma, a saída do modelo pode ser interpretada como a probabilidade de uma observação pertencer à classe "padrão" do problema.
 - Por exemplo, ao modelar o sexo de uma pessoa com base na altura e considerando a classe "masculino" como padrão, o modelo estima: $P(\text{sexo} = \text{masculino} \mid \text{altura})$
- Os coeficientes da Regressão Logística podem ser estimados através do método de máxima verossimilhança .